

Ioan-Adrian CANDREA

PROIECT DE DIPLOMĂ

**Tehnici de detectare a evenimentelor de apnee
bazate pe analiza semnalului ECG**

SPECIALIZAREA TEHNOLOGII ȘI SISTEME DE TELECOMUNICAȚII

*Marchează dacă ai studiat
în limba engleză:*



**FACULTATEA DE ELECTRONICĂ, TELECOMUNICAȚII
ȘI TEHNOLOGIA INFORMAȚIEI
UNIVERSITATEA TEHNICĂ DIN CLUJ-NAPOCA**

UNIVERSITATEA TEHNICĂ DIN CLUJ-NAPOCA
FACULTATEA DE ELECTRONICĂ
TELECOMUNICAȚII ȘI TEHNOLOGIA INFORMAȚIEI
Specializarea: Tehnologii și Sisteme de Telecomunicații

**Tehnici de detectare a evenimentelor de apnee
bazate pe analiza semnalului ECG**

Proiect de diplomă

Absolvent,
Ioan-Adrian CANDREA



Decan,
Prof.dr.ing. Ovidiu POP

Președinte comisie,
Prof.dr.ing. Sorin HINTEA

2024

Această pagină a fost lăsată goală în mod intenționat.

UNIVERSITATEA TEHNICĂ DIN CLUJ-NAPOCA
FACULTATEA DE ELECTRONICĂ
TELECOMUNICAȚII ȘI TEHNOLOGIA INFORMAȚIEI

Departamentul Bazele Electronicii

Titlul proiectului de diplomă:

**Tehnici de detectare a evenimentelor de apnee
bazate pe analiza semnalului ECG**

Descrierea temei:

Obiectivul acestei lucrări este reprezentat de dezvoltarea unor metode eficiente pentru detectarea sindromului de apnee în somn, utilizând analiza semnalului ECG. Astfel, prin determinarea vârfurilor undelor P, Q, R, S și T, cât și prin identificarea a 13 parametrii caracteristici ai semnalului ECG, algoritmul propus permite identificarea evenimentelor de apnee cu o acuratețe de 84% pentru cele 50 de eșantioane testate.

În cadrul algoritmului, cei 13 parametrii sunt reprezentați de caracteristici ca ritmul cardiac, intervalele RR sau QRS, amplitudinea undelor R, P și T, precum și alți parametrii care sunt detaliați în capitolul dedicat implementării. Din perspectiva funcționării, algoritmul compară valorile fiecărui parametru cu un prag stabilit, iar semnalele care depășesc acest prag pentru parametrul testat sunt încadrate cu posibilitatea de a fi semnale cu apnee. În etapa următoare, se calculează suma parametrilor care au depășit pragul. Dacă suma depășește pragul unic, se detectează prezența apneei, iar în caz contrar, este clasificat ca fiind normal.

Locul de realizare:

Laboratorul de Circuite Integrate Digital - Facultatea de Electronică, Telecomunicații și Tehnologia Informației din Cluj-Napoca

Consultant: As.drd.ing. Laura MIHĂILĂ

Adaugă
consultant: ☒

Data emiterii temei: 25.10.2023

Data predării temei: 22.08.2024

Absolvent,

Ioan-Adrian CANDREA



Conducător,

Director departament,

Prof.dr.ing. Sorin HINTEA

Prof.dr.ing. Sorin HINTEA

Această pagină a fost lăsată goală în mod intenționat.

Declarație pe proprie răspundere privind autenticitatea lucrării de diplomă

Subsemnata/ul **Ioan-Adrian CANDREA**

legitimat cu CI seria XV nr. 648840 (conform copiei anexate prezentei declarații,
copie semnată și certificată "conform cu originalul"), autorul lucrării

Tehnici de detectare a evenimentelor de apnee bazate pe analiza semnalului ECG

elaborată în vederea susținerii examenului de finalizare a studiilor de licență,
la Facultatea de Electronică, Telecomunicații și Tehnologia Informației
Programul de studiu Tehnologii și Sisteme de Telecomunicații
din cadrul Universității Tehnice din Cluj-Napoca
sesiunea septembrie a anului universitar 2023-2024

declar pe proprie răspundere că această lucrare este rezultatul propriei activități intelectuale, pe baza
cercetărilor mele și pe baza informațiilor obținute din surse care au fost citate în textul lucrării și în
bibliografie.

Declar că această lucrare nu conține porțiuni plagiate, iar sursele bibliografice au fost
folosite cu respectarea legislației române și a convențiilor internaționale privind drepturile de autor.
Declar, de asemenea, că această lucrare nu a mai fost prezentată în fața unei alte comisii de examen
de absolvire/licență/diplomă/disertație.

În cazul constatării ulterioare a unor declarații false, voi suporta sancțiunile administrative,
respectiv anularea examenului de diplomă.

Sunt de acord ca, pe tot parcursul vieții, în cazul în care este necesar și se va dori verificarea
autenticității lucrării mele să fiu identificat și verificat în baza datelor declarate de mine și conform
copiei documentului de identitate menționat mai sus.


Data

22.08.2024

Nume și prenume

Ioan-Adrian CANDREA

Semnătura



Această pagină a fost lăsată goală în mod intenționat.

Absolvent: Ioan-Adrian CANDREA

Conducător: Prof.dr.ing. Sorin HINTEA

Consultant: As.drd.ing. Laura MIHĂILĂ

SINTEZA PROIECTULUI DE DIPLOMĂ

Tehnici de detectare a evenimentelor de apnee bazate pe analiza semnalului ECG

Această lucrare propune o tehnică eficientă pentru detectarea sindromului de apnee în somn prin utilizarea semnalelor ECG. În cadrul acestei metode, este aplicat algoritmul Pan-Tompkins pentru detecția punctelor P, Q, R, S și T, iar 13 parametri obținuți din morfologia semnalului sunt utilizați pentru a realiza clasificarea. Analiza de prag este aplicată pentru identificarea episoadelor de apnee, fiind o metodă neinvazivă și sigură, dar și utilă în ceea ce privește identificarea apneei pe un număr mare de parametri analizați. Această metodă se bazează pe compararea fiecărui parametru cu un prag prestabilit și prin contorizarea parametrilor care depășesc valoarea acestuia. La final, dacă un semnal are cel puțin 5 parametri care depășesc valorile pragurilor, semnalul va indica prezența apneei. Așadar, rezultatele obținute demonstrează că algoritmul atinge o acuratețe de 84% pe un set de 50 de eșantioane analizate, evidențiind eficiența metodei propuse. Din perspectiva contribuțiilor aduse, se poate evidenția eficientizarea procesului de detectare a sindromului de apnee prin dezvoltarea unei analize bazate pe parametri specifici și compararea acestora cu anumite praguri stabilite în funcție de caracteristicile semnalului evaluat.


Techniques for detecting apnea events based on ECG signal analysis

This paper proposes an effective technique for detecting sleep apnea syndrome by using ECG signals. In this method, the Pan-Tompkins algorithm is applied for the detection of P, Q, R, S and T points, and the 13 parameters obtained from the signal morphology are used to perform the classification. Threshold analysis is applied to identify apnea episodes, being a non-invasive and safe method, but also useful in identifying apnea on a large number of analyzed parameters. This method is based on comparing each parameter with a predetermined threshold and counting the parameters that exceed its value. Finally, if a signal has at least 5 parameters exceeding the threshold values, the signal will indicate the presence of apnea. So, the results obtained demonstrate that the algorithm achieves an accuracy of 84% on a set of 50 analyzed samples, highlighting the efficiency of the proposed method. From the perspective of the contributions made, it can be highlighted the efficiency of the apnea syndrome detection process by developing an analysis based on specific parameters and comparing them with certain thresholds established according to the characteristics of the evaluated signal.

Avizul conducătorului

Conducător,

Absolvent,



Această pagină a fost lăsată goală în mod intenționat.

Cuprins

1	Stadiul actual	11
2	Fundamentare teoretică	16
2.1	Inima și sistemul circulator	16
2.2	Celulele inimii.....	17
2.3	Electrocardiograma și frecvența cardiacă	17
2.4	Undele P, Q, R, S, T și intervalele acestora	19
2.5	Caracterizarea undelor semnalului ECG.....	20
2.5.1	Unda P.....	20
2.5.2	Unda Q.....	21
2.5.3	Unda R	22
2.5.4	Unda S.....	22
2.5.5	Unda T	23
2.5.6	Intervalul RR.....	23
2.5.7	Intervalul PR	23
2.6	Caracteristicile Apneei.....	24
2.6.1	Clasificarea tipurilor de Apnee	24
2.7	Zgomotul prezent în semnalul ECG.....	26
2.8	Filtrarea semnalului ECG	27
2.9	Algoritmul Pan-Tompkins	28
2.9.1	Filtru trece bandă	28
2.9.2	Filtru derivativ	29
2.9.3	Ridicarea la pătrat	29
2.9.4	Integrarea cu ferestre mobile	29
3	Implementarea soluției adoptate.....	30
3.1	Descrierea lucrării.....	30
3.2	Descrierea mediului de lucru MATLAB R2023a	30
3.3	Descrierea bazei de date - PhysioNet.....	31
3.4	Descrierea algoritmului de clasificare.....	32
3.5	Încărcarea datelor și realizarea algoritmului Pan-Tompkins	34
3.5.1	Algoritmul Pan-Tompkins	34
3.5.2	Filtru trece bandă	35
3.5.3	Derivarea.....	36
3.5.4	Ridicarea la pătrat – Squaring.....	36
3.5.5	Integrarea folosind ferestre mobile	36
3.6	Determinarea parametrilor	37
3.6.1	Unda R	37
3.6.2	Unda Q.....	38
3.6.3	Unda S.....	38

3.6.4	Unda P și Unda T	39
3.7	Determinarea parametrilor utilizați pentru detecție	39
3.7.1	Determinarea amplitudinii și media acesteia pentru undele R, P și T	39
3.7.2	Determinarea intervalelor RR	40
3.7.3	Determinarea intervalelor PR	40
3.7.4	Determinarea intervalelor QRS.....	41
3.7.5	Determinarea ritmul cardiac - Heart Rate	41
3.7.6	Determinarea puterii totale a semnalului ECG	42
3.7.7	Determinarea parametrului SDNN	42
3.7.8	Determinarea parametrului RMSSD.....	42
3.7.9	Determinarea deviației standard a intervalelor RR	43
3.7.10	Determinarea deviației standard a intervalelor RD	43
3.7.11	Determinarea parametrului NEP – numărul de puncte extreme	43
3.8	Metoda de clasificare a semnalelor	44
4	Rezultate experimentale	46
4.1	Detectarea vârfurilor P, Q, R, S și T pe tot intervalul	46
4.2	Testarea semnalelor ECG – Simulări MATLAB.....	47
4.3	Centralizarea rezultatelor semnalelor ECG.....	52
4.4	Analiza de performanță a algoritmului propus	53
5	Concluzii	55
6	Bibliografie.....	56

Lista de abrevieri

AHI – Apnea-Hypopnea	MSA - Mixed Apnea
BPM – Beats Per Minute	NEP - Number of Extreme Points
CNN - Convolutional Neural Network	OSA - Obstructive Sleep Apnea
CSA - Central Sleep Apnea	PPG - Photoplethysmogram
CVD - Cardiovascular Diseases	RD St. DEV. - RD Standard Deviation
ECG - Electrocardiogram	SpO2 - Oxygen saturation
EEG – Electroencephalogram	TN – True Negative
EMG – Electromiograma	TP – True Positive
FN – False Negative	WBAN - Wireless Body Area Network
FP – False Positive	
FTJ - Filtrul Trece-Jos	
FTS - Filtrul Trece-Sus	
HR - Heart Rate	
HRV - Heart Rate Variability	
RR St. DEV. – RR Standard Deviation	
RMSSD – Root Mean Square of Successive Differences	
SDNN - Standard Deviation of Normal-to-Normal Intervals	

Lista de tabele

Tabelul 1. Numărul de decese provocate din cauza bolilor cardiovasculare (2000 și 2019)[2].....	11
Tabelul 2. Semnalele extrase și clasificate conform adnotărilor din PhysioNet	32
Tabelul 3. Identificarea pragului unic pentru fiecare parametru	45
Tabelul 4. Stabilirea pragului pentru cei 13 parametrii	52
Tabelul 5. Diagnostic și contorizare rezultate semnale ECG	52

Lista de figuri

Figura 1. Valoarea de piață a dispozitivelor terapeutice pentru diagnosticarea de apnee [7].....	15
Figura 2. Structura camerelor inimii și a sistemului circulator [24].....	16
Figura 3. Electrocardiograma cu cele 6 derivații toracice [26]	18
Figura 4. Reprezentarea punctelor P-Q-R-S-T în cadrul ciclului cardiac [32].....	20
Figura 5. Unda P cu derivațiile (a.) II, (b.) V1 și (c.) V5 [34].....	21
Figura 6. Reprezentarea undei Q [34]	21
Figura 7. Unda R [35].....	22
Figura 8. Unda S [36].....	22
Figura 9. Unda T [36].....	23
Figura 10. Intervalul RR [37]	23
Figura 11. Intervalul PR [39]	24
Figura 12. Clasificarea tipurilor de Apnee [39].....	25
Figura 13. Exemplu de semnal ECG Normal și de semnal ECG cu Apnee [45]	26
Figura 14. Mediul MATLAB R2023a.....	31
Figura 15. Platforma PhysioNet – PhysioBank ATM.....	32
Figura 16. Etapele realizate pentru algoritmul de clasificare	33
Figura 17. Afișarea eșantionului de 10 secunde a semnalului ECG brut din PhysioNet.....	34
Figura 18. Secțiune de cod MATLAB pentru filtrare și normalizare.....	35
Figura 19. Afișarea semnalului ECG după etapele de filtrare, normalizare și derivare	35
Figura 20. Secțiune de cod MATLAB pentru etapa de squaring, integrare și limitare	36
Figura 21. Afișarea semnalului ECG conform celor 3 etape.....	37
Figura 22. Codul utilizat pentru detecția undei R.....	38
Figura 23. Codul utilizat pentru detecția undei Q și a undei S	38
Figura 24. Codul utilizat pentru detecția undei P și a undei T	39
Figura 25. Identificarea celor cinci unde și marcarea acestora pe semnalul ECG	39
Figura 26. Calcularea mediei amplitudinilor undelor R.....	40
Figura 27. Calcularea mediei intervalelor RR.....	40
Figura 28. Detectarea intervalelor QRS	41
Figura 29. Determinarea ritmului cardiac	41
Figura 30. Spectrul de putere și puterea totală a semnalului ECG	42
Figura 31. Algoritmul utilizat pentru detecția parametrului NEP	44
Figura 32. Algoritmul de detecție a pragului unic.....	44
Figura 33. Algoritmul de clasificare normal/apnee	45
Figura 34. Semnal ECG cu durată de o oră a subiectului a01	46
Figura 35. Semnal ECG cu durată de o oră a subiectului a14.....	47
Figura 36. Aplicarea algoritmului Pan-Tompkins pentru subiectul a01 cu etapele de filtrare, normalizare și diferențiere.....	47
Figura 37. Aplicarea algoritmului Pan-Tompkins pentru subiectul a01 cu etapele de ridicare la pătrat, integrare și aplicarea pragului	47
Figura 38. Reprezentarea semnalului ECG cu detecția vârfurilor pentru subiectul a01, eșantionul 37-47, detectat ca fiind normal	48
Figura 39. Reprezentarea semnalului ECG cu detecția vârfurilor pentru subiectul a01, eșantionul 3017-3027, detectat cu apnee	48
Figura 40. Reprezentarea semnalului ECG cu detecția vârfurilor pentru subiectul a07,	49
Figura 41. Reprezentarea semnalului ECG cu detecția vârfurilor pentru subiectul a14,	49
Figura 42. Reprezentarea semnalului ECG cu detecția vârfurilor pentru subiectul a13,	49
Figura 43. Reprezentarea semnalului ECG cu detecția vârfurilor pentru subiectul a19,	50
Figura 44. Testarea subiectului a14 care este detectat cu apnee	50
Figura 45. Testarea clasificării în raport cu unda R pentru toate semnalele.....	51
Figura 46. Clasificarea tuturor semnalelor utilizate	51
Figura 47. Eficiența generală a algoritmului de detecție	54
Figura 48. Eficiența particulară a algoritmului de detecție	54

Summary

The objective of the present work is to identify and detect the presence of abnormalities in the proper functioning of the heart. In recent years, the prevalence of sleep disorders, especially sleep apnea, has become a significant concern in medical research due to its profound impact on cardiovascular health and general well-being. Sleep apnea syndrome is characterized by repeated interruptions in breathing during sleep, interruptions that can lead to serious health complications, including heart disease, stroke, and high blood pressure. Thus, early and accurate detection is essential for effective treatment and management of the condition. To carry out this work, ECG or electrocardiogram signals were used, which represented an effective tool for detecting sleep apnea, offered amazing possibilities in terms of monitoring the heart's activity. Thus, by analyzing these signals, it is possible to identify ways and methods to identify the presence of sleep apnea. The present work aims to contribute to the development of a reliable and effective diagnostic tool for detecting the presence of sleep apnea. By using ECG data, the aim is to improve the accuracy of apnea detection, thus creating an alternative to existing diagnostic methods.

Nowadays, cardiovascular diseases (Cardiovascular Diseases - CVD) represent one of the main causes that cause a significant increase in mortality from one year to the next. The production of cardiovascular diseases are caused by various types of abnormalities, such as: heart attack, stroke, myocardial infarction, ventricular fibrillation, premature ventricular contraction, ventricular or supraventricular tachycardia or various types of arrhythmias. Compared to the last 25 years, among the population globally, the number of deaths caused by heart diseases has increased from 14 million people in 2000 to more than 17 million in 2019 worldwide planets. At the European level, things are a bit better given the fact that in 2000 there were 4.1 million deaths, representing a rate of almost 48% of the total deaths recorded at the level of the entire continent with a greater predisposition among women (54%) than men (43%), and in 2019, 3.4 million deaths were recorded on the European continent, this being the only location on earth where the number decreased compared to the number recorded at the level of the year in 2000. In Romania, the situation is as follows, at the level of 2000, a statistic is presented that indicates 500 deaths per 100,000 inhabitants, and in 2019, 315 deaths per 100,000 inhabitants are reported, which indicates a positive progress towards of the world trend. Globally, it is predicted that in the future things will continue to worsen especially in Asia, but also in Africa with the aging of the current population and due to the precarious eating style and way of life of people today, thus cardiovascular problems, with those related to obesity and diabetes, will end up being a much more serious problem for the health system even than it is today. Of these, timely disease prediction is a key step in avoiding many diseases that can result from apnea and even lead to death, especially in less developed areas of the world.

The cardiac cycle is characterized by two types of movements which are contraction or systole and relaxation or diastole. Thus, in the last century, people have invented methods, applications and devices to measure the parameters of the heart in order to determine in time various abnormal changes in the characteristics of the heart in order to avoid diseases or deaths that may arise from it, and one of the solutions has been invention of the electrocardiogram (ECG or EKG). This technique is a method used nowadays in almost all fields of modern medicine globally, being a non-invasive data recording method that is based on the collection of data about people's health status.

The electrocardiogram (ECG) is a basic and crucial diagnostic tool used to evaluate the electrical and muscular functions of the heart in order to identify abnormalities that may occur and to be able to correct them in time so that they do not endanger the lives of those monitored in danger. So the electrocardiogram captures the electrical activity of the heart over a period of time, generating a waveform with distinct patterns, yet repeating at a very short interval of time, and representing different phases of the cardiac cycle. These patterns are known as P, Q, R, S and T waves, each letter corresponding to a specific reference point on the ECG signal and

having some specific meaning. Also, these points have the role of helping to identify and delimit the different phases of the cardiac cycle and are used in various applications and methods of diagnosis, monitoring, even in the field of research, all of which have a very important role in the field of medicine modern. The points selected as reference points are represented by the P wave, where elements such as onset, peak or lag, the QRS complex, but also the presence of the T wave, are noted within the signal. The R wave is the first and only positive wave in the QRS complex, it represents the most important part of ventricular depolarization. This wave is also the main part of this process, mostly monitoring the depolarization of the ventricular myocardium. From the point of view of wave classification, from the QRS complex, all positive waves are R waves. If two or three positive waves appear in the same group, rare cases, the two waves that appear in addition will be called the R-first wave respectively R-bis, in addition to the first wave that will keep its name. The Q wave represents the first deflection which will always have negative values and is positioned after the P wave but before the R wave. This represents the stage after atrial depolarization, namely, the beginning of ventricular depolarization which is formed by the complex of Q, R and S waves. The S wave is the first negative wave that occurs immediately after the R wave and represents the last step of ventricular depolarization. Thus, this wave represents the final depolarization of the ventricles, especially of their upper parts near the base of the heart as blood leaves the body. The P wave represents the beginning wave of the ECG signal that shows and records the process of atrial depolarization. This is a wave that registers small values but shows only positive values, the small values being due to the fact that atrial depolarization occurs in the atria that have a small muscle mass, if a sinus rhythm is present, more precisely in conditions normal. In terms of the T wave, this represents the section of the ECG signal that is responsible for repolarization of the ventricles. The T wave is divided into two different parts, separated by its peak. The first part is known as the absolute refractory period, and the second half, which occurs after the peak of the T wave, is called the relative refractory period or vulnerable period.




Figure A. Representation of P-Q-R-S-T points within the cardiac cycle

The medically explained and very general term apnea, established by a simple and short idea, is a term that refers to the suspension of the breathing process for a varied period of time. Within it, the level of air in the lungs does not change, thus resulting in a constant volume, this happens because there is no more activity in the respiratory muscles or a very asymmetric activity of them. More specifically, there is a reduction in the flow of air entering the lungs of at least ninety percent of the normal value of the lungs for durations measured from at least ten seconds upwards. This airflow reduction event occurs for at least ninety percent of the total duration of the monitored event, and in terms of events per hour, a count of at least five events per hour can identify the presence of mild apnea or more severe, if more than fifteen or even thirty events per hour are recorded. For short periods, apnea does not endanger people's lives,

because it does not influence the process of cellular respiration if it lasts only for short periods of time, but if it is carried out for longer periods, here we are already talking about periods of time of at least three minutes of continuous status. Therefore, the situation can change drastically, because the lack of substances obtained from the breathing process, such as oxygen, can lead to many complications, including at the cerebral level, such as stroke or problems such as high blood pressure, memory disorders, fatigue continuous, lack of energy and quality sleep, attention or productivity. From the point of view of the classification of this condition, it is noted the appearance of three types of cases in which the ones present in Figure B can be listed, such as: obstructive sleep apnea (OSA), which is also the most common case of apnea marked by the presence to a respiratory effort felt throughout the event, central sleep apnea (CSA), marked by an absence of respiratory effort during the event, and mixed apnea (MSA), which is a combination of the first two cases and manifests itself especially against the first two cases by an absence at the beginning of the event of respiratory effort followed by an increase in it in the second part of this event, and for this reason, this case is mixed. One can also mention complex sleep apnea (CompSa), which can arise from CSA, so it is not a separate type like the first three, but is an unwanted evolution of CSA and is unfortunately known to be treatment-emergent.

The ECG signal has been used for the detection of both apnea syndromes, OSA and CSA, the advantages for which this variant can be used are represented by different physiological changes such as those given by the heart rate (HR). In this case, there is a visible increase in the rhythm in the case of apnea and may also reflect changes in the sympathetic nervous system which is in an active state during the apnea thus influencing the heart rate parameters, the heart rate variability (HRV), expressed in the time domain by the parameters such as SDNN or RMSSD.




Figure B. Classification of Apnea types

The selection of the subjects and the choice of the analyzed signal segments for each case for which the algorithm in the present work was created was made from the PhysioNet platform, a platform that provides information about the physiological data that keeps track of several people suspected of certain ailments and that were monitored over a varied period of time, depending on the condition for which the biomedical data was to be recorded in order to identify possible problems. This platform is very useful for implementing or creating applications with the role of monitoring severe conditions, such as the one exposed in this paper, and to achieve an efficiency of algorithms. Thus, the algorithms can be applied directly to the signals from PhysioNet, and the expensive step, both financially and time-consuming, of monitoring and collecting ECG signals from patients or people suspected of any abnormality, can be avoided by using the data from this platform. In the case of apnea, the database is structured as follows, the signals have a period equal to the sleep period that each subject has, so the total length of a signal from a patient is approximated to somewhere around 8 hours, exactly as is the normal sleep period for a person. In total, the signals from 30 people numbered from a01-a20, b01-b05, respectively c01-c05 are recorded, of which 5 of them were chosen for testing. Therefore, subjects a01, a07, a013, a14, and a19 were selected, from which selected ECG signals of one hour in length each, in seconds time format, were taken.

The algorithm in this paper extracts the parameters exclusively from the processed signal structure, and in this way the following steps will be performed: using the Pan Tompkins algorithm to detect the peaks for Q, R and S waves, and based on thresholds set with respect to the R wave, they will be detected the values also for the other two waves, respectively P and T. In this context, with all correctly detected waves, it is possible to obtain based on them and not only, the different parameters to be able to analyze and divide the normal cases from the abnormal ones that present the apnea syndrome . So, after detection according to the unique threshold for each parameter, two classes of parameters will be highlighted, those that have a value below the threshold, parameters that are part of the normal class and those that have a value above the threshold and will therefore be part of the apnea class. In total, in this work, 13 different parameters were evaluated in order to finally make a diagnosis as precise as possible. Several parameters were chosen to test because the characteristic of the apnea signal is not always the most constant, as not all waves in the PQRST complex comply with the apnea condition. In this situation, the best method was chosen to increase the number of tested parameters, thus reaching 13, which after testing gave very good results. In the first part of the algorithm, after identifying the P, Q, R, S and T waves, which served as an important and essential support in order to identify the 13 parameters and establish the threshold for each parameter, a result will be provided binary, 0 in the normal case, respectively 1 if the parameter goes over that established threshold, and this is where the first part of the algorithm ends. Next, comes the second part of the algorithm where, based on the first part, all the cases within the 13 parameters that return a value greater than their threshold are gathered for a signal, therefore the case of apnea or the case that is numbered 1, is sum them up and depending on how many cases of 1 there were for a signal you will get a number between 0 and 13 that will reflect the number of cases less good than the good ones. Furthermore, a threshold will be set to delimit the cases of normal signals from the cases of apnea signals which, normally and obviously, will be less than half the value of all parameters in order to provide a result as correct as possible and so that the algorithm to present as much accuracy as possible to be considered relevant in this field in which it was made. In the following figure, you can see a diagram showing the steps taken to implement the apnea detection algorithm.




Figure C. The stages performed for the classification algorithm

The Pan-Tompkins algorithm is a highly recognized and very effective method, it is used for the detection of the QRS complex, more specifically their peaks within the ECG signal, later other parameters can be identified. Other parameters that can be identified are represented by examples as the other peaks in the signal, like P and T, but also by certain intervals that were detected in the present work, like the RR, QRS or PR intervals, but also the possibility of

identifying parameters such as the heart rate which can be deduced from the number of R waves within the analyzed ECG signal. Thus, the steps of the algorithm are as follows: the application of a low-pass filter, represented in the paper in the form of two consecutive high-pass and low-pass filters, followed by a differentiation step that has the role of determining the information about the slope, after which a squaring to be able to ensure that all peaks will register positive values and finally the integration part is applied which is highlighted by motion window integration to get a clearer and more obvious feature of the QRS complex. Also, an important indicator of the ECG signal in identifying the diagnosis of Apnea is given by changes in the reference points or intervals of the ECG signal (P wave, T wave and QRS complex) being used to be able to obtain the reference points or for to detect waveform values. Examples can be supported by changes in the ST segment that can be highlighted by hypoxia or problems of a myocardial nature. Also, the changes in the QRS complex, in which the changes in the amplitude or duration of the RR intervals were highlighted, where these intervals tend to be longer in the case of apnea signals due to the decrease in heart rate.

From the perspective of the analyzed parameters, the 13 parameters that will provide the answer of this algorithm are: the average of the peaks of the R waves, the average of the peaks of the T waves, the average of the peaks of the P waves, the average of the RR intervals, the average of the QRS intervals, the average of the PR intervals, the heart rate value, the total power, SDNN (Standard Deviation of Normal-to-Normal Intervals), RMSSD (Root Mean Square of Successive Differences), Standard Deviation RR, Standard Deviation RD and NEP (Number of Extreme Points), as also shown in Table A.

Tabele A. Identification of the unique threshold for each parameter

Parameter	Threshold	Parameter	Threshold
R Wave Amplitude	0,731	Total Power	0,025
T Wave Amplitude	0,088	SDNN	0,057
P Wave Amplitude	0,037	RMSSD	0,00609
RR Interval	0,817	RR Standard Deviantion	0,054
QRS Interval	0,2244	RD Standard Deviation	0,048
PR Interval	0,087	NEP	0,38632
Heart Rate	60 -100	-	-

From the results obtained following the execution of the algorithm, it emerges that this algorithm has an accuracy and precision equal to 84%, results from the application of the algorithm on the 50 signals, tested from the 5 people, of which 25 signals were identified as normal , and 25 identified with apnea according to PhysioNet, in 42 cases the answer was the same as that provided by PhysioNet, and in 8 cases a result inconsistent with the one in the database was recorded. In the case of the 8 signals with the wrong answer, 4 signals were normal signals detected with apnea, respectively all 4 signals with apnea detected as normal, from these values the accuracy and precision percentages of the algorithm were calculated.

In conclusion, the present project represents a very good starting point to reach a more effective medical assistance, in order to prevent some health problems. Capitalizing on the processing and analysis of the ECG signal can become a real possibility for the early detection of sleep apnea, because in this way the chances of developing cardiovascular complications associated with this syndrome are reduced. From the perspective of technological advancements, the development of such technologies is extremely promising for the future of medicine in terms of patient health monitoring and disease prevention.

Planificarea activității

Număr Criteriu	Activitate	Data Începere	Data Finalizare
1	Alegere temă proiect	25.10.2023	30.10.2023
2	Studiu bibliografic	05.11.2023	20.03.2024
3	Implementarea practică	01.04.2024	10.08.2024
4	Redactare parte teoretică	23.03.2024	19.07.2024
5	Redactare capitolului de implementare	08.08.2024	16.08.2024
6	Rezultate și concluzii	17.08.2024	19.08.2024
7	Finalizarea lucrării	27.10.2023	22.08.2024

1 Stadiul actual

În zilele noastre, bolile cardiovasculare (Cardiovascular Diseases - CVD) reprezintă una din principalele cauze care determină o creștere semnificativă a mortalității de la un an la altul. Poducerea bolilor cardiovasculare sunt cauzate de diferite tipuri de anomalii, precum: atacul de cord, accidentul vascular cerebral, infarctul miocardic, fibrilația ventriculară, contracția ventriculară prematură, tahicardia ventriculară sau supraventriculară sau diverse tipuri de aritmii. Raportat la ultimii 25 de ani, în rândul populației la nivel global, conform [1], numărul de decese care au fost provocate de afecțiunile cardiace a crescut de la 14 milioane de oameni, aferent anului 2000, la o valoare de peste 17 milioane în anul 2019 la nivelul întregii planete. La nivel european lucrurile stau ceva mai bine prin prisma faptului că în anul 2000 s-au înregistrat 4,1 milioane de decese, reprezentând o rată de aproape 48% din totalul deceselor înregistrate la nivelul întregului continent cu o predispoziție mai mare în rândul femeilor (54%) decât al bărbaților (43%), iar în anul 2019, la nivelul continentului european au fost înregistrate 3,4 milioane de decese, acesta fiind singura locație de pe pământ unde numărul a scăzut comparativ cu numărul înregistrat la nivelul anului în anul 2000. În România situația se prezintă în următorul fel, la nivelul anului 2000 este prezentată o statistică ce indică 500 de decese raportat la 100.000 de locuitori, iar în 2019 sunt raportate 315 decese raportate la 100.000 de locuitori, conform *WHO, Global Health Estimates (2020)*, lucru care denotă un progres pozitiv față de tendința mondială. La nivel global se preconizează că în viitor lucrurile vor continua să se înrăutățească în mod special în Asia, dar și în Africa odată cu îmbătrânirea populației actuale și datorită stilului precar de alimentație și modul de viață a oamenilor din prezent, astfel problemele cardiovasculare, odată cu cele legate de obezitate și diabet, o să ajungă să fie o problemă mult mai serioasă pentru sistemul de sănătate chiar decât este în ziua de astăzi. Din punct de vedere economic, la nivelul Uniunii Europene, conform [2] raportat la nivelul anului 2023, bolile cardiovasculare implică costuri în medie de 282 miliarde de euro anual, din care 155 de miliarde de euro reprezintă sănătatea și îngrijirea pe termen lung, raportând o valoare de 11% din totalul bugetului alocat pentru sănătate, iar celelalte costuri sunt reprezentate de pierderile de productivitate (17%) sau de costurile de îngrijire informală (28%). În medie, la nivelul Uniunii Europene bolile cardiovasculare au generat un cost de aproximativ 630 de euro de persoană, aceste cifre variind în funcție de țară, spre exemplu: în Grecia costul a fost de 491 de euro pe persoană, în timp ce în România costul a fost de 637 de euro, iar în Germania s-a înregistrat aproximativ 900 de euro, această fiind și cea mai mare valoare din Uniunea Europeană.

Tabelul 1. Numărul de decese provocate din cauza bolilor cardiovasculare (2000 și 2019)[2]

[Sursa datelor : *WHO, Global Health Estimates (2020)*]

Situația numărului de decese	AN		EVOLUȚIA SITUAȚIEI	
	2000	2019	ABSOLUTĂ	RELATIVĂ
Regiune				
ASIA	7.197.265	10.751.486	+3.554.221	+49%
AFRICA	1.153.034	1.616.215	+463.182	+40%
EUROPA	4.100.834	3.399.734	-701.100	-17%
AMERICA DE NORD	1.209.787	1.303.411	+93.624	+8%
AMERICA DE SUD	550.858	719.668	+3.775	+31%
OCEANIA	69.538	73.313	+168.810	+5%
TOTAL	14.281.316	17.863.826	+3.582.510	+25%

De-a lungul timpului, problema monitorizării manuale și precise a modului în care inima lucrează a reprezentat o adevărată provocare pentru cardiologi. Conracțiunile inimii sunt caracterizate de ciclul cardiac care are o durată de 0,8 secunde, echivalentul a aproximativ 75 de bătăi pe minut. Ciclul cardiac este caracterizat de două tipuri de mișcări care sunt reprezentate de contracție sau sistolă și de relaxare sau diastolă. Astfel, în ultimul secol, oamenii au inventat metode, aplicații și dispozitive pentru a măsura parametrii inimii în vederea determinării din timp a diferitelor modificări anormale a caracteristicilor inimii în vederea evitării bolilor sau a deceselor care pot surveni din aceasta, iar una dintre soluții a fost inventarea electrocardiogramei (ECG sau EKG). Această tehnică este o metodă folosită în zilele noastre aproape în toate domeniile medicinei moderne la nivel global, fiind o metodă de înregistrare a datelor neinvazivă care se bazează pe colectarea de date despre starea de sănătate a oamenilor. ECG este o metodă care înregistrează semnalul electric la suprafața corpului prin amplasarea unor electrozi, fiind o tehnică utilizată în monitorizarea diferitor tipuri de subiecți de la cei care urmează diverse tratamente bazate pe consumul de medicamente, la cei care lucrează la locuri de muncă cu risc ridicat sau chiar și la sportivi care practică sport de performanță. Această tehnologie poate să fie folosită în domeniul cercetării și a studiilor a medicamentelor care au rolul de a îmbunătăți starea de sănătate a persoanelor care suferă de probleme cardiace severe [3].

Tehnica electrocardiogramei a fost implementată pentru prima dată la începutul secolului trecut, mai exact în anul 1901 de către medicul olandez și fiziolog Willem Einthoven. Acesta s-a remarcat prin prezentarea unui nou galvanometru cu corzi, acesta fiind o îmbunătățire față de electrometrul capilar prezentat în 1887 la Londra de către fizicianul britanic Augustus Waller, cel care l-a inspirat pe Einthoven să cerceteze în mai de aproape acest domeniu și să creeze termenul de electrocardiograma în 1893, iar în 1895 au fost caracterizate și cele 5 abateri notate cu (PQRST). În 1905 acesta pune bazele prin faptul că a reușit să se conecteze la un spital utilizând linia telefonică pe o distanță echivalentă cu o lungime de 1500 metrii, acesta fiind un lucru foarte impresionant pentru acea perioadă care din păcate nici măcar în zilele noastre nu a reușit să fie per total implementat. Chiar dacă la început noua tehnologie era pusă la îndoială, sub aspectul că Waller nu a crezut că poate ca aceasta să fie răspândită la nivel larg în spitale, în urma studiilor lui clinice ale lui Einthoven cu galvanometrele cu corzi, care au fost derulate pe o perioadă de 10 ani, s-a ajuns la nivelul în care acest dispozitiv să fie un dispozitiv indispensabil din orice unitate medicală. Mulțumită descoperirilor științifice ale lui Willem Einthoven, acesta a primit Premiul Nobel pentru Medicină în anul 1924, fiind recunoscut drept „Părintele electrocardiografiei”. Datorită faptului că dispozitivele inițiale aveau o masă foarte mare de aproximativ 300 de kilograme, în anii următori, descoperirile lui Einthoven au avansat, fiind descoperite metode de scriere directă a electrocardiografiei. În 1937 medicul japonez Taro Takemi a dus totul la un alt nivel prin crearea primului aparat portabil capabil să înregistreze semnalele în cauză, ceea ce a permis o mobilitate mult mai bună a dispozitivelor și la răspândirea mai ușoară a acestei tehnologii. În anii care au urmat au fost realizate progrese mari în acest domeniu, dar și anumite idei care nu au putut să fie niciodată implementate la scară largă, spre exemplu în 1963 oamenii de știință care au identificat magnetocardiograma bazată tot pe activitatea electrică a inimii, au venit cu o metodă care putea detecta semnalul ECG fără utilizarea plasturilor cu electrozi cutanați, dar din păcate această metodă nu a putut să fie implementată din cauza costurilor mari pe care le-ar fi generat [4].

În anii care au urmat, oamenii au trecut la tehnologia digitală, fapt care nu a ocolit domeniul detecției semnalului ECG. Tehnologia tipăririi circuitelor utilizând siliciul a revoluționat lumea prin micșorarea dispozitivelor medicale care au putut să fie implementate pentru o monitorizare continuă a semnalelor inimii chiar din confortul casei pacientului. Prin urmare, s-au dezvoltat și popularizat dispozitivele portabile care pot monitoriza parametrii cardiaci ai corpului uman. Tehnologii ca WBAN (Wireless Body Area Network), care a apărut în 1995, a prezentat un pas mare înainte. Prin această tehnologie se transferă informații esențiale foarte rapid, care înainte trebuia să fie descoperite și comunicate între cel puțin două persoane. De exemplu, în domeniul medicinei au putut să fie identificate anumite afecțiuni mult mai rapid, sau situații

neașteptate precum sunt cele de ordin cardiac, ca exemplu, hipertensiunea sau dereglările pulsului, cât și prin costurile reduse cu care poate să fie implementată această tehnologie. Această tehnică s-a bazat pe sisteme deja inventate ca internetul sau Bluetooth, unde datele monitorizării semnalelor emise de inimă să poată fi transmise între dispozitive. Așadar, aplicațiile din domeniul medicinei au fost adaptate la tehnologiile care erau deja existente, simplificând procesul de monitorizare continuă a stării de sănătate a populației, iar un aspect foarte important este constituit de monitorizarea care se realizează în condiții normale. Datele obținute sunt foarte concludente, deoarece în timpul colectării acestora corpul uman se află într-un mediu cu care acesta interacționează zilnic, deci la apariția unei probleme aceasta o sa poată să fie identificată în cel mai scurt timp posibil. Un sistem bazat pe Wireless Body Area Network (WBAN) trebuie să conțină următoarele componente: senzori și unitate de control (transmite informații de la senzori la dispozitivele personale prin intermediul unor antene de mici dimensiuni, dar care trebuie să transmită datele pe cât de corect posibil). Din punct de vedere al condițiilor de funcționare se remarcă următoarele: chiar dacă persoana își modifică poziția în mod continuu senzorii trebuie să ofere o transmitere a informațiilor precisă, neîntreruptă și relevantă. Latența aparatelor de măsură trebuie să fie sub 250 ms pentru aplicațiile non-medicale și de sub 125 ms pentru aplicațiile medicale, iar fluctuațiile lor trebuie să fie sub 50 ms. Fiecare rețea WBAN trebuie să suporte minim 256 de noduri. În cazul dispozitivelor care sunt implantate în corpul uman este utilizată o bandă de transmisie MICS (Medical Implant Communication System) care are valori cuprinse între (402-405 MHz), putere mică și o lungime de transmisie mică, de aproximativ 2 metri. Pot să folosească WMTS (Wireless Medical Telemetry Service) pentru sistemele de telemetrie medicală, iar ca aplicații putem aminti de telemedicina și monitorizarea pacientului la distanță, viața asistată ambiantă sau biofeedback, în domeniul medicinei. Totuși un lucru semnificativ de notat este faptul că orice tehnologie nouă aduce atât avantaje cât și dezavantaje. În cazul WBAN au apărut probleme precum nevoia de a crea dispozitive care consumă puțină energie electrică, deoarece dispozitivele de monitorizare a parametrilor lucrau pe baterii, cât și de calibrare a senzorilor care în funcție de diferiți factori externi, pot să nu mai înregistreze corect datele. Un avantaj considerabil este reprezentat de gama foarte mare de produse cu rol de monitorizare pe care le poate avea această tehnologie. Câteva exemple de produse care folosesc WBAN sunt reprezentate de dispozitive ca ceasurile smart, brățările de monitorizare, plasturi, articole de îmbrăcăminte sau coliere inteligente, care pot să fie legate de laptopuri, servere sau telefoane pentru a transmite informații.

Totuși, foarte greu au putut fi abordate diverse cazuri excepționale ale echipamentelor care monitorizează semnalul ECG. De exemplu, electrocardiograma cu trei deviații, care era considerată o metodă bună de detecție și evaluare a aritmiilor, nu era suficient de precisă în vederea detectării infarctului miocardic, deoarece acesta se putea produce în zona de tăcere a electrocardiogramei și astfel acesta nu mai era corect identificat. Astfel, la nivelul anului 1934 au fost stabilite principiile electrofiziologiei contemporane la care *The American Heart Association* a emis o recomandare care delimita 6 puncte de interes în vederea colectării informațiilor de pe corpul uman numerotate de la V1 la V6. Chiar și așa unele zone au rămas neobservate, în următorii ani fiind compuse variante noi de înregistrare, ca de exemplu adăugarea monitorizării semnalului la nivelul membrelor, care deși genera o arie mare de acoperire, s-a dovedit că semnalul transmisiei era prea mic. În 1954 *The American Heart Association* a recomandat folosirea electrocardiogramei cu 12 derivații care a trecut prin diverse modificări până astăzi [4].

Raportat la stadiul din ultimii ani și a ceea ce există în prezent din punct de vedere a noilor tehnologii, conform [5] în ultima perioadă au apărut tot mai multe aplicații care au la bază inteligența artificială (AI) prin formele sale de implementare utilizând machine learning. Mai mult, deep learning, fiind un domeniu al inteligenței artificiale care utilizează modele sau anumiți algoritmi extrași din datele brute pentru a învăța cum să se identifice o caracteristică normală de una care desemnează o dereglare sau o afecțiune. Din domeniul învățării profunde, rețele neuronale convoluționale (CNN) sunt folosite în general în detectarea imaginilor. Aceste progrese au dus la dezvoltarea unor modele complet automatizate care reproduc interpretarea

umană a semnalului în cauză având o rată de succes în diagnosticarea problemelor apărute superior celei umane și într-un timp mult mai scurt. Astfel, un singur semnal ECG cu 12 derivații ar putea să asigure suficiente date pentru detectarea rapidă a problemelor de sănătate, testările și ghidările fiind centrate într-un mod precis și bine punctat pentru descoperirea rapidă și eficientă a unor probleme care pot să apară. Totuși, aceste tehnologii nu înseamnă că nu prezintă și limitări. Cum am precizat și mai sus, semnalul prezintă câteva constrângeri, limitări care pot să cauzeze rezultate eronate furnizate de modelele cu inteligență artificială. Multe aplicații ale semnalului ECG sunt realizate în domeniul deep learning care utilizează rețele neuronale cu mai multe straturi care învață în funcție de ce date avem la intrare cam ce trebuie să iasă la ieșire. Avantajul acestei metode față de cea clasică este că aceste rețele cu cât se antrenează pe mai multe modele, pot învăța potriviri și căi noi de unele singure fără a necesita asistența umană. Posibilul dezavantaj venind de la faptul că dacă algoritmul are modele prea ușoare sau doar de un anumit fel să nu fie fezabil în detectarea problemelor în modelele noi sau cele prea complexe. Referitor la analiza ECG, se pot considera ca date de intrare intervalele QT, QRS, RR sau morfologia undei T, iar ca ieșiri să avem ritmul ECG. În cazul deep learning, cel mai comun model de învățare fiind cel pe CNN care are ca și componentă principală reprezentarea video[6]. Din punct de vedere al aplicațiilor care folosesc deep learning, în acest domeniu se remarcă implementări ca detectarea bolilor de inimă dintr-un ECG necalibrat (2021)[8], clasificarea bolilor de inimă folosind nucleul bazat pe caracteristici ECG (2021)[9], un sistem inteligent de monitorizare a asistenței medicale pentru predicția bolilor de inimă, care este bazat pe învățare profundă a modelului și fuziunea caracteristicilor (2020)[10], diagnosticarea defectului septal atrial din electrocardiogramă (2021)[11], localizarea infarctului miocardic pe baza rețelei DenseNet (2021) [12] sau model de detecție a anomaliilor bazat pe modelul de decizie (2020) [13].

Somnul este o componentă crucială în viețile noastre, oamenii dormind în medie o treime din viață. Orice afecțiune sau dereglare care poate să apară în somn reprezintă un pericol pentru viața indivizilor. Astfel, aceștia trebuie să fie atenți la stilul de viață pe care îl au, să își monitorizeze starea de sănătate constant și să facă cercetări suplimentare atunci când apar simptome nedorite. Apneea este caracterizată prin episoade de stopuri respiratorii care se repetă în timpul somnului, aceasta se împarte în OSA (Sindromul de Apnee Obstructivă în somn) și CSA (Apneea Centrală de Somn). OSA se caracterizează prin răspândirea la o proporție de 2% până la 4% din populația adultă, dar este întâlnită la o rată de 1% - 3% la copii. Aceste cifre nu sunt chiar precise și sunt imposibil de monitorizat cu exactitate din cauza faptului că procedura de detectare durează mult timp, iar unii oameni care suferă de această problemă, nu semnalează prezența apneei. Relevanța este considerată destul de ridicată, cu valori care variază între 9 și 38% din populația lumii, estimându-se că cel puțin 1000 de persoane își pierd viața anual din această problemă. Un element cheie este reprezentat de faptul că aceste cazuri sunt în mare parte nediagnosticate, totodată generând pierderi de 70 de miliarde de dolari. Tot din punct de vedere al cheltuielilor, un studiu efectuat pe piața din estul continentului european, în martie 2022 [7], a arătat că în anul 2017 s-a investit în medie 277 de milioane de dolari în dispozitive terapeutice pentru diagnosticarea apneei, iar în anul 2020 valoarea crescând la 332 de milioane de dolari și se preconizează că această valoare o să crească și mai mult. La nivelul anului 2027 fiind estimate cheltuieli de aproximativ 511 milioane de dolari, din care aproximativ 300 de milioane de dolari au fost pentru dispozitivele terapeutice, iar restul de 210 milioane de dolari pentru dispozitivele de diagnostic. Din punct de vedere economic, acest domeniu se află pe un trend ascendent și în următorii ani vor avea o importanță tot mai mare.




Figura 1. Valoarea de piață a dispozitivelor terapeutice pentru diagnosticarea de apnee [7]

Ca simptome generale care pot să ajute la depistarea problemei se numără zgomotele produse de pacienți pe durata somnului, somnolența excesivă sau insomniile, iar ca factori de risc fiind lucruri ca vârsta, sexul, obezitatea, alcoolul sau traumatismele fizice suferite. Ca fapt de notat, diversele zgomote produse de pacienți pe durata somnului este una din principalele cauze solicitării asistenței medicale în cazul persoanelor susceptibile că ar putea suferii de OSA, în medie 60% dintre bărbați și 40% dintre femei suferă de sforăit, dar aproximativ 70% dintre persoanele care produc anumite sunete pe perioada somnului, dezvoltă riscul de a avea OSA, în timp ce aproximativ 95% din persoanele diagnosticate cu OSA suferă și de sforăit. Astfel, s-a constatat că este o nevoie foarte mare de progres în acest domeniu pentru a se reuși identificarea în timp util a problemelor cu scopul de a se lua măsuri, înainte ca acestea să degenereze în afecțiuni noi care pun viața populației în pericol. Conform sursei [14], din punct de vedere clinic, apneea este reprezentată de o scădere a fluxului de aer inspirat cu cel puțin 30 de procente până chiar la încetarea fluxului față de nivelul de aer inspirat pe perioada somnului, de asemenea se remarcă și o scădere cu cel puțin 4 procente, pentru o perioadă mai mare de 10 secunde, ceea ce prezintă un alt aspect de notat când vine discuția despre identificarea acestei probleme. Ca principale efectele ale unui somn necalitativ cumulat cu afecțiunea menționată pot duce la probleme ca insuficiență cardiacă, hipertensiune arterială, afecțiuni la nivelul arterelor coronare, diabet și alte afecțiuni. Prin urmare, identificarea timpurie a acestei probleme de sănătate reprezintă un aspect important în ceea ce privește evoluția vieții pacienților. Din punct de vedere al identificării, polysomnografia (PSG) se remarcă ca fiind un mijloc util, acesta necesită ca persoana examinată să stea o noapte sau chiar două nopți într-un laborator în vederea supravegherii continue pe durata somnului. În mod obișnuit, diferiți senzori și fire sunt amplasați pe corpul subiectului în vederea înregistrării de diferite semnale fiziologice care pot să fie: unde cerebrale remarcate de electroencefalograma (EEG), nivelul oxigenului din sânge (SpO2), monitorizarea mișcărilor ochilor – electrooculogramă (EOG), electromiograma (EMG), PPG, a ritmului cardiac, ECG chiar și efortul de respirație sau fluxul de aer [15]. Diagnosticul este identificat de către indicii de apnea-hypopnea (AHI) care este reprezentat de numărul de evenimente anormale identificate pe oră pe toată durata somnului. Cu toate acestea multe semnale analizate prezintă și dezavantaje, spre exemplu, semnalul ECG este ușor influențat de starea altor boli cardiovasculare active sau în cazul semnalului SpO2 sensibilitatea oximetriei este prea mică pentru a detecta toate evenimentele [14]. Evenimentele legate de respirație pot să fie detectate de ECG doar în proporție de 75% din cazuri [16], dar pe perioada somnului se pot induce modificări hemodinamice acute măsurabile, cum ar fi presiunea arterială crescută și frecvența cardiacă și nivelul pulsului. Una dintre soluții fiind folosirea fotopletomografie (PPG) care în acest context are rolul de a detecta diverse variații ale amplitudinii unde de puls (PWA), acesta prezintă o corelație mai bună cu modificările induse care nu sunt detectate de EEG. La pacienții care suferă de apnee s-a constatat că evenimentele de respirație introduc mai multe modificări ale PWA decât cele ale frecvenței cardiace (HR), astfel folosirea PPG și SpO2 sunt opțiuni viabile pentru detectarea anumitor probleme.

2 Fundamentare teoretică

2.1 Inima și sistemul circulator

Inima reprezintă un organ muscular esențial întâlnit la toate ființele umane și reprezintă o parte vitală în procesul de susținere a vieții. Acest organ are o funcționalitate asemănătoare cu o pompă, acesta are rolul de a asigura circulația sângelui prin vasele sistemului circulator și are un rol esențial în susținerea vieții organismului în care se află. Sângele care este pompat prin intermediul inimii livrează oxigen și diferite substanțe nutritive către întregul corp la diferite țesuturi ale corpului uman, în timp ce pe calea de întoarcere a sângelui din care a fost extras oxigenul se colectează și elimină diferitele resturi sau materii utilizate de natură metabolică, precum dioxidul de carbon (CO_2). Acestea sunt direcționate către plămâni pentru a putea fi eliminate. În cadrul corpului uman, inima are dimensiunea aproximativă a unui pumn închis, având o masă de aproximativ 300 de grame și este localizată în cavitatea toracică, mai exact între plămâni, având vârful orientat spre stânga, iar din cauza acestei amplasări plămânii corpului uman se remarcă prin faptul că au dimensiuni diferite, mai precis se distinge proprietatea de asimetrie a acestora. În general, inima unei persoane aflate în condiții normale de viață, are o medie cuprinsă între 60 și 100 de bătăi pe minut și efectuează în aceeași etapă ambele procese de recepționare și de trimitere a sângelui în organism [27] [28] [29] [30]. Din punct de vedere al alcătuirii, inima este compusă din patru camere, două fiind reprezentate de camerele atriale și celelalte două de cele ventriculare. Acestea sunt clasificate împreună, câte două în funcție de partea inimii în care se află, pe perechi, atriu și ventricul, perechi care nu comunică din perspectiva volumului de sânge care trece prin inimă. O parte a inimii, adică o pereche formată dintr-un atriu și un ventricul, este responsabilă de sângele oxigenat, partea dreaptă, în timp ce cealaltă pereche, de pe partea stângă, este responsabilă de sângele venit din corp și care este lipsit de oxigen. Sângele având proprietatea de a trece prin inimă, utilizând o singură direcție, mergând de la atrii la ventricule, acestea vor permite existența ciclului cardiac și implicit a sistemului circulator, care este reprezentat de circulația pulmonară, prin artera pulmonară și de circulația sistemică care se realizează prin artera aortă, cea din urmă, necesitând o putere de pompare mai mare, fapt care generează și grosimea ventriculului stâng care are pereții mai groși. Dezvoltând subiectul, circuitul pe care sângele îl urmează, reprezentat și în cadrul Figurii 2, are următorul traseu: sângele fără oxigen din corp ajunge în atrul drept după care acesta, în urma procesului de pompare al inimii, ajunge în ventriculul drept de unde este trimis la plămâni unde, în urma procesului de ventilație pulmonară, sângele o să fie oxigenat. După acest proces, sângele se întoarce la inimă în atrul stâng, iar apoi este trimis în ventriculul stâng care îl va trimite în corp în vederea realizării mecanismului de circulație prin întreg corpul. Nodul sinoatrial este localizat în atrul drept și reprezintă modalitatea de stimulare a inimii, fiind considerat stimulatorul cardiac natural, datorită rolului esențial pe care îl joacă în procesul de generare și de transmitere al impulsurilor electrice care determină contracțiile ritmice ale inimii. De asemenea, acesta are capacitatea de a genera spontan impulsuri electrice, impulsul electric fiind transmis către atrul drept și la restul mecanismelor de conducere ale inimii, lucru care duce la contracția miocardului și la procesul de distribuire a sângelui în corp [27] [28] [29] [30].




Figura 2. Structura camerelor inimii și a sistemului circulator [24]

2.2 Celulele inimii

Ciclul cardiac este format din două componente principale reprezentate de diastole și de sistole, diastolele reprezentând intervalul în care camerele inimii sunt în starea de relaxare, permițând sângelui să intre în inimă, iar în timpul sistolei, inima se contractă pentru a realiza pomparea sângelui din inimă în cop, având parametrii diferiți. Un ciclu durează aproximativ 0,8 secunde, din care diastola durează aproximativ 0,4 secunde, iar sistola tot 0,4 secunde, din care 0,1 secunde sunt reprezentate de sistola atrială, iar 0,3 secunde sunt reprezentate de sistola ventriculară. În cadrul inimii întâlnim trei tipuri de celule reprezentate de stimulatoare cardiace, celulele conducătoare electrice și celulele miocardice. Primul tip de celule este reprezentat de celulele stimulatoare cardiace care sunt de dimensiuni mici, maxim până la 10 μm , fiind responsabile de procesul de depolarizare, având rata de depolarizare direct dependentă de caracteristicile sale electrice primite direct de la apariția acestora. În cadrul inimii, fiecare proces de depolarizare reprezintă mecanismul care inițializează un ciclu cardiac complet de contracție și relaxare. În cadrul unei singure celule, înregistrarea pentru fiecare ciclu electric de depolarizare și repolarizare este cunoscută sub numele de potențial de acțiune, acesta apărând la fiecare depolarizare și are rolul de a încuraja celulele vecine să depolarizeze la rândul lor și să genereze propriile potențiale până în punctul în care întregul sistem a fost depolarizat. Din punct de vedere al nivelelor atinse, sarcina electrică a unui potențial negativ poate să atingă o valoare minimă chiar de -60 mV, care totuși durează o perioadă nesemnificativă de timp care se petrece preț de o clipă, după care crește treptat până ajunge la un prag la care se produce depolarizarea. Rata sau viteza lor de lucru poate varia enorm în funcție de factori precum activitatea sistemului nervos și solicitările prin care trece organismul la un moment dat, dar care scade în cele mai multe din cazuri pe perioada somnului [23].

Al doilea tip de celule sunt cele de conductoare electrice care prezintă proprietatea de a fi acele celule care au lungimea și lățimea cea mai mare, având rol foarte important în transport al curentului rapid și eficient între regiuni care se află la o anumită distanță în cadrul inimii. Celulele conducătoare electrice de la nivelul ventriculelor compun căi electrice distincte, sistemul format de acestea având denumirea de sistem Purkinje. Căile de conducere la nivelul atriilor au de asemenea un rol extraordinar de important prin faptul că printre acestea se numără fibrele din partea superioară a septului intra-atrial din regiunea care poartă numele de fascicul Bachmann prin care se permite activarea rapidă a atriului din partea stângă [23].

Al treilea tip de celule ale inimii sunt reprezentate de celulele miocardice care reprezintă și cea mai mare parte a țesutului inimii, fiind componenta care se ocupă cu procesul de contracție și de relaxare al inimii, aceste celule având o lungime cuprinsă între 50 - 100 de micrometrii și care conțin foarte multe proteine reprezentate în principiu de miozină și actină. Aceste celule pot să funcționeze similar cu cele de conducere, dar într-un mod mai inferior astfel, viteza de transmitere a unei depolarizări o să fie mult mai mică în cadrul întregului sistem [23].

2.3 Electrocardiograma și frecvența cardiacă

Bătăile inimii sunt controlate de un sistem electric complex care coordonează contracția camerelor sale. Nodul sinoatrial (SA), situat în atriul drept, acționează ca stimulator cardiac natural al inimii prin generarea de impulsuri electrice regulate care stabilesc ritmul inimii. În acest proces, se oferă foarte multe informații despre starea inimii la momentul în care se produce procesul de contracție, astfel avem prezent un semnal electric care poate ajunge la multe locații de la suprafața stratului de epidermă al ființelor umane. Astfel, se produce un proces în care s-a descoperit prezența electricității la acest nivel, lucru care a fost exploatat de oameni prin faptul că aceste potențiale electrice au fost înregistrate folosind mecanisme precum electrozii și diferite dispozitive de interpretare a semnalului, a momentelor și modelelor activității electrice cum sunt reprezentate prin intermediul electrocardiografei (ECG). Aceasta evidențiază și prezintă

informații valoroase despre starea inimii, întrucât diferitele anomalii care pot să apară la sistemul de conducere ale semnalului electric pot duce la diferite probleme de sănătate, probleme care pot să afecteze capacitatea și puterea inimii de a trimite sângele în întregul corp în mod eficient. Acest semnal înregistrează o valoare a numărului de variații egal cu 12 derivații, fiind obținute folosind 10 electrozi, iar din toate derivațiile, este selectată la final doar una, în funcție de afecțiunea medicală care trebuie să fie diagnosticată [25].

Din punct de vedere al clasificării celor 12 derivații, acestea pot să fie grupate conform sursei [25], în 12 clase de diagnosticări care în mod cert și punctual acoperă ambele cazuri care pot să fie clasificate drept normale și de cele care prezintă apariția anumitor anomalii comune, după cum urmează: 1-sindrom coronarian acut, 2-VT/IVR/WCT, 3-asistole, SA arrest, 4-CAD, 5-AVB, 6-tulburări de conducere intraventriculară, 7-APC/VPC, 8-AF/AFI, 9-SVT, 10-alte afecțiuni, 11-ritm ritmat, 12-condiție normală, unde TV vine de la tahicardie ventriculară, IVR reprezintă ritm indioventricular, WCT reprezintă tahicardie largă complexă, SA reprezintă stop sinoatrial, CAD reprezintă probleme la artera coronară, AVB reprezintă blocaj atrioventricular, APC reprezintă complex atrial prematur, AF reprezintă fibrilația atrială sau SVT care este reprezentată prin tahicardie supraventriculară [25].

Într-un ECG, electrozii sunt plăcuțele conductoare atașate la suprafața corpului, așa cum se poate observa din Figura 3, detectează diferența de potențial electric dintre două puncte de atașare. Aceste derivații sunt clasificate în șase derivații toracice și șase derivații pentru membre, inclusiv derivații precordiale sau toracice, derivații pentru membre augmentate și derivații pentru membre. Sondările toracice captează potențialul cardiac pe orizontală, în timp ce derivațiile membrelor captează potențialul în plan frontal. Prin utilizarea mai multor derivații, ECG oferă o evaluare cuprinzătoare a activității electrice a inimii din diferite unghiuri, permițând profesioniștilor din domeniul sănătății să diagnosticheze cu acuratețe o gamă largă de afecțiuni cardiace. Sistemul complex de derivații ECG asigură o evaluare detaliată și amănunțită a funcției electrice a inimii, ajutând la detectarea și monitorizarea diferitelor afecțiuni cardiace [26].




Figura 3. Electrocardiograma cu cele 6 derivații toracice [26]

Frecvența cardiacă sau pulsul reprezintă frecvența bătăilor sau a contracțiilor pe care le prestează inima pe durata unui minut, acestea se măsoară în bătăi pe minut (bpm). Parametrii la care operează inima depind foarte mult de ritmul cardiac, acesta variind în funcție de nevoile fizice al organismului uman, cum ar fi procesul de respirație care se bazează pe activitatea de absorbție a oxigenului și de eliminare al dioxidului de carbon (CO₂). Pe de altă parte, ritmul cardiac mai putând să fie influențat de parametrii sau factori ca cei care țin de genetică sau starea fizică a corpului, stresul de zi cu zi, factori de natură psihologică, factori legați de alimentația pe care o au oamenii, medicamentele care sunt consumate pe anumite perioade, starea hormonală și de secreție a acestora de către corp sau de bolile de orice natură pe care le putem avea, dar în mod normal are o valoare constantă cu parametrii care se află între valorile în repaus de aproximativ 60-100 de bătăi pe minut. În cazul persoanelor care practică sport de performanță,

această valoare poate ajunge chiar și la 40 de bătăi pe minut. În cazul în care se monitorizează valori anormale, poartă numele de bradicardie care prezintă o frecvență cardiacă foarte scăzută, fiind definită ca având valori de sub 60 de bătăi pe minut în starea de repaus, iar în cealaltă extremă, tahicardia, este definită ca având o frecvență cardiacă de peste 100 de bătăi pe minut în stare de repaus. În timpul somnului, pentru oameni, frecvența cardiacă are o frecvență de aproximativ 45 de bătăi pe minut, iar în cazul în care inima nu se încadrează în aceste valori, adică anomalii generate din diferite motive care fac inima să nu bată conform acestui model, se atribuie denumirea de aritmie [19] [21] [22]. Variabilitatea ritmului cardiac (HRV) se referă la monitorizarea precisă și continuă a modificărilor specifice de variabilitate sau ale timpului dintre bătăile sau contracțiile succesive ale inimii, astfel în cadrul acestui proces de identificare, timpul dintre două contracții ale inimii este măsurat în milisecunde (ms) și poartă denumirea de interval între bătăi (IBI), iar prin acest parametru se remarcă faptul că există diferențe foarte mari între cele două noțiuni, chiar dacă acestea seamănă între ele din punct de vedere morfologic. Contracțiile au funcții diferite și anume: ritmul cardiac se focusează pe contracțiile medii în intervale medii pe minut, iar variabilitatea ritmului cardiac se ocupă cu măsurarea modificărilor specifice de timpul dintre contracțiile succesive ale inimii. Din punctul de vedere al valorilor pe care le poate înregistra variabilitatea ritmului cardiac, se remarcă că o valoare ridicată este de preferat în mod general, iar prezența unor valori scăzute, poate indica o variabilitate mai mică a contracțiilor inimii, care poate să indice numeroase fapte ca faptul că organismul trece prin momente stresante sau psihologice sau diferiți factori de stres intern sau extern. Pe de altă parte, la o valoare mai mare, corpul are capacitatea mai solidă de a tolera stresul sau de asemenea are potențialul de a se recupera rapid după evenimentele solicitante, acest sistem reprezentând calcule matematice care dacă sunt aplicate corect sistemul nervos autonom poate să fie monitorizat cu precizie. Acesta este legat de toate procesele automate din organismul uman și prezintă două componente principale care sunt responsabile de controlul stresului și al mecanismelor de recuperare ale corpului uman, de asemenea este responsabil de lucruri ca reglarea zahărului din organism, a temperaturii corporale, dar și al digestiei [31]. Variabilitatea ritmului cardiac poate să fie asociată cu ritmul cardiac (HR), astfel variabilitatea ritmului cardiac poate să ofere informații despre ritmul cardiac și de modul în care acesta variază. Una dintre problemele care apar este reprezentată de cele două ritmuri care prezintă un rol mai principal în ceea ce privește valoarea clinică a variabilității ritmului cardiac sau mai mult, asocierea dintre acestea fiind atât un fenomen fiziologic cât și unul matematic. Pe partea fiziologică, dependența este determinată de procesele și mecanismele care țin de activitatea sistemului nervos, iar pe partea matematică este dependentă de relația neliniară dintre intervalele RR și HR, astfel putând să fie contribuția HR la valoarea clinică a HRV, care reprezintă un lucru de o foarte mare importanță prin prisma faptului că dacă abordăm tema eliminării impactului HR asupra HRV se poate concluziona că HRV se face mai predictiv pentru decesele provocate de afecțiunile necardiace. Chiar și așa, cu toate aceste aspecte menționate, creșterea acestui impact provoacă HRV să fie o cale mai eficientă în vederea predicției mortalității cardiovasculare, prin acest mod HR trebuie să fie luat în considerare când se monitorizează și se compară măsurătorile la anumiți pacienți [Ann Noninvasive Electrocardiol 2014;19(3):207–216] [18].

2.4 Undele P, Q, R, S, T și intervalele acestora

Electrocardiograma (ECG) este un instrument de diagnostic elementar și crucial folosit pentru a evalua funcțiile electrice și musculare ale inimii în vederea identificării unor anomalii care pot să apară și de a le putea remedia din timp în așa fel încât acestea să nu pună viața celor monitorizați în pericol. Așadar, electrocardiograma captează activitatea electrică a inimii pe o perioadă de timp, generând o formă de undă cu modele distincte, dar totuși care se repetă la un interval foarte scurt de timp și care reprezintă diferite faze ale ciclului cardiac. Aceste modele sunt cunoscute ca undele P, Q, R, S și T, fiecare literă corespunzând unui punct de referință

specific pe semnalul ECG și care prezintă o anumită semnificație specifică. Aceste puncte fiduciale sunt esențiale pentru analiza funcției inimii și diagnosticarea diferitelor afecțiuni cardiace. Astfel, în cadrul sau contextul semnalelor de electrocardiogramă, punctele fiduciale reprezintă și oferă caracteristici extraordinar de precise care sunt identificate în cadrul formei de undă și care se poate preciza, la un nivel foarte elementar, că aceste puncte reprezintă prin alocarea lor un rol de puncte de referință sau un mijloc de marcare a unor zone mai reprezentative din semnalul pe care îl avem de prelucrat. Aceste identificări sau mai bine precizat, aceste puncte și claritatea amplasării acestora, sunt cruciale în vederea analizării și interpretării corecte a activității și funcționalității electrice și morfologice a inimii. De asemenea, aceste puncte au rolul de a ajuta la identificarea și delimitarea diferitelor faze ale ciclului cardiac și sunt utilizate în diverse aplicații și metode de diagnosticare, monitorizare, chiar și în domeniul de cercetare, toate acestea având un rol foarte important în cadrul domeniului medicinei moderne. Punctele selectate drept puncte de referință sunt reprezentate de unda P, unde se remarcă elemente ca debut, vârf sau decalaj, complexul QRS, dar și prezența undei T, în cadrul semnalului. Mai mult, sunt luate în considerare și diferite intervale care se regăsesc în cadrul semnalului și care reprezintă distanțele dintre anumite puncte identificate cu scopul de a marca diferiți parametri cu dorința de a le monitoriza valorile exacte pentru a putea identifica posibilitatea apariției diverselor probleme de sănătate. Din punct de vedere al identificării propriu zise, procesul a fost explicat în paginile anterioare când a fost dezvoltat subiectul celor 12 derivații, identificarea lor pe baza electrozilor și și a celor șase puncte toracice de unde se poate face monitorizarea. După ce au fost menționate aceste aspecte, se poate observa în Figura 4 reprezentarea formelor de undă, dar și poziționarea acestora în cadrul inimii. Mai exact, în ce stadiu se află inima în cadrul ciclului cardiac în momentul în care aceste unde sunt monitorizate de către dispozitivele moderne de identificare a semnalului de electrocardiogramă pentru o evidențiere mai potrivită a subiectului. În continuare, urmează să fie dezvoltat mai bine subiectul în diverse arii mai particulare prin prezentarea în mod mai exact a fiecărei unde sau al fiecărui interval reprezentativ.




Figura 4. Reprezentarea punctelor P-Q-R-S-T în cadrul ciclului cardiac [32]

2.5 Caracterizarea undelor semnalului ECG

2.5.1 Unda P

Această undă reprezintă unda de început a semnalului ECG care prezintă și înregistrează procesul de depolarizare atrială. Aceasta este o undă care înregistrează valori mici, dar care prezintă doar valori pozitive, valorile mici fiind datorate faptului că depolarizarea atrială are loc la nivelul atriilor care au o masă musculară mică, în cazul în care este prezent un ritm sinus, înregistrarea este pozitivă.

mai precis în condiții normale. Unda P este orientată în jos și la stânga în plan frontal fiind o undă întotdeauna pozitivă în derivația a doua care se remarcă printr-o înclinare. Această undă prezintă o înclinație spre planul frontal cu aproximativ 60 de grade, folosindu-se de acest aspect, vectorul atrial care este localizat în acest plan frontal, o să fie întotdeauna îndreptat spre derivația a doua, astfel unda fiind mereu pozitivă. În Figura 5.a este prezentată unda P pozitivă. Dacă ne aflăm în cadrul derivației V1, care se remarcă prin faptul că unda P este curbată în plan orizontal, dar este în primă fază orientată înainte urmând ca aceasta să revină la stânga în vederea activării atriului stâng, cum este prezentat în Figura 5.b. Astfel, rezultă că avem o undă P bifazică sau difazică, ceea ce înseamnă că în cea mai mare măsură unda P este pozitivă, dar spre finalul undei se înregistrează și valori ușor negative. Uneori această tendință poate să fie descoperită, de menționat fiind faptul că mărimea atriului stâng și drept provoacă modificări destul de majore în cadrul derivațiilor discutate. De exemplu, mărimea atriului drept este una dintre cauze, pentru că se dezvoltă o rezistență puternică în ceea ce privește funcționarea ventriculului drept, mărimea atriului ducând la mărirea curenților electrice și astfel la creșterea influenței pe care o are atriul drept asupra valorii undei P. Acest lucru este valabil și în cazul atriului stâng, care prin parametrii săi de funcționare, poate influența adâncimea undei P în cadrul derivației V1. Caracteristicile derivației V1 pot să fie observate și monitorizate și în cazul derivațiilor V2 punând în comparație cu V5 care se ocupă de detectarea unei depolarizări care se deplasează într-o manieră mai mult sau mai puțin spre aceasta, astfel rezultând o undă P pozitivă, cum este ilustrat în Figura 5.c [33]. Din punct de vedere al caracteristicilor generale, unda P se remarcă prin faptul că are o deformare negativă mai mică decât un milimetru, durata undei este mai mică decât 0,12 secunde, iar amplitudinea unei trebuie să fie mai mică ca 2,5 milimetrii [33].




Figura 5. Unda P cu derivațiile (a.) II, (b.) V1 și (c.) V5 [34]

2.5.2 Unda Q

Unda Q reprezintă prima deviație care va avea întotdeauna valori negative și se poziționează după unda P, dar înainte de unda R, în cadrul semnalului de electrocardiogramă, așa cum este ilustrat în Figura 4. Aceasta reprezintă etapa de după depolarizarea atrială și anume, începutul depolarizării ventriculare care este formată din complexul de unde Q, R și S. Unda Q prezintă valori mici care sunt observabile în derivațiile laterale precum derivația V5 sau V6. În acest mod, unda Q indică o depolarizare normală a septului ventricular, care are loc într-o direcție de la stânga la dreapta. De asemenea, două unde Q mici pot să fie observate în cadrul derivațiilor V5-V6, în timp ce în cazul derivației III este prezentă o singură undă Q izolată. Din punct de vedere patologic, o problemă semnificativă este reprezentată de infarctul miocardic, care poate cauza undele Q patologice, lucru care mai poartă denumirea de infarct cu unde Q și poate fi reprezentat de o lărgire a undei Q mai mare de 40 de milisecunde sau de o adâncime mai mare a semnalului de 2 mm [33]. Din perspectiva caracteristicilor undei, se pot remarca următoarele: avem o durată mai mică de 40 de milisecunde sau 0.04 secunde, cu o amplitudine mai mică cu până la 25 de procente față de unda R. Unda Q poate să fie observată în Figura 6 [33].




Figura 6. Reprezentarea undei Q [34]

2.5.3 Unda R

Unda R este prima și singura undă pozitivă din complexul QRS, aceasta reprezintă partea cea mai importantă a depolarizării ventriculare. Această undă reprezintă și partea principală a acestui proces, monitorizând în cea mai mare parte depolarizarea miocardului ventricular. Miocardul ventricular este un moment cheie în cadrul sistemului circulator și al ciclului cardiac, deoarece în acest moment, ventriculele se contractă și acest proces duce la pomparea și trimiterea sângelui din inimă în restul corpului. Din punct de vedere al clasificării undelor, din complexul QRS, toate undele pozitive sunt unde R. Dacă apar două sau trei unde pozitive în același grup, cazuri rare, cele două unde care apar în plus vor purta denumirea de unda R-prim respectiv unda R-bis, pe lângă prima undă care își va păstra numele. Din punct de vedere al caracteristicilor undei R, se remarcă amplitudinea undei care dacă prezintă valori mari, totul se poate datora fie măririi sau a hipertrofiei ventriculare. Pentru V5 și V6, este recomandată o valoare mai mică de 26 milimetrii, pentru unda R se recomandă o valoare mai mică de 12 milimetrii sau în cazul derivațiilor I, II sau III, se recomandă o valoare mai mică de 20 milimetrii, iar în cazul V1, o valoare mai mică de 5 milimetrii în condițiile în care unda S este mai mare ca R. Din punct de vedere al duratei temporale, pentru unda R se recomandă ca aceasta să dureze sub 35 de milisecunde pentru ventriculul drept și sub 45 de milisecunde pentru ventriculul stâng la anumite derivații. Această undă este și cea mai ușor de recunoscut și poate să fie măsurată între unda Q până la vârful undei R, așa cum se poate observa în Figura 7 [33].



Figura 7. Unda R [35]

2.5.4 Unda S

Unda S este prima undă negativă care apare imediat după unda R și reprezintă ultimul pas al depolarizării ventriculare. Astfel, această undă reprezintă depolarizarea finală a ventriculelor, mai ales al părților superioare ale acestora de lângă baza inimii la plecarea sângelui în corp. Din punct de vedere al caracteristicilor undei, aceasta prezintă o amplitudine mai pronunțată pentru derivații ca V1, V2 sau V3 și valori mai mici pentru derivațiile V4 până la V6. Pe de altă parte, din punct de vedere al undelor patologice, dacă avem o undă prea adâncă la derivațiile V5 sau V6, poate să apară o hipertrofie ventriculară stângă, pe când la o undă absentă pentru derivațiile V1 sau V2, poate indica o hipertrofie ventriculară dreaptă sau chiar în cazurile mai nefericite un infarct miocardic posterior. Unda S este o undă foarte ușor de identificat, aceasta plasându-se imediat după unda R, dar înainte de unda T, așa cum este evidențiat și în Figura 8 [33].



Figura 8. Unda S [36]

2.5.5 Unda T

Din punct de vedere al undei T, aceasta reprezintă secțiunea din semnalul ECG care este responsabilă de repolarizarea ventriculelor. Unda T este împărțită în două părți diferite, separate de vârful acesteia. Prima parte este cunoscută sub denumirea de perioadă refractară absolută, iar a doua jumătate, care se regăsește după vârful undei T, este denumită sub numele de perioadă refractară relativă sau perioadă vulnerabilă. Din parametrii care pot fi folosiți pentru monitorizarea undei T, putem aminti de amplitudinea acesteia, panta membrelor de descendență și ascendență, asimetrie sau simetria acesteia. Din punct de vedere al poziționării undei T în raport cu valoarea zero, se poate spune faptul că în majoritatea cazurilor unda T este o undă pozitivă și reprezintă zona de repolarizare a ventriculelor după ce acestea au fost depolarizate la finalul complexului QRS. Repolarizarea se manifestă printr-un proces de sens opus față de cel de depolarizare, deși acest flux este unul negativ, efectul acestuia este opus, iar semnalul ECG îl înregistrează ca și o undă pozitivă care este unda T. Totuși, un lucru care este destul de important de menționat este că unda T poate să aibă valori negative pentru cazul VR, de exemplu, pentru V1 se poate obține un T negativ, dar pentru alte cazuri ca derivația a treia, acest lucru ar fi un aspect nefiresc, această undă având un rol important în identificarea a multor probleme de sănătate ca și infarctul miocardic [38].



Figura 9. Unda T [36]

2.5.6 Intervalul RR

Intervalul RR este acel interval definit între două unde R, mai exact, începe într-un vârf R și se termină într-un vârf R și este utilizat pentru a delimita două complexe QRS unul de celălalt. Acesta este un interval important, deoarece mulți parametrii care vor fi prezentați în această lucrare, de exemplu: deviația standard pentru RR sau RD, RMSSD sau HR depind de acest interval.




Figura 10. Intervalul RR [37]

2.5.7 Intervalul PR

Intervalul PR este acel interval care începe la începutul undei P când caracteristica începe să urce din valoarea zero spre vârful undei P și se încheie imediat înainte de complexul QRS. Lungimea acestui interval este foarte importantă în definirea unor aspecte care țin cont de sănătatea oamenilor și are două praguri cuprinse între valorile de 0,12 secunde, prag inferior, și 0,22 secunde, prag superior. La oamenii mai tineri, pragul poate fi chiar de 0,20 secunde, pragul

superior. Depășirea pragului superior este echivalentă cu un prim grad de blocaj AV, iar situarea sub pragul minim, indică o preexcitare care poate să fie asociată cu unda Delta.




Figura 11. Intervalul PR [39]

2.6 Caracteristicile Apneei

Termenul de apnee explicat în mod medical și foarte general, stabilit printr-o idee simplă și scurtă, este un termen care se referă la suspendarea procesului de respirație pe un interval de timp variat. În cadrul acesteia, nivelul de aer din cadrul plămânilor nu se mai schimbă, astfel rezultând un volum constant, acest lucru se petrece din cauză că nu mai are loc nici o activitate la nivelul mușchilor respiratorii sau o activitate foarte asimetrică a acestora. Mai concret, se remarcă o reducere a fluxului de aer care intră în plămâni de cel puțin nouăzeci de procente din valoarea normală a plămânilor pe durate măsurate de la cel puțin zece secunde în sus. Acest eveniment de reducere a debitului de aer se petrece pentru cel puțin nouăzeci la sută din perioada totală a evenimentului monitorizat, iar din punct de vedere al evenimentelor pe oră, un număr de cel puțin cinci evenimente pe oră poate identifica prezența de apnee ușoară sau mai severă, dacă se înregistrează un număr de evenimente mai mare de cincisprezece sau chiar treizeci de evenimente pe oră. Pe durate mici, apneea nu pune viața oamenilor în pericol, deoarece aceasta nu influențează procesul de respirație celulară dacă durează doar pe intervale scurte de timp, dar dacă aceasta se realizează pe durate mai mari, aici deja discutăm de intervale de timp de cel puțin trei minute de stare continuă. Prin urmare, situația se poate modifica drastic, deoarece lipsa substanțelor obținute din procesul de respirație, precum este oxigenul, poate duce la multe complicații, inclusiv la nivel cerebral, ca accidentul vascular cerebral sau probleme precum hipertensiune arterială, tulburări ale memorie, stare de oboseală continuă, lipsa de energie și de somn calitativ, de atenție sau de productivitate [40] [41] [42].

2.6.1 Clasificarea tipurilor de Apnee

Din punct de vedere al clasificării acestei afecțiuni, se remarcă apariția a trei tipuri de cazuri în care se pot enumera cele prezente în Figura 12, precum: apneea obstructivă în somn (OSA), care este și cel mai comun caz de apnee marcată de prezența unui efort respirator resimțit pe toată perioada evenimentului, apneea centrală în somn (CSA), marcată de o absență a efortului respirator pe durata evenimentului și apneea mixtă (MSA), care este o combinație a primelor două cazuri și se manifestă în mod special față de primele două cazuri printr-o absență la începutul evenimentului a efortului respirator urmată de o creștere a acestuia în a doua parte al acestui eveniment, iar din acest motiv, acest caz este mixt. Se mai poate menționa apneea complexă în somn (CompSa), care poate să apară din CSA, deci nu este un tip separat cum sunt primele trei, dar este o evoluție nedorită a CSA și care este cunoscută din nefericire ca fiind emergentă la tratament [40] [41] [42].




Figura 12. Clasificarea tipurilor de Apnee [39]

OSA se caracterizează prin tulburarea respirației în timpul somnului și este reprezentată de evenimente de obstrucție a căilor aeriene superioare, problemă care poate să fie la nivel parțial sau chiar complet și care poate să ducă la efectele prezentate mai concret și precis în paragraful anterior. Această problemă afectează în jur de 10% din populația planetei, fiind mult mai întâlnită la persoanele care suferă de obezitate sau prezintă o masă corporală mai bogată. În raportul dintre genuri, această afecțiune afectează mai mulți bărbați decât femei, raportul fiind de 4% la 2% în rândul persoanelor de vârstă mijlocie. Din punct de vedere al comparației episoadelor care pot să fie întâlnite în OSA, în termeni de specialitate, episoadele de apnee sunt caracterizate de încetarea aproape completă sau completă a respirație, pe când episoadele de respirație parțială sunt considerate episoade de hipoapnee, ambele cazuri afectând în mod grav concentrația de oxigen care se regăsește în organismul uman. În ceea ce privește definirea evenimentelor, cel de apnee a fost definit mai sus, iar din perspectiva celui de hipoapnee este reprezentat de evenimente cu durată mai mare de 10 secunde pentru o scădere a evenimentelor respiratorii cu cel puțin 30% și pentru o desaturare a oxigenului din sângele pacienților cu cel puțin 3-4 % din valoarea normală. Indiciile de apnee în somn pentru OSA sau hipoapnee index (AHI), evaluează severitatea OSA, iar acest indice se referă în mod direct la numărul de evenimente de apnee și hipoapnee care sunt monitorizate pe perioada somnului. Severitatea sau prezența afecțiunii este raportată în următorul mod: pentru $AHI < 5$ este intervalul normal, pentru $5 < AHI < 15$ avem o prezență a afecțiunii ușoară, pentru $15 < AHI < 30$ avem un sindrom de apnee moderat, iar pentru $AHI > 30$ avem deja de a face cu un sindrom sever [40] [41] [42] [43].

CSA se caracterizează prin faptul că respirația fie este diminuată sau chiar absentă, iar pacienții caracterizați cu această problemă experimentează mai ales evenimente centrale. Acest tip de apnee este caracterizată de imposibilitatea sistemului nervos de a furniza impulsuri adecvate sistemului respirator din cauza instabilității sistemului respirator. Fenomenul de respirație Cheyne-Stokes este acestui tip de apnee și este reprezentată de respirația periodică în care avem secvențe recurente de apnee care prin natura lor, alternează cu secvențe de respirație rapidă, aceste episoade apărând pe perioada timpului de somn, dar chiar și în repaus. În cazul evenimentelor mixte, acestea prezintă atât evenimente obstructive, dar și centrale, fiind considerate drept sindrom complex care pot duce la diferite disfuncții cardiovasculare sau chiar la moarte. Din acest motiv, partea de detecție joacă un rol major, dar, de asemenea dintr-un context în care avem evenimente mixte, se poate schimba încadrarea la OSA sau CSA dacă unul dintre evenimente este dominant [44].

Semnalul ECG a fost utilizat pentru detectarea ambelor sindroame de apnee, OSA și CSA, avantajele pentru care această variantă poate să fie utilizată sunt reprezentate de diferite modificări de natură fiziologică cum ar fi cele date de ritmul cardiac (HR). În acest caz, există o creștere vizibilă a ritmului în cazul de apnee și poate reflecta inclusiv modificări ale sistemului nervos simpatic care este în stare activă pe perioada apneei influențând astfel parametrii ritmului cardiac, variabilitatea ritmului cardiac (HRV), exprimat în domeniul timp prin parametri precum SDNN sau RMSSD.

De asemenea, un indicator important al semnalului ECG în identificarea diagnosticului de Apnee este dată de modificări ale punctelor sau intervalelor de referință ale semnalului ECG (unda P, unda T și complexul de unde QRS) fiind utilizate pentru a putea obține punctele de referințe sau pentru a detecta valori ale formelor de undă. Exemple pot fi susținute de modificări ale segmentului ST care pot să fie evidențiate de hipoxie sau probleme de natură miocardică. De

asemenea, modificările complexului QRS, în care au fost evidențiate mai ales modificările de amplitudine sau durată a intervalelor RR, unde aceste intervale au tendința de a fi mai lungi în cazul semnalelor cu apnee din cauza scăderii ritmului cardiac. La finalul evenimentului de apnee se întâmplă un fenomen exact opus, iar din perspectiva a ceea ce afectează, aceste intervale RR pot să fie prezente procese ca impedanța toracică sau efortul produs în timpul procesului de respirație care pot fi observate prin modificarea amplitudinii și a frecvenței componentelor respiratorii. De menționat fiind faptul că parametrii ca HR, HRV sau intervalele reprezentate și modificările acestora sunt atribuiți analizei în domeniul timp, spre exemplu SDNN sau RMSSD pentru HRV, pe când cele din domeniul frecvenței sunt reprezentate de componentele legate de procesul de respirație. În general, pe baza bibliografiei menționate în lucrare, majoritatea analizelor experimentate pe semnalul ECG au indicat o precizie ridicată de clasificare raportată de până la 96%, deși toate analizele pot prezenta rezultate foarte diversificate din cauza unicității pe care o au semnalele ECG. În Figura 13 se poate observa un exemplu în care se evidențiază un caz normal și unul afectat de Apnee din care se poate remarca din grafic abnormalitatea semnalului și în consecință modificări ale valorii parametrilor menționați mai sus [45].




Figura 13. Exemplu de semnal ECG Normal și de semnal ECG cu Apnee [45]

2.7 Zgomotul prezent în semnalul ECG

Diferențele de potențial electric dintre electrozii așezați pe corp în punctele prezentate în Figura 3 din această lucrare sunt utilizați cu scopul de a recepționa semnalul ECG. Astfel, prin acest mod, se pot obține diferite informații despre impulsul inimii și originea acestuia, despre propagarea impulsului sau chiar despre diferite efecte pe care le au factorii externi și de alimentație asupra inimii. Un alt scop este pentru a estima detalii biologice legate de inimă, precum sunt cele de localizare și mărime ale camerelor inimii, dar și de variațiile impulsurilor electrice pe care le are inima. De asemenea, prin identificarea anumitor probleme, ca de exemplu, zgomotul care poate să influențeze în mod negativ procesele de monitorizare și de interpretare a acestui semnal prin degradarea lui, ducând la afectarea acurateții acestuia. Principalele surse de zgomot sunt reprezentate de deviația de bază, interferența în linia de alimentare sau artefacte de contracție musculară sau de mișcare [46] [47].

Deviația de bază reprezintă un zgomot care prezintă frecvențe joase și este datorat din cauza procesului de respirație, de modificări ale impedanței pe care o au electrozii. Acest zgomot poate avea ca și consecință schimbarea liniei de bază a semnalului ECG, iar în acest mod, detectarea unor segmente importante din semnal poate să devină dificilă, spre exemplu, detectarea segmentului ST. Această linie de bază se petrece într-un interval de frecvențe de aproximativ 0,15 Hz până la 0,3 Hz [47].

Interferența în linia de alimentare este un zgomot care poate să apară la frecvența liniei de alimentare, situată undeva la 50 Hz - 60 Hz și armonicile pe care le are. Acest zgomot este unul de bandă îngustă, iar această problemă are ca și cauză o cuplare de natură inductivă și capacitivă între liniile de alimentare și echipamentele de monitorizare a semnalului. Astfel, poate să apară o interferență pe linia de alimentare care are ca și efect mascarea intervalului de semnal ECG și

care poate să ducă la situația nefericită că vârful R să nu mai fie detectat corect și astfel semnalul ECG să prezinte detectări false pozitive sau negative [48].

Artefactele de contracție musculară au ca și cauză activitatea electrică a mușchilor scheletului uman, mai ales în situații solicitante precum sunt cele de stres sau activitate fizică foarte intensă. Astfel, din aceste procese rezultă un spectru foarte larg de frecvențe și astfel pot să fie confundate cu formele de undă normale ale semnalului ECG brut printr-o detectare eronată a componentelor semnalului înregistrat [49].

Artefactele de mișcare au ca și principală cauză modificările de impedanță electrod-piele care se datorează din cauze normale, mai exact din mișcări fine sau subtile ale corpului uman în timpul monitorizării. În acest mod, se pot produce modificări ale liniei de bază, iar prin acest lucru se induc modificări de amplitudine ale vârfurilor din semnalul ECG. Aceste efecte sunt mult mai pronunțate pe perioade lungi de monitorizare și detectare ale apneei pe perioada somnului, iar în acest mod, procesul devine mai deficitar [50].

După caracterizarea anterioară a acestor tipuri de zgomot, putem continua cu identificarea unor metode de atenuare a acestor efecte, unde se remarcă folosirea unor tehnici de filtrare în cadrul etapei de preprocesare a algoritmului care este responsabil de detecție a cazurilor care prezintă probleme din cadrul semnalului ECG. Prin acest mod, deplasarea liniei de bază este eliminată cu ajutorul filtrului trece sus care este folosit la o frecvență de 0,5 Hz. Interferența la linia de alimentare poate să fie eliminată folosind filtre reglate la frecvența liniei de alimentare. Artefactele musculare pot să fie eliminate sau reduse folosind filtre adaptive. Artefactele de mișcare pot să fie reduse sau eliminate folosind algoritmi bazați pe detectarea complexului QRS și a unor metode de filtrare adaptivă. Din procesul de eliminare sau reducere în mod eficientizat al acestor probleme legate de zgomot, calitatea semnalelor ECG utilizate în identificarea afecțiunilor va permite extragerea mai precisă a diferitor caracteristici legate de evenimentele de apnee pentru o detectare precisă și fiabilă [47] [48] [49] [50].

2.8 Filtrarea semnalului ECG

Așa cum se poate observa și mai sus, în cadru procesul de identificare a unei afecțiuni, pot să apară multe probleme de natură variată, majoritatea fiind cauzate de apariția unui tip de zgomot pe perioada monitorizării și înregistrării datelor. În consecință, trebuie să se găsească soluții pentru a evita aceste probleme și pentru a monitoriza și înregistra corect datele asupra căreia se concentrează procesarea semnalului. Astfel, putem susține că filtrarea este o etapă crucială în rezolvarea acestor probleme în etapa de preprocesare a detecției din semnalul ECG. Prin urmare, filtrarea se va ocupa de eliminarea zgomotului și a artefactelor ale semnalului, dar în același timp, semnalul trebuie să fie capabil să rețină informațiile relevante pentru a detecta apneea. În cadrul semnalului ECG, se folosesc mai multe tipuri de filtre pentru a detecta corect anomaliiile din semnal, spre exemplu filtrele trece-jos elimină zgomotul de înaltă frecvență și artefactele semnalului, astfel se elimină acea deplasare a liniei de bază și a interferenței asupra liniei de alimentare menționate și anterior. Filtrele trece-sus sunt utilizate pentru eliminarea deviației de linie de bază și desigur a altor componente de joasă frecvență. Filtrele trece-bandă sunt folosite pentru a determina doar un anumit domeniu de frecvențe și de a le elimina pe celelalte din afara intervalului, în acest context ele pot să fie folosite pentru a izola anumite componente specifice ale semnalului ECG, spre exemplu anumite unde sau vârfuri. Filtrele Notch pot să fie folosite pentru a elimina diferite tipuri de frecvențe, cum ar fi frecvența linie de alimentare și a armonicilor acestora, iar filtrele Wavelet care se pot folosi la descompunerea wavelet pentru a reuși să elimine zgomotul și artefactele semnalului ECG. Din perspectiva construcției acestor filtre, trebuie să fie îndeplinite mai multe condiții și trebuie parcurse mai multe etape, spre exemplu trebuie să fie analizată frecvența și determinarea componentelor de frecvențe care trebuie să fie modificate. De asemenea, alți factori ca specificațiile filtrului, aici ne referim la parametrii ca frecvența de tăiere sau chiar ondularea benzii de trecere, sunt

determinate pe baza acestei analize ale frecvențelor avute. Mai mult, tipul de filtru, analogic sau digital, poate juca un rol important. Din perspectiva filtrării adaptive, parametrii utilizați în cadrul filtrului sunt ajustați dinamic pe baza atributelor semnalului ECG analizat, înregistrând rezultate bune de detecție cu o eficiență medie de aproximativ 90%. Astfel, filtrarea reprezintă un pas esențial pentru procesarea corectă a semnalului ECG în vederea identificării apneei, iar alegerea tipului de filtrare depinde de semnalul pe care îl avem pentru a reuși să eliminăm zgomotul, astfel fiind îmbunătățită calitatea semnalului ECG, iar detectarea va fi mult mai precisă după filtrare.

2.9 Algoritmul Pan-Tompkins

Complexul QRS este un grup de unde care reprezintă activitatea electrică principală a inimii, mai precis, a ventriculelor inimii care au rolul de a pompa sângele în corp, fiind cea mai reprezentativă componentă a semnalului ECG. De asemenea, poate să fie interpretat în vederea identificării mai multor probleme de sănătate, deci acest complex este de o importanță foarte mare și în concluzie trebuie ales un algoritm de detectare a punctelor QRS în vederea detectării parametrilor urmăriți. Astfel, a fost ales pentru această lucrare algoritmul Pan-Tompkins, fiind considerat ca și o modalitate de bază în vederea identificării punctelor urmărite, de asemenea acest algoritm poartă denumire celor care l-au și inventat, anume Willis Tompkins și James Pan în anul 1985. Algoritmul funcționează prin izolarea complexului QRS de restul undelor prin folosirea a două filtre, unul trece jos și unul trece sus, care acționează similar cu un filtru trece bandă. Mai departe, urmează etapele de diferențiere, ridicare la pătrat, cea de integrare și de thresholding în vederea identificării punctelor Q, R și S. Prin urmare, ca identificările să se facă conform cu caracteristicile fiecărui semnal ECG în parte, acest algoritm este recomandat, deoarece a fost utilizat în multe aplicații clinice cum ar fi identificarea ritmului cardiac și a variabilității acestuia sau la identificarea anumitor tipuri de probleme care duc la modificarea distanțelor și a amplitudinilor undelor analizate. Așadar, de-a lungul timpului, Pan-Tompkins a devenit cunoscut ca fiind unul dintre cele mai precise metode valabile pentru a detecta punctele din complexul menționat și, de asemenea, are cea mai mică eroare comparativ cu alți algoritmi cum ar fi Hamilton-Tompkins. Prin urmare, a fost ales pentru această lucrare pentru avantajele pe care poate să le ofere. Acest algoritm oferă o serie de etape care trebuie să fie parcurse pentru a atinge etapa finală de recunoaștere corectă a tuturor punctelor urmărite, iar în continuare o să fie parcurse fiecare în parte pentru o detaliere mai profundă [51] [52].

2.9.1 Filtru trece bandă

Acest filtru este folosit pentru a atenua sau chiar a elimina zgomotul cu deviația liniei de bază din semnalul ECG în formă brută, pentru a obține o bandă de trecere de aproximativ 5-15 Hz. Semnalul ECG re ceptionat și nemodificat o să treacă printr-un filtru trece-jos care are o frecvență de tăiere de 11 Hz, având rolul de a anula interferența produsă de la sursa de alimentare, respectiv un filtru trece-sus cu o frecvență de tăiere de 5 Hz. În acest mod, se obține caracteristica de filtru trece-bană, simulat prin folosirea celorlalte două filtre, astfel obținându-se pragurile necesare filtrării [51] [52].

Ecuția pentru filtrul trece-jos:

$$y(nT) = 2y(nT - T) - y(nT - 2T) + x(nT) - 2x(nT - 6T) + x(nT - 12T) \quad (1)$$

Ecuția pentru filtrul trece-sus:

$$y(nT) = 32x(nT - 16T) - y(nT - T) - x(nT) + x(nT - 32T) \quad (2)$$

2.9.2 Filtru derivativ

Acest filtru este utilizat pentru a se oferi informații despre panta semnalului format din punctele identificate, mai în detaliu, rolul acestui filtru este de a suprima componentele de frecvențe joase [51] [52]. Acest filtru are următoarea ecuație:

$$y(nT) = (1/8T)[-x(nT-2T) - 2x(nT-T) + 2x(nT+T) + x(nT+2T)] \quad (3)$$

2.9.3 Ridicarea la pătrat

Acest proces de ridicare la pătrat se folosește pentru a putea intensifica panta semnalului și are ca efect o amplificare și evidențiere a componentelor de frecvență mare. Astfel, se limitează posibilitatea ca undele T să fie considerate unde R pentru a se realiza o eroare în semnal. Această ridicare la putere ajută la limitarea de cazuri fals pozitive. Un alt efect al acestei amplificări este dat de faptul că toate punctele din semnal vor deveni pozitive [51] [52]. În acest caz se aplică următoarea ecuație:

$$y(nT) = [x(nT)]^2 \quad (4)$$

2.9.4 Integrarea cu ferestre mobile

Un asemenea filtru este folosit pentru netezirea caracteristicii semnalului, pentru a obține informații despre pantă, despre punctele majore ale semnalului și despre forma de undă a acestuia. Astfel, cu ajutorul acestui pas, se obțin caracteristici suplimentare despre semnal față de ce au oferit pașii anteriori. Prin acest mod, sunt evitate anumite chestiuni de natură patologică care în general sunt definite de valori mari pe ambele axe de monitorizare ale semnalului ECG. Un exemplu potrivit de fereastră de integrare de $0,15 \cdot \text{frecvența de eșantionare}$ fiind folosită pentru rezultate optime [51] [52]. Acest pas are ca și mod de definire următoarea ecuație:

$$y(nT) = (1/N) [x(nT-(N-1)T) + x(nT-(N-2)T) + \dots + x(nT)] \quad (5)$$

În această ecuație, N este numărul de monstre din lățimea ferestrei de integrare. Vârfurile locale care ies ca și rezultat din acest proces sunt marcate pentru a găsi complexul QRS, iar lungimea pantei fiind direct proporțională cu lățimea complexului de vârfuri care a fost detectat. Prin urmare, acest lucru aducând de la sine un grad de detecție foarte bun.

Din perspectiva caracteristicilor utilizate, pentru a extrage parametrii din semnalul ECG cu scopul identificării de anomalii prezente în semnal care să ducă la identificarea de apnee, în cele care urmează, o să fie cuprinși anumiți parametrii care pot să ajute în îndeplinirea scopului lucrării. Din rândul caracteristicilor statice, se pot considera caracteristica de medie a intervalelor RR, abaterea standard pentru intervalele RR sau implementarea de parametrii ca media diferențialelor inter-beat, rădăcină medie pătratică a diferențialelor inter-beat, coeficienții de corelație serială sau NEP care vine de la numărul de puncte extreme. Din perspectiva caracteristicilor în domeniul timp, putem să amintim lungimile dintre diferite puncte care definesc anumite intervale, ca spre exemplu, RR, PR sau ST. Astfel, putând să fie monitorizate caracteristicile de accelerare și încetinire ale vitezei cu care inima lucrează. Din punct de vedere al amplitudinii semnalului ECG, se pot măsura și analiza valoarea amplitudinii punctelor detectate în cadrul algoritmului de detecție precum sunt punctele R, P sau T, caracteristici bazate pe frecvență, spre exemplu spectrul de putere și valoarea acesteia, chiar și ritmul cardiac. Aceste aspecte oferind informații precise despre starea semnalului [53].

3 Implementarea soluției adoptate

3.1 Descrierea lucrării

În cadrul acestei secțiuni a lucrării o să fie prezentat și exemplificat un algoritm de detecție a problemelor de sănătate legate de sindromul de apnee care, prin propria sa definiție, necesită descoperirea unor soluții și metode de monitorizare de la distanță. Această afecțiune necesită monitorizare pe întreaga perioadă a somnului pentru a obține rezultate relevante și pentru a asigura un mediu natural cu care pacientul este acomodat. De asemenea, pentru a putea obține rezultate bune, trebuie să se țină cont de faptul că condițiile pentru un somn de calitate trebuie să fie la cel mai înalt standard posibil raportat la condițiile la care a avut acces pacientul pe toată durata vieții sale, fără a fi necesar un proces de internare într-un spital pentru a se face aceste cercetări care pot să fie incomode și neeficiente pentru toate părțile implicate în proces.

Din perspectiva scopului pe care îl are lucrarea de față, s-au realizat mai multe etape precum, segmentarea, prelucrarea și clasificarea mai multor semnale ECG preluate dintr-o bază de date. Semnalele utilizate au avut o durată de o oră din care s-au extras secțiuni de câte 10 secunde pentru a fi analizate și clasificate în două categorii care sunt reprezentate de semnale normale și de cele care prezintă sindromul de apnee. Astfel, această afecțiune este prezentă în mod exclusiv și unic în cadrul semnalelor care după executarea algoritmului sunt clasificate ca fiind drept anormale. În cadrul acestui proiect, s-a utilizat pentru procesul de procesare a semnalelor ECG, programul software MATLAB, mai exact versiunea R2023a care a prezentat toate utilitățile necesare pentru realizarea acestui proiect în care principalul obiectiv este reprezentat de detectarea punctelor P-Q-R-S-T cu scopul de a putea calcula diferiți parametrii pe baza lor. În total, vor fi analizați pentru stabilirea diagnosticului fiecărui semnal, 13 parametrii, din care va fi stabilit un prag de câți parametrii trebuie să fie obligatoriu pentru a returna fie un rezultat normal sau fie unul cu afecțiunea menționată. Din punct de vedere al datelor folosite, în cadrul acestui proiect, a fost folosită platforma web PhysioNet, de unde au fost obținute datele de la un anumit număr de persoane la care au fost determinate caracteristicile semnalului și pe care s-au obținut concluziile necesare.

3.2 Descrierea mediului de lucru MATLAB R2023a

Denumirea vine de la MATrix LABoratory, acesta este un limbaj de programare clasificat de nivel mediu și chiar înalt, acesta prezintă un mediu cu foarte multe capacități utilizat în principal pentru procesele de calcul numeric, analiză a datelor și a semnalelor, pentru dezvoltarea de diferite interfețe sau aplicații și pentru expunerea datelor în diferite moduri. În zilele noastre, MATLAB este folosit în foarte multe domenii diferite pe scară largă din care merită să amintim de arii ca cea industrială, de inginerie, știință, pe partea de cercetare inclusiv în mediile academice, dar și în domenii ca cel financiar unde se realizează multe predicții și simulări în funcție de diverse surse de date, iar acest mediu putând fi folosit de la calcule de o complexitate redusă și până la realizarea de simulări foarte complexe și diversificate [54][55].

Printre principalele caracteristici cheie ale acestui limbaj se pot enumera următoarele: capacitatea de lucru pe matrice, foarte utilă pentru lucrul cu calcule matematice care conțin diverși vectori sau structuri matriciale, accesul la toolbox-uri, în cadrul acestora se oferă diferite funcții cu rolul de la prelucrări de semnale și până la învățarea automată, de asemenea aici se regăsesc și diferite biblioteci predefinite care au rolul de a simplifica sarcinile de natură complexă. Din perspectiva de vizualizare, se remarcă prin capacități extinse de a reprezenta date la nivel grafic și pentru a oferi o reprezentare la modul cel mai eficient posibil, aspecte care vor fi dezvoltate și în următoarea parte a lucrării. Un alt aspect relevant legat de acest mediu este

prezența Simulink, care ne poate oferi un mediu grafic pentru a putea simula diferite configurații, fiind folosit mai ales simularea semnalelor, respectiv procesarea, acestora [54][55].

Din punct de vedere al versiunii utilizate, MATLAB R2023a este prima versiune lansată în anul 2023 din cele două existente, făcând parte din ciclul obișnuit de 2 versiuni în fiecare an lansate pentru acest mediu de lucru. Din perspectiva îmbunătățirilor oferite față de versiunile anterioare, putem enumera: performanță îmbunătățită, instrumente și funcționalități noi prin facilitarea proceselor de import, vizualizare și analiză a datelor, introducerea de funcții și actualizări în ceea ce privește funcționarea Live Editor prin oferirea de sugestii de modificări îmbunătățite sau un proces de depanare mai eficient, precum și îmbunătățiri aduse la platforma Simulink, dar și la introducerea de noi funcții AI și de Machine Learning, oferind capacități de utilizare a algoritmilor de deep learning sau de formulare și creare a unor modele predefinite. Alte aspecte ce mai pot să fie menționate sunt reprezentate de diferite actualizări minime ale aspectului aplicației, interoperabilitatea prin îmbunătățirea conectivității cu alte limbaje populare de programare [54][55].




Figura 14. Mediul MATLAB R2023a

3.3 Descrierea bazei de date - PhysioNet

Selecția subiecților și alegerea segmentelor de semnal analizate pentru fiecare caz pentru care a fost creat algoritmul din lucrarea de față a fost făcută de pe platforma PhysioNet, platformă care oferă informații referitor la datele fiziologice care țin evidența a mai multor persoane suspecte de anumite afecțiuni și care au fost monitorizate pe o perioadă de timp variată, în funcție de afecțiunea pentru care se dorea să se realizeze înregistrarea datele biomedicale pentru a se putea identifica problemele posibile. Această platformă este foarte utilă pentru implementarea sau crearea de aplicații cu rol de a monitoriza afecțiuni severe, ca și cea expusă în cadrul acestei lucrări și pentru a realiza o eficientizare a algoritmilor. Astfel, algoritmiile pot să fie aplicați direct pe semnalele din PhysioNet, iar pasul costisitor atât financiar, cât și de timp pentru monitorizarea și colectarea de semnale ECG de la pacienți sau de la persoanele suspecte de vreo anomalie, poate să fie evitat prin utilizarea datelor din această platformă [56].

Din perspectiva subiecților aleși de mine, baza de date din cadrul PhysioNet (<https://archive.physionet.org/cgi-bin/atm/ATM>) [56] are forma ilustrată în Figura 15 unde se poate observa cum sunt structurate datele și organizarea platformei. În cazul de apnee, baza de date este structurată în modul următor, semnalele au o perioadă egală cu perioada de somn pe care o are fiecare subiect, așa că lungimea totală a unui semnal de la un pacient este aproximată undeva la 8 ore, exact cât este perioada de somn normală pentru o persoană. În total sunt înregistrate semnalele de la 30 de persoane numerotate de la a01-a20, b01-b05, respectiv c01-c05, din care au fost alese spre testare 5 dintre ele. Prin urmare, au fost selectați subiecții a01, a07, a013, a14 și a19, de la care s-au preluat semnalele ECG selectate cu lungimea de o oră fiecare, în formatul de timp de secunde. Din punct de vedere al formatului de fișiere disponibile pentru a lucra cu baza de date PhysioNet, aceasta oferă datele structurate în fișiere de tipul .mat,

.csv sau chiar text, astfel asigurându-se o diversitate destul de bună a modului de structurare al datelor. În cadrul acestei lucrări s-au folosit fișiere de tipul .csv, care au fost convertite din fișierele .mat folosind un algoritm în MATLAB pentru a reuși să se efectueze conversia într-un mod cât mai simplu și mai precis posibil. S-a ales această abordare, deoarece platforma nu oferă fișiere .csv în formate de timp mari, cum au fost cele folosite în lucrarea de față [56].




Figura 15. Platforma PhysioNet – PhysioBank ATM

În total, de la cei 5 pacienți au fost extrase 50 de eşantioane de semnale ECG cu care s-a testat algoritmul propus. Au fost descărcate cele 5 semnale într-un format de o oră din cele 8 pe care este definită întreaga înregistrare, mai precis, tot ciclul de somn al fiecărui subiect, pentru a putea fi observată caracteristica semnalului persoanei respective și cum evoluează starea de somn de la valori normale, la cele cu apnee pe parcursul unei singure ore. Mai departe, folosind adnotările din PhysioNet, s-au extras pentru fiecare semnal de o oră câte 10 secvențe de semnal de durată de 10 secunde. Din cele 10 secvențe de semnal extrase din semnalul cu lungimea de o oră, conform adnotărilor menționate anterior, 5 eşantioane vor aparține clasei normale, în timp ce celelalte 5 eşantioane vor fi din zona cu apnee. Astfel, în total o să fie prelucrate și analizate caracteristici pentru 50 de eşantioane de la 5 persoane, din care 25 semnale sunt clasificate de către adnotările bazei de date ca fiind normale și alte 25 de semnale care sunt clasificate ca fiind cu apnee. În general, s-a constatat că în cazul de apariție a apneei, valorile amplitudinilor cresc pentru toate componentele, dar această variație nu este întotdeauna valabilă, deoarece unele amplitudini vor avea tendința de a își păstra valorile aproape nemodificate. Prin urmare, în acest caz existând o șansă destul de mică, dar nu imposibilă, ca detecția să nu se facă corect.

Tabelul 2. Semnalele extrase și clasificate conform adnotărilor din PhysioNet

Denumire Clasă	TOTAL
Număr subiecți utilizați	5
Număr total de secvențe analizate	50
Număr secvențe normale	25
Număr secvențe cu prezența apneei	25

3.4 Descrierea algoritmului de clasificare

În cazul de față s-a utilizat un algoritm de clasificare a semnalelor în funcție de tipul acestora, dacă acestea sunt în cazul normal sau în cel cu apnee. Pentru a face această clasificare, s-au folosit mai mulți parametri și s-a urmărit obținerea unei rate de succes de cel puțin 80% pentru a putea asigura că acest algoritm este unul relevant. Astfel, pentru a se realiza acest lucru,

algoritmul depinde de rezultatul furnizat de către fiecare parametru, dacă acesta este sau nu este peste un anumit prag calculat unic pentru toate testările de față, iar dacă se identifică că valoarea acelui parametru va depăși pragul stabilit se va alege ca acel parametru se situează în zona cu apnee, deoarece în zona cu apnee valoarea anumitor parametrii crește în timp ce altele rămân la fel. Astfel, se creează o discrepanță între valorile individuale ale unui singur parametru, dar odată mediate valorile sale pentru a se putea obține o valoare relevantă testelor de față se va obține o valoare mai mare ca în cazul normal și astfel efectul o să fie evident. În mod inițial se încarcă semnalul de o oră în MATLAB după care se extrage un semnal de 10 secunde din acesta care trebuie să înceapă cu o undă P și să se termine cu o undă T pentru a respecta structura definitorie a semnalului ECG. Algoritmul din această lucrare extrage parametrii exclusiv din structura semnalului prelucrat, iar în acest mod se vor parcurge următoarele etape: folosirea algoritmului Pan-Tompkins pentru detectarea vârfurilor pentru undele Q, R și S, iar pe baza unor praguri stabilite față de unda R se vor detecta valorile și pentru celelalte două unde, respectiv P și T. În acest context, cu toate undele detectate corect, se pot obține pe baza lor și nu numai, diferiți parametrii pentru a putea analiza și împărți cazurile normale de cele anormale care prezintă sindromul de apnee. Așadar, după detectarea conform pragului unic pentru fiecare parametru, se vor evidenția două clase de parametrii, cei care au valori sub prag, parametrii care fac parte din clasa normală și cei care au valoarea peste prag și prin urmare vor face parte din clasa apneei. În total, în cadrul acestei lucrări, au fost evaluați 13 parametrii diferiți pentru a putea realiza la final un diagnostic cât mai precis posibil. S-au ales mai mulți parametrii de testat, deoarece caracteristica semnalului cu apnee nu este întotdeauna cea mai constantă, deoarece nu toate undele din complexul PQRST respectă condiția de apnee. În această situație, cea mai bună metodă a fost aleasă de a crește numărul de parametrii testați, astfel s-a ajuns la 13, care în urma testării au dat rezultate foarte bune. În prima parte a algoritmului, după ce au fost identificate undele P, Q, R, S și T, care au servit ca suport important și esențial în vederea identificării celor 13 parametrii și stabilirii pragului pentru fiecare parametru în parte, se va furniza un rezultat binar, 0 în cazul normal, respectiv 1 dacă parametrul trece peste acel prag stabilit, iar aici se sfârșește prima parte a algoritmului. Mai departe, vine a doua parte a algoritmului unde pe baza primei părți sunt adunate pentru un semnal toate cazurile din cadrul celor 13 parametrii care returnează o valoare mai mare decât pragul acestora, prin urmare cazul de apnee sau cazul care este numerotat cu 1, se face suma lor și în funcție de câte cazuri de 1 au fost pentru un semnal se va obține un număr cuprins între 0 și 13 care va reflecta numărul de cazuri mai puțin bune de cele bune. Mai departe se va pune un prag pentru a delimita cazurile de semnale normale de cazurile de semnale cu apnee care, normal și evident, o să fie mai mică ca jumătate din valoarea tuturor parametrilor pentru a putea furniza un rezultat cât mai corect posibil și pentru ca algoritmul să prezinte o acuratețe cât mai mare pentru a putea să fie considerat relevant în cadrul acestui domeniu în care a fost realizat.

În cadrul figurii următoare, se poate observa o diagramă care prezintă etapele realizate pentru implementarea algoritmului de detecție a apneei.




Figura 16. Etapele realizate pentru algoritmul de clasificare

3.5 Încărcarea datelor și realizarea algoritmului Pan-Tompkins

Înainte de aplicarea algoritmului, baza de date trebuie să fie încărcată în MATLAB. După conversia semnalului ECG din format .mat în format .csv, folosind funcția `importfile()` s-au încărcat fișierele .csv din baza de date pentru a putea fi analizate. Semnalele încărcate au lungimea de o oră și s-au ales două limite pentru a analiza semnale în intervale de 10 secunde. De asemenea, pentru o analiză cât mai eficientă a semnalului trebuie eliminată componenta continuă, iar semnalul ar urma să fie amplificat cu un factor egal cu 100, amplificare necesară deoarece amplitudinea inițială a semnalului este foarte mică, aproximativ de mărimea milivoltului. De asemenea, tot în acest pas, au fost definite și cele două limite pentru intervalul de 10 secunde, definite de variabilele `min_time` și `max_time`, unde se introduc valorile de la tastatură și `start_index` și `end_index` pentru axa timpului în secunde în vederea delimitării corecte a intervalului de 10 secunde care urmează a fi analizat. Din perspectiva afișării semnalului inițial, acesta se poate observa în Figura 17, așa cum a fost afișat mai jos.

```
[time,signal] = importfile('a01s.csv');  
  
%Pas 0 Eliminarea componentei continue  
signal= signal-mean(signal);  
signal= signal.*100;  
  
% Slectare intervale afisare  
min_time = input('Valuare minimă în secunde: ');  
max_time = input('Valuare maximă în secunde: ');  
  
% interval in secunde,min si max  
start_index = find(time >= min_time, 1);  
end_index = find(time <= max_time, 1, 'last');  
  
% Afisare semnal ECG Original  
figure,  
subplot(4,1,1);  
plot(time(start_index:end_index), signal(start_index:end_index));  
xlabel('Timp (s)');  
ylabel('Amplitudine (mV)');  
title('Semnal ECG Original');  
grid on;
```




Figura 17. Afișarea eșantionului de 10 secunde a semnalului ECG brut din PhysioNet

3.5.1 Algoritmul Pan-Tompkins

Algoritmul Pan-Tompkins este o metodă recunoscută la nivel înalt și foarte eficientă, se folosește pentru detectarea complexului QRS, mai precis vârfurile acestora din cadrul semnalului ECG, ulterior putând fi identificați și alți parametri. Alți parametri care pot fi identificați sunt reprezentați de exemple ca celelalte vârfuri din semnal, adică P și T, dar și de anumite intervale care au fost detectate chiar în lucrarea de față, ca intervalele RR, QRS sau PR, dar și posibilitatea de identificare a unor parametri precum este ritmul cardiac care poate să fie dedus din numărul de unde R din cadrul semnalului ECG analizat. Acest algoritm este esențial pentru monitorizarea stării de sănătate a pacienților, totodată este un algoritm eficient pentru gestionarea zgomotului din semnalele ECG deoarece, din păcate, semnalele preluate direct din bazele de date, care au fost doar monitorizate și neprelucrate în cadrul procesului, prezintă elemente de natură spectrală inutile analizei de față și care au un efect negativ asupra capacității de redare a semnalului și a proprietăților acestuia prin prezența zgomotului și al interferențelor. Dar, aplicând acest algoritm, se pot remedia problemele menționate anterior deoarece algoritmul din această lucrare excelează prin proprietățile sale de a oferi o filtrare digitală și un prag adaptiv, acești pași vor fi explicați în

cele ce urmează, astfel etapele algoritmului sunt următoarele: aplicarea unui filtru trece bandă, reprezentat în lucrare sub forma a două filtre consecutive trece sus și trece jos, după care urmează un pas de diferențiere care are rolul de a determina informația despre pantă, după care se execută o ridicare la pătrat pentru a se putea asigura că toate vârfurile vor înregistra valori pozitive, iar în final se aplică partea de integrare care este evidențiată prin integrarea ferestrei de mișcare pentru a obține o caracteristică mai clară și mai evidentă a complexului QRS. În final se va folosi o limitare determinată printr-un prag cu rolul de a delimita sau a obține vârfurile R față de celelalte vârfuri din semnalul analizat și procesat de către această aplicație, în continuare vor fi explicați mai în detaliu acești pași:

3.5.2 Filtru trece bandă

În cadrul acestui pas, scopul este dat de obiectivul de eliminare sau filtrare a componentelor nedorite din cadrul semnalului, spre exemplu, componente ca zgomotul de înaltă frecvență care dacă nu este eliminat poate să ducă la detecție eronată a complexului QRS. Filtrul Trece-Sus (FTS) aplicat semnalului ECG este folosit pentru a elimina diverse zgomote de frecvențe joase care pot să apară în semnal, ca de exemplu deviația liniei de bază care este un zgomot de joasă frecvență cauzat de mișcările pacientului. Acest filtru se realizează folosind un filtru Butterworth cu o frecvență de tăiere de 2 Hz. Filtrul Trece-Jos (FTJ) prezintă o frecvență de tăiere egală cu 40 Hz, contrar primului filtru, acesta este folosit pentru a elimina zgomotul de înaltă frecvență care poate proveni din interferența electrică. Ca și în cazul FTS, se folosește un filtru Butterworth care atenuează frecvențele prea mari asigurând astfel vizibilitatea vârfurilor din complexul QRS.

În continuare, se va aplica un proces de normalizare a semnalului prin care se execută împărțirea întregului semnal la valoarea absolută maximă, ceea ce duce la delimitarea intervalului de amplitudini la o valoare cuprinsă între -1 și 1, ajutând mai departe la procesul de stabilire a pragurilor pentru detectarea celor 5 vârfuri din cadrul semnalului ECG. O reprezentare a efectului pe care îl au acești doi pași asupra semnalului ECG original poate fi observat în Figura 19, dar și prin codul utilizat care este ilustrat în Figura 18.

```
%definire frecvente de taiere filtre
fjos=2;
fsus=40;
ord=4;

%filtrare trece sus
f1 = fdesign.highpass('n,F3dB', ord, fjos, fs);
ftss = design(f1,'butter');
s_filtrat_1 = filter(ftss,signal);

%filtrare trece jos
f2 = fdesign.lowpass('n,F3dB', ord, fsus, fs);
ftjj = design(f2, 'butter');

s_filtrat_2 = filter(ftjj,s_filtrat_1);

%Pas2 NORMALIZARE, includ semnalul între un interval mai mic si bine
%stabilit(-1->1)
numitor=max(abs(s_filtrat_2));
s_normalizat=(1/numitor)*s_filtrat_2;
```

Figura 18. Secțiune de cod MATLAB pentru filtrare și normalizare




Figura 19. Afișarea semnalului ECG după etapele de filtrare, normalizare și derivare

3.5.3 Derivarea

Etapă de derivare din cadrul semnalului ECG analizat joacă un rol important deoarece, această etapă calculează prima derivată a semnalului, această derivată se evidențiază informațiile despre panta semnalului analizat. Această etapă se aplică pentru a evidenția caracteristici ale semnalului, de exemplu marginea ascendentă și descendentă a complexului QRS. Derivarea calculează diferența dintre valorile succesive ale semnalului. Pe de altă parte, procesul de derivare reduce influența variațiilor lente din semnal, spre exemplu deviația liniei de bază. În concluzie, această caracteristică contribuie la eliminarea unor artefacte și variații lente, care nu sunt relevante pentru detectarea complexului QRS.

3.5.4 Ridicarea la pătrat – Squaring

Ridicarea la pătrat a semnalului diferențial este utilizată atât pentru a amplifica caracteristicile semnalului, dar și pentru a obține doar valori pozitive ale semnalului. În acest caz, diferențele dintre caracteristicile semnalului cresc, cele mai mari fiind mult mai accentuate decât cele mai mici, iar în acest mod, această etapă este în mod crucial importantă, deoarece oferă valori doar pe un singur spectru de semn și are rolul de a evidenția mult mai bine unele din complexul QRS față de celelalte unde prezente în semnal. Deoarece această etapă amplifică valorile mari și micșorează valorile mici, semnalele cu amplitudini mici (cum ar fi zgomotul) devin mai puțin evidențiate. Astfel, această etapă contribuie la filtrarea zgomotului de joasă amplitudine din semnal. Aspectele acestei etape pot fi vizualizate în Figura 21.

3.5.5 Integrarea folosind ferestre mobile

Acest pas este definit pentru a se reuși atât considerarea caracteristicii de pantă, cât și a celei de lățime a semnalului ceea ce are ca efect o detectare mai precisă a complexului QRS. În cadrul proiectului de față, această integrare are rolul în ceea ce privește netezirea semnalului, dar cu păstrarea anumitor informații despre semnal ca cele legate de amplitudinii și durate. Impactul acestui pas fiind reprezentat de reducerea zgomotului și a altor caracteristici nerelevante, pregătind astfel semnalele pentru ultima etapă a algoritmului, adică cea responsabilă de stabilirea unui prag pentru a determina anumite informații despre unda R. Ultima etapă din acest algoritm se va realiza prin stabilirea unui prag pentru detectarea de vârfuri a semnalului integrat care să corespundă cu proprietățile complexului QRS, mai specific avem o setare sub formă de procent, unde 0,01 reprezintă 1% din valoarea maximă a semnalului integrat după care este folosit acest prag pentru a se realiza comparații cu semnalul integrat și dacă acest prag este depășit atunci există o șansă foarte bună ca în acea zonă să fie prezent un complex QRS. Din cele scrise mai sus, este evident că acest pas este unul crucial, deoarece ne separă zonele din semnal unde avem QRS de cele unde nu este prezent acest complex. În continuare, poate să fie vizualizat codul utilizat pentru această secțiune în Figura 20, dar și semnalele corespunzătoare din Figura 21.

```
%PAS 4 Ridicare la pătrat
% Squaring
% o sa am caracteristici pozitive si se vor evedentia mai bine semnalele
semnal_squ = sem_dif_fin .^ 2;

%PAS 5 Integrare
integreare_f = round(0.150 * fs);
filterrrr=ones(1,integreare_f)/integreare_f;
s_integrat= conv(semnal_squ,filterrrr, 'same');

%PAS 6 Initalizarea de praguri -> Thresholding
thr=0.01 * max(s_integrat);
s_date = s_integrat > thr;
```

Figura 20. Secțiune de cod MATLAB pentru etapa de squaring, integrare și limitare




Figura 21. Afișarea semnalului ECG conform celor 3 etape

3.6 Determinarea parametrilor

3.6.1 Unda R

Unda R este cea mai proeminentă undă dintre toate cele analizate. Aceasta este localizată în perioada de depolarizare ventriculară și este esențială în procesul de detectare a foarte multe probleme de sănătate. Secțiunea de cod din Figura 22 detectează unda R, iar această detecție a fost realizată printr-o scanare a semnalului, care a rezultat în descoperirea valorii maxime dintr-o fereastră definită în cadrul semnalului ECG. Așadar, această structură are rolul de a asigura detecția unei singure unde R printr-o singură fereastră alocată unui interval unic. Folosirea acestor ferestre este de a evita detectarea multiplă sau eronată în cadrul unui singur interval. Caracteristica care asigură detectarea corectă este dată de perioada de refractare, aceasta este implementată prin *per_r* și calculează lungimea ferestrei în care este calculată unda R, fiind setată la 0,25 din frecvența de eșantionare f_s . Prin urmare, în acest mod, se asigură o detectare pe un interval egal cu un sfert din perioada frecvenței de eșantionare. Parametrul *fer_r* reprezintă fereastra de refractare, aceasta este un vector, având o mărime egală cu dimensiunea perioadei de refractare. Acest parametru este inițial inițializat cu 0. În acest fel, dacă cerințele de detectare a unei nu sunt respectate, fereastra se va muta cu o poziție spre dreapta, iar acest proces se tot repetă până când toate eșantioanele semnalului ECG au fost parcurse și s-a obținut un răspuns final. În cadrul programului, variabilele *r_v* și *r_loc* provin de la *r_vârf*, respectiv *r_locație* și indică amplitudinea, respectiv locația unei unde R la un moment dat. Astfel, se furnizează informațiile despre locația unei R pe ambele axe de coordonate. Variabilele *r_vs* și *r_locs* au rolul de a stoca toate valorile pentru amplitudine, dar și locația undelor R într-o ordine cronologică. Cei doi vectori vor avea valorile asociate pentru amplitudine și timp pentru a se putea determina caracteristica unei unde R pe ambele axe de coordonate analizate. Această clasificare se va dovedi foarte utilă în inițializarea valorilor *r_loc_specific*, respectiv *r_amp_specific*, care vor desemna doar valorile unei R pe un interval de 10 secunde specificat de utilizator din linia de comandă, iar aceste două valori vor reprezenta practic două secțiuni din cadrul *r_vs* și *r_locs*. Prin urmare, se poate observa mai bine în Figura 22 algoritmul implementat pentru detectarea unei R.

```

%Detectare R
%per_r perioada de refractară - folosit pentru determinarea lungimii
%ferestrei, evită punctele fals pozitive și asigură că unda R este
%detectată într-o fereastră
%fer_r fereastră refractară - asigură detectarea unei singure unde R la un
%moment dat
per_r = round(0.25 * fs);
fer_r = zeros(1, per_r);
r_vs = zeros(size(s_date)); % va stoca amplitudinile undelor R
r_locs = []; %va stoca locațiile undelor R
%se produce o iterare peste fiecare probă a senalului s_date
for i = 1:length(s_date) - per_r
    %verifică dacă valoare curentă e zero și că nici o undă R anterioară nu
    %este în fereastra curentă
    if s_date(i) && all(fer_r == 0)
        %detectare amplitudine și locație unda R
        [r_v, r_loc] = max(s_normalizat(i:i + per_r));
        r_vs(i + r_loc - 1) = r_v;
        r_locs = [r_locs i + r_loc - 1];
        fer_r = ones(1, per_r);
    else
        fer_r = [0 fer_r(1:end - 1)];
    % dacă condiția nu este adevărată atunci fereastra se mută cu o poziție
    % spre dreapta
    end
end

```

Figura 22. Codul utilizat pentru detecția undei R

3.6.2 Unda Q

Pentru detecția undei Q se va utiliza un cod modificat față de cel folosit pentru unda R. Această metodă se va folosi de poziția vârfurilor R care vor fi folosite drept referință, iar în acest caz, algoritmul implementat va căuta cel mai mic punct din perspectiva amplitudinii care se află exact înainte de unda R. Astfel, se va aplica principiul undei R și anume, dimensiunea ferestrei trebuie să fie identificată în funcție de frecvența de eșantionare. Din punct de vedere al organizării, valorile undelor Q vor fi salvate în variabila *q_locs*, iar pentru intervalul de 10 secunde analizat, salvarea se va face în variabila *q_loc_specific*. Acest algoritm lucrează în același mod ca la unda R, iar codul utilizat pentru detectarea undei Q poate să fie vizualizat în Figura 23.

3.6.3 Unda S

Metoda de detecție a undei S este foarte similară cu cea a undei Q, dar diferența este că unda S o să fie căutată după unda R și nu înaintea acesteia ca în cazul undei Q. Astfel, în afară de poziționarea față de unda R, metoda este similară cu cea aplicată în cazul undei Q, iar acest aspect este confirmat și de structura codului care este afișată în Figura 23.

<pre> %UNDA Q % Q referinta_q = round(0.2 * fs); q_locs = zeros(size(r_locs)); % Se caută Q fix înainte de poziția lui R for i = 1:length(r_locs) r_loc = r_locs(i); start_cq = max(r_loc - referinta_q, 1); end_cq = r_loc - 1; [q_v, q_idx] = min(s_normalizat(start_cq:r_loc)); q_locs(i) = start_cq + q_idx - 1; end </pre>	<pre> %Unda S % referința aproape unda R(imediat după ea) referinta_s = round(0.05 * fs); s_locs = zeros(size(r_locs)); % cautare unda s după unda r for i = 1:length(r_locs) r_loc = r_locs(i); start_cs = r_loc + 1; end_cs = min(r_loc + referinta_s, length(s_normalizat)); [s_v, s_idx] = min(s_normalizat(start_cs:end_cs)); s_locs(i) = start_cs + s_idx - 1; end </pre>
--	--

Figura 23. Codul utilizat pentru detecția undei Q și a undei S

3.6.4 Unda P și Unda T

Cele două unde vor fi identificate folosind o referință față de unda R, similar cu ce a fost prezentat în cazurile anterioare. Astfel, în ambele cazuri, se caută o valoare maximă a amplitudinii, diferența fiind reprezentată de zona semnalului ECG în care se vor căuta informațiile. În acest mod, unda T este căutată în apropierea zonei unde a fost identificată unda S, fiind reprezentată de zona aflată la dreapta de unda R. Pentru unda P se urmărește o abordare similară ca la unda T, dar identificarea acestei unde se va realiza în zona aflată la stânga de unda R. Din punct de vedere al procesului de memorare al datelor, informațiile celor două unde vor fi salvate în mod identic ca la celelalte trei cazuri, adică în variabilele p_locs și t_locs . Algoritmul pentru ambele unde este redat în Figura 24. În Figura 25 este reprezentat rezultatul de detecție a celor 5 unde, care a fost realizat conform algoritmilor prezentați mai sus.

```
% UNDA P
referinta_p = round(0.13 * fs);
p_locs = zeros(size(r_locs));
p_vs = zeros(size(r_locs));

for i = 1:length(r_locs)
    r_loc = r_locs(i);

    start_cp = max(r_loc - referinta_p, 1);
    end_cp = r_loc - referinta_p;

    [p_v, p_idx] = max(s_normalizat(start_cp:end_cp));
    p_vs(i) = p_v;
    p_locs(i) = start_cp + p_idx - 1;
end

%UNDA T
referinta_t = round(0.15 * fs);
t_locs = zeros(size(r_locs));

for i = 1:length(r_locs)
    r_loc = r_locs(i);

    start_ct = r_loc + referinta_t;
    end_ct = min(r_loc + referinta_t, length(s_normalizat));

    [t_v, t_idx] = max(s_normalizat(start_ct:end_ct));
    t_locs(i) = start_ct + t_idx - 1;
end
```

Figura 24. Codul utilizat pentru detecția undei P și a undei T




Figura 25. Identificarea celor cinci unde și marcarea acestora pe semnalul ECG

3.7 Determinarea parametrilor utilizați pentru detecție

3.7.1 Determinarea amplitudinii și media acesteia pentru undele R, P și T

Toate amplitudinile undelor R, P și T sunt determinate încă din pasul anterior de detectare al undelor, unde acestea au fost identificate pe cele două axe de timp și amplitudine. Astfel, pentru a putea să obținem rezultate relevante, care să poată să fie comparate între mai multe semnale diferite și pentru a putea stabili un prag unic pentru toate semnalele testate, este nevoie de realizarea operației de mediere a tuturor undelor semnalului dintr-o anumită categorie, spre exemplu, toate undele R. Pentru a putea compara și identifica dacă aceste valori ale amplitudinii sunt în limita corectă sau nu, acest pas este unul relevant, deoarece analiza fiecărei unde R în parte a unui semnal este o operație foarte complexă, dar și nerelevantă fiindcă undele pot să varieze destul de mult chiar și într-un interval cu apnee. Astfel, există o șansă foarte mică ca toate undele dintr-un interval de 10 secunde să respecte condiția de apnee sau pe cea de semnal normal. Din acest motiv, operația de mediere și utilizarea mediei unei categorii de unde este cu

mult mai eficientă decât analiza fiecărei unde în parte la nivelul unui semnal de 10 secunde. În Figura 26 este reprezentat procesul de mediere a amplitudinilor pentru unda R, fiind identic cu cel pentru undele P și T. Din perspectiva parametrilor algoritmului prezentat, *linia_isoelectrica* a fost definită cu valoarea 0, această definire are scopul de a reflecta amplitudinea reală a undelor prelucrate, prin scăderea valorii amplitudinii undelor analizate față de zero. În acest mod, se asigură faptul că punctul la care a fost raportată amplitudinea a fost cel de 0 și nu față de o valoare care să fie peste sau sub acest punct. Codul aferent explicațiilor oferite în această secțiune se regăsește în Figura 26.

```
% DETERMINARE AMPLITUDINE MEDIE UNDA R
% calcul amplitudini unda r
r_amp_amplitudine = s_normalizat(r_loc_specific) - linia_isoelectrica;
r_amplitudine_medie = mean(r_amp_amplitudine);
disp(['AMPLITUDINEA MEDIA A UNDEI R PE INTERVALUL ALES ESTE: ', num2str(r_amplitudine_medie, '%.4f')]);
```

Figura 26. Calcularea mediei amplitudinilor undelor R

3.7.2 Determinarea intervalelor RR

Intervalele RR sunt reprezentate de distanța exactă dintre două unde R consecutive. Acest parametru este foarte folositor în aplicațiile din cadrul domeniului medicinei, deoarece ajută la determinarea a mai muți parametrii, unii chiar incluși în lucrarea de față, iar un exemplu potrivit este ritmul cardiac sau heart rate (HR). În cazurile în care parametrul RR este identificat ca fiind anormal, există șanse foarte mari ca mai mulți parametri să returneze rezultate care să identifice anumite probleme de sănătate. Intervalele RR pot să fie exprimate doar în domeniul timp și se pot identifica ca fiind cuprinse între valorile de 0,6 secunde și o secundă, aspect care a fost respectat și în această lucrare. De asemenea, precum s-a procedat și în cazurile precedente, s-a ales ca rezultatul final să fie reprezentat sub forma de medie a intervalelor RR, exact din aceleași considerente ca la cazurile precedente. Algoritmul pentru detectarea intervalelor RR și calcularea mediei acestora poate să fie vizualizat în Figura 27.

```
%Determinare Intervale RR perioadă aleasă
rr_intervale = diff(time(r_loc_specific));
intervale_rr_spec = diff(time(r_loc_specific));
disp('Intervale RR:');
disp(num2str(rr_intervale', '%.4f '));

% distanta unde rr media
r_dis_medie=mean(rr_intervale);
disp(['Distanța MEDIE A undelor RR PE INTERVALUL ALES ESTE: ', num2str(r_dis_medie, '%.4f')]);
```

Figura 27. Calcularea mediei intervalelor RR

3.7.3 Determinarea intervalelor PR

Intervalele PR, așa cum a fost definit și în partea teoretică, sunt delimitate de la începutul undei P, unde a fost fixat punctul cu valoarea amplitudinii 0, care se află exact la momentul în care valoarea undei P începe să crească. Din perspectiva punctului de sfârșit al intervalului, a fost fixat punctul de după vârful undei P, unde amplitudinea este 0, acest punct aflându-se între undele P și Q, servind în același timp ca punct de start pentru intervalele ORS. Dacă un interval PR este identificat ca fiind prea lung, se poate identifica apariția unor probleme. Intervalul PR este foarte afectat de aritmiile cardiace, iar acest aspect poate să fie legat de cel al sindromului de apnee, în contextul în care acest sindrom se poate manifesta sub forma de aritmie.

3.7.4 Determinarea intervalelor QRS

Intervalele QRS se monitorizează în cadrul semnalului ECG cu scopul de a identifica dacă acestea au depășit o anumită limită stabilită. Pentru duratele intervalelor QRS foarte lungi, sau anormal de lungi, pot să fie identificate anumite probleme la nivel de conducere ventriculară, având un impact negativ asupra sistemului circulator și implicit al parametrilor ritmul cardiac. Intervalele QRS pot să fie influențate de sindromul de apnee, acest fapt se datorează influenței pe care o are acest sindrom asupra sistemului nervos simpatic uman, astfel, rezultă modificări ale duratelor intervalelor QRS. Din perspectiva algoritmului implementat pentru intervalele QRS, primul pas este reprezentat de identificarea punctului de final al undei S. În acest caz, valoarea semnalului trebuie să ajungă la valoarea liniei izoelectrice, în punctul de amplitudine 0. Din perspectiva punctului de început al intervalului, acesta este identic cu punctul de sfârșit al intervalului PR. După detecția punctelor limită urmează detectarea intervalului QRS care o să fie salvat în vectorul *qrs_durata*. Procesul de obținere al intervalelor QRS este reprezentat prin obținerea lungimii intervalelor în număr de eșantioane, după care valoarea obținută o să fie convertită în secunde prin împărțirea rezultatului la frecvența de eșantionare a semnalului. Toate aceste aspecte sunt ilustrate în Figura 28.

```
%INTERVALU QRS
val = length(intervale_rr_spec);
s_end = zeros(1, val);
%Detectare punct final interval QRS
for i = 1:val
    start_s_idx = s_loc_specific(i);
    s_end_idx = find(s_normalizat(start_s_idx:end) >= linia_isoelectrica, 1, 'first') + start_s_idx - 1;
    s_end(i) = s_end_idx;
end
% Detectie Interval QRS
qrs_durata = zeros(1, val);
qrs_start_points = zeros(1, val);
qrs_end_points = zeros(1, val);

for i = 1:val
    qrs_start = find(s_normalizat(p_loc_specific(i):q_loc_specific(i)) <= linia_isoelectrica, 1, 'first') - 1;
    qrs_start = p_loc_specific(i) + qrs_start - 1;

    qrs_end = s_end(i);
    qrs_duration_samples = qrs_end - qrs_start + 1;
    qrs_duration_seconds = qrs_duration_samples / fs;
    qrs_durata(i) = qrs_duration_seconds;

    qrs_start_points(i) = qrs_start;
    qrs_end_points(i) = qrs_end;
end
disp('Intervale QRS:');
disp(num2str(qrs_durata, '%.4f '));
```

Figura 28. Detectarea intervalelor QRS

3.7.5 Determinarea ritmul cardiac - Heart Rate

Ritmul cardiac reprezintă una dintre cele mai eficiente modalități de clasificare a unui semnal ECG, fiind unul dintre cele mai comune teste efectuate în timp scurt pentru a vedea la un nivel general cum se simte o persoană la un moment dat. Un aspect important la acest parametru este reprezentat de faptul că prezintă praguri standardizate. Pentru toate semnalele analizate se aplică două limite bine cunoscute, deci nu este necesar un pas de detecție separat în cadrul proiectului, deoarece pragurile acestui parametru situându-se între 60 și 100 de bătăi pe minut. În caz de apnee, acesta se poate localiza sub valoarea de 60 de bătăi pe minut, fiind sub pragul minim. După cum a fost specificat și anterior, acest parametru este calculat în funcție de undele R, mai exact de numărul acestora, după care se face o conversie în minute pentru a se exprima corect parametrul pentru lungimea intervalului pe care îl avem, iar după se execută împărțirea și se obține o valoare exactă. Codul algoritmului este ilustrat în Figura 29.

```
% Detectie HR interval scurt
time_segment = time(start_index:end_index);
time_segment_min = length(time_segment) / (fs * 60);
RCs = round(length(r_loc_specific) / time_segment_min);
disp(['Heart rate interval: ', num2str(RCs), ' bpm']);
```

Figura 29. Determinarea ritmului cardiac

3.7.6 Determinarea puterii totale a semnalului ECG

Puterea totală a semnalului este determinată prin calcularea spectrului de putere al semnalului ECG. Acest parametru este relevant prin fluctuațiile care apar pe timpul somnului în cadrul intervalului de apnee, deoarece aceste fluctuații pot afecta spectrul de putere al semnalului și prin urmare, acest parametru poate să fie relevant în cadrul acestui proiect. Din perspectiva algoritmului, puterea totală reprezintă suma tuturor variabilelor de putere exprimate prin variabila *putere_ECG*. Rezultatele au fost obținute prin ridicarea amplitudinilor spectrului la puterea a doua, valori obținute din calculul FFT al semnalului, unde o secțiune din cod poate fi vizualizată în Figura 30.

```
% Spectrul de PUTERE si calculul PUTERII totale
% se aplica prima data FFT
N_s = length(s_normalizat(start_index:end_index));
f_s = (0:N_s-1) * (fs / N_s);
n_s = floor(N_s / 2);
FFT_ECG = fft(s_normalizat(start_index:end_index));

% amplitudinii spectrului
ecg_amplitudine_putere = abs(FFT_ECG/ N_s);
putere_Totala = sum(putere_ECG);
disp('Puterea totală a spectrului de putere semnal ECG:');
disp(putere_Totala);

% calcul pt. spectru de putere
putere_ECG = ecg_amplitudine_putere.^2;
```

Figura 30. Spectrul de putere și puterea totală a semnalului ECG

3.7.7 Determinarea parametrului SDNN

Termenul SDNN reprezintă Standard Deviation of Normal-to-Normal Intervals, fiind definit ca un termen important al variabilității ritmului cardiac sau HRV. Acest termen este unul relevant în ceea ce privește detectarea sindromului de apnee, prin legătura sa cu ritmul cardiac și intervalele RR. Din perspectiva codului, avem următoarea secvență de cod: $SDNN = std(intervale_rr_spec)$, unde se calculează deviația standard a intervalelor RR din cadrul semnalelor. Acest parametru reprezintă o măsură a dispersiei valorilor față de propria lor medie.

$$SDNN = \sqrt{\frac{1}{N-1} \sum_{n=1}^{N-1} (RR_n - \overline{RR})^2} \quad (6)$$

3.7.8 Determinarea parametrului RMSSD

Termenul RMSSD vine de la Root Mean Square of Successive Differences și reprezintă al doilea parametru relevant a variabilității ritmului cardiac. Acest parametru are ca principal obiectiv monitorizarea fluctuațiilor care pot să apară în cadrul ritmului cardiac și care pot să apară la diverse momente de timp, de asemenea, parametrul are rolul de a monitoriza buna activitate a sistemului nervos. Din aspectele menționate anterior, la sindromul de apnee referitor la influența sa asupra sistemului nervos, o valoare mare a RMSSD indică o variabilitate foarte mare a ritmului cardiac, ceea ce denotă o activitate mare a sistemului nervos parasimpatic, care poate să fie afectat de sindromul de apnee. Din codul $rmssd = \sqrt{\sum((rd_interval).^2)/m}$ se efectuează o ridicare la pătrat a tuturor diferențelor intervalelor RR identificate în variabila *rd_interval*. Ulterior, algoritmul calculează suma lor pentru a obține un singur rezultat final, iar în final se elimină ridicarea la pătrat pentru a obține rezultatul în unitatea potrivită și se împarte la numărul de intervale RR [57].

$$RMSSD = \sqrt{\frac{1}{N-1} \sum_{n=1}^{N-1} (RR(n+1) - RR(n))^2} \quad (7)$$

3.7.9 Determinarea deviației standard a intervalelor RR

Deviația Standard a intervalelor RR măsoară variabilitatea timpului dintre bătăile inimii. Acest parametru poate să ofere o idee despre modul în care bate inima și despre consistența cu care bate aceasta. Implementarea acestui parametru este similară cu cea a RMSSD, dar deviația standard este o măsură mai generală a variabilităților discutate anterior, ceea ce îl face mai rezistent la prezența diferitelor erori, reflectând gradul în care durata intervalelor RR este diferită față de media acestora $standard_dev_rr = \sqrt{\sum((intervale_rr_spec - mean_rr).^2) / m}$, în timp ce RMSSD este o măsură mai precisă dar și mai sensibilă decât a deviației standard. Chiar dacă seamănă, analiza ambilor parametri este utilă, deoarece ne poate indica dacă semnalul ECG are probleme cu zgomotul după prelucrare sau dacă într-adevăr este prezentă o problemă de sănătate, iar ambele semnale fiind relevante din perspectiva impactului pe care îl monitorizează asupra sistemului nervos [57].

$$RR_StDev = \sqrt{\frac{\sum(rr(i) - \mu(rr))^2}{m}} \quad (8)$$

3.7.10 Determinarea deviației standard a intervalelor RD

Acest parametru provine de la calcularea diferenței interbit între intervalele RR consecutive. RD, în contextul de față, se referă la o diferență efectuată între intervalul RR curent și cel viitor, proces care se repetă până la finalul vectorului care stochează valorile intervalelor RR. În acest mod, vectorul care conține intervalele RD o să fie cu un parametru mai mic decât cel cu intervalele RR cu un element. În ceea ce privește deviația standard RD, aceasta este mai sensibilă la anumite modificări și se poate folosi pentru a identifica modificări mai subtile în ceea ce privește funcționarea inimii și a sistemului nervos, fiind mai potrivită pentru intervale scurte pentru a arăta anumite modificări mai subtile. Modul de implementare este asemănător cu cel de la parametrul anterior.

$$RD_StDev = \sqrt{\frac{\sum(rd(i) - \mu(rd))^2}{m}} \quad (9)$$

3.7.11 Determinarea parametrului NEP – numărul de puncte extreme

Ultimul parametru analizat este NEP, care este utilizat pentru monitorizarea la nivel extrem al intervalelor RR. Acest parametru este folositor în depistarea anumitor probleme pe care le poate avea ritmul cardiac. Dacă NEP înregistrează valori mici, acest lucru reprezintă o stabilitate a ritmului cardiac crescută, dar valorile mari indică contrariul. Astfel, datorită influenței pe care o poate avea apneea asupra ritmului cardiac, conduce la diferențe între intervalele RR. Aceste diferențe sunt identificate și monitorizate de NEP, deoarece apneea induce stări de stres inimii, iar NEP este specializat mai ales în a identifica situațiile de stres cu care are de a face sistemul cardiac. Din perspectiva codului, acesta se remarcă prin compararea intervalului RR curent cu cele din jurul lui, mai precis, intervalul RR anterior și cel posterior, iar produsul dintre cele două diferențe va returna o valoare de 0 sau 1 în funcție de semnul produsului. Valoarea de 0 sau 1 este contorizată într-o variabilă sumă, după care această sumă o să fie normalizată la numărul de intervale disponibile și se va obține un NEP cuprins între 0 și 1. Codul utilizat pentru implementarea parametrului se regăsește în Figura 31 [57].

$$NEP = \frac{1}{m-1} \sum_{i=2}^{m-1} (1 - \text{unit}[(rr(i) - rr(i-1)) * (rr(i+1) - rr(i))]) \quad (10)$$

```

% NEP (Number of Extreme Points)
%unit 1 -> pozitiv, 0 -> negativ
% deci daca produsul este pozitiv unit pozitiv => unit = 1 => SUMA 1-1 = 0
% deci daca produsul este negativ unit negativ => unit = 0 => SUMA 1-0 = 1
m_NEP = length(rr_intervale);

NEP_sum = 0;
for i = 2:m_NEP-1
    if ((rr_intervale(i) - rr_intervale(i-1)) * (rr_intervale(i+1) - rr_intervale(i))) < 0
        NEP_sum = NEP_sum + 1;
    end
end

NEP = (1 / (m_NEP - 2)) * NEP_sum;
disp(['Number of Extreme Points (NEP): ', num2str(NEP)]);

```

Figura 31. Algoritmul utilizat pentru detecția parametrului NEP

3.8 Metoda de clasificare a semnalelor

După ce toate caracteristicile semnalului ECG au fost extrase, se poate trece la etapa de clasificare a rezultatelor obținute. Bazele de date analizate pot varia destul de mult între ele, din cauza formei pe care o are semnalul ECG, deoarece înregistrările pot să varieze destul de mult între două persoane. Pentru a putea reduce pe cât de mult aceste diferențe, s-a ales varianta de a crea un algoritm care, pe baza a două structuri matriciale, una care conține doar valorile normale pentru un anumit parametru, pentru toate semnalele ECG analizate, iar a doua structură care conține valorile cu apnee, această clasificare se face după adnotările oferite de PhysioNet. Sunt folosite datele de la 5 persoane, fiecare matrice va avea câte 5 rânduri, iar pe fiecare dintre aceste rânduri o să fie trecute 5 valori de la numărul de semnale normale sau cu apnee analizate pentru fiecare persoană în parte. Așadar, s-a ales această organizare în vederea unei clasificări eficiente. Acest algoritm va analiza valorile celor două structuri și va furniza un prag unic de clasificare pentru toate valorile din cadrul parametrului analizat. Algoritmul va fi aplicat pentru fiecare dintre cei 13 parametri analizați, iar rezultatul final va fi marcat de 13 praguri diferite, unul pentru fiecare parametru. Dacă valorile sunt sub prag acestea sunt normale, iar dacă sunt peste pragul stabilit pentru fiecare parametru, o să fie susceptibile de prezența de sindrom de apnee. La acest pas nu poate fi concluzionat precis acest lucru, dar informațiile obținute în această parte a algoritmului sunt esențiale pentru a doua parte, unde se va returna un răspuns cert în ceea ce privește existența unei anomalii legate de apnee sau nu. În continuare, o să fie ilustrat algoritmul folosit pentru această etapă, dar și rezultatele acestuia pentru fiecare dintre parametri. În cadrul acestui cod, *normal_values* și *apnea_values*, sunt cele două structuri matriciale, iar codul este creat pentru clasificarea undei R, unde și la ceilalți parametri s-a folosit același principiu.

```

% Combină toate valorile într-un singur vector
combined_normal_values = normal_values(:);
combined_apnea_values = apnea_values(:);

% calcul media valori normale si cu apnee
mean_combined_normal = mean(combined_normal_values);
mean_combined_apnea = mean(combined_apnea_values);

% Determinare Prag General
prag_medie = (mean_combined_normal + mean_combined_apnea) / 2;
disp(['Pragul General/unic este: ', num2str(prag_medie)]);

% Clasificare in functie de prag
disp('Clasificare vector valori normale:');
for i = 1:size(normal_values, 1)
    for j = 1:size(normal_values, 2)
        value = normal_values(i, j);
        if value > prag_medie
            disp(['Vector Normal (Persoana ', num2str(i), ', Valoare ', num2str(j), '): Apnea']);
        else
            disp(['Vector Normal (Persoana ', num2str(i), ', Valoare ', num2str(j), '): Normal']);
        end
    end
end

% Clasificare intervale cu apnee
disp('Clasificare vector valori apnee:');
for i = 1:size(apnea_values, 1)
    for j = 1:size(apnea_values, 2)
        value = apnea_values(i, j);
        if value > prag_medie
            disp(['Vector Apnea (Persoana ', num2str(i), ', Valoare ', num2str(j), '): Apnea']);
        else
            disp(['Vector Apnea (Persoana ', num2str(i), ', Valoare ', num2str(j), '): Normal']);
        end
    end
end

```

Figura 32. Algoritmul de detecție a pragului unic

Tabelul 3. Identificarea pragului unic pentru fiecare parametru

Parametru	Prag	Parametru	Prag
Amplitudine undă R	0,731	Puterea Totală	0,025
Amplitudine undă T	0,088	SDNN	0,057
Amplitudine undă P	0,037	RMSSD	0,00609
Interval RR	0,817	Deviație Standard RR	0,054
Interval QRS	0,2244	Deviație Standard RD	0,048
Interval PR	0,087	NEP	0,38632
(Ritm Cardiac	60 -100	-	-

După ce au fost determinate pragurile, se poate trece la partea a doua a algoritmului. Tot pe logica cu structuri matriciale, se va continua și la acest pas întrucât, în funcție de situația în care ne aflăm, se vor alcătui două structuri matriciale cu valori binare pentru fiecare persoană în parte, de 0 și 1. Zero este folosit dacă valoarea este normală, iar 1 dacă aceasta depășește pragul stabilit. În total, vor fi 10 structuri matriciale, câte două pentru fiecare persoană, o matrice în care sunt puse cele 5 eșantioane date ca fiind clasificate normale de adnotările PhysioNet și o altă matrice, în care vor fi puse cele care sunt identificate drept apnee de aceeași sursă. Toate cele 10 matrici vor avea câte 5 rânduri, corespunzătoare eșantioanelor testate, pentru fiecare caz în parte, și câte 13 coloane care reprezintă cei 13 parametri analizați. Acest algoritm va crea câte o sumă pe fiecare rând a parametrilor de 1, iar în acest mod vom avea, pentru fiecare semnal testat, o sumă a parametrilor care au valoarea 1. Această sumă va fi testată cu un prag ales, cu cerința ca acesta să fie sub jumătate din numărul parametrilor testați, cu scopul de a prezenta că acest algoritm are o acuratețe bună și că este suficient de strict. În cadrul acestui proiect a fost ales pragul de 5 ca fiind cel mai potrivit, asta înseamnă că dacă în urma sumei efectuate un semnal are cel puțin 5 parametri, inclusiv valoarea 5, sau mai mulți parametri până la maximum de 13, acel semnal o să fie etichetat ca semnal cu apnee, în timp ce semnalele care nu au mai mult de 4 parametri care trec peste pragul stabilit, vor primi eticheta de semnal normal. În continuare, urătoarele figuri prezintă codul pentru această parte a algoritmului, cât și matricile folosite care sunt ilustrate pentru unul dintre subiecți. Important este faptul că toate semnalele sunt clasificate în cadrul unei singure execuții a programului, iar rezultatul execuției întregului algoritm va putea fi vizualizat în următorul capitol, rezultate experimentale.

```
% Valoarea de clasificare dintre cazurile normale % stocare nume si matrici
prag = 5; data = {

% Definire matrice pentru fiecare persoana
subject_a01_normal = [
    0 0 0 1 0 0 0 0 0 1 0 0 1;
    0 1 0 0 0 0 0 0 0 1 0 0 0;
    0 0 0 1 0 0 0 0 0 1 0 0 0;
    0 0 0 1 0 0 0 0 0 1 0 0 1;
    0 0 0 1 0 0 0 0 0 1 0 0 0;
];

subject_a01_apnea = [
    0 0 1 0 0 1 0 0 1 1 1 0 0;
    0 0 1 0 1 0 0 0 0 1 0 1 1;
    0 0 0 1 0 0 0 0 1 1 1 1 1;
    0 0 1 1 0 0 0 0 1 1 1 1 0;
    0 0 1 1 0 0 1 0 1 1 1 1 1;
];

'Subject_a01_Normal', subject_a01_normal;
'Subject_a01_Apnea', subject_a01_apnea;

'Subject_a07_Normal', subject_a07_normal;
'Subject_a07_Apnea', subject_a07_apnea;

'Subject_a13_Normal', subject_a13_normal;
'Subject_a13_Apnea', subject_a13_apnea;

'Subject_a14_Normal', subject_a14_normal;
'Subject_a14_Apnea', subject_a14_apnea;

'Subject_a19_Normal', subject_a19_normal;
'Subject_a19_Apnea', subject_a19_apnea;
};

for i = 1:size(data, 1)
    denumire = data{i, 1};
    sir = data{i, 2};

    % numaratoare in cadrul sirului
    for rand = 1:size(sir, 1)
        k = sum(sir(rand, :) == 1); % numaratoare cazuri apnee per esantion

        %Determinare rezultat
        if k >= prag
            classification = 'Apnea';
        else
            classification = 'Normal';
        end

        % Afisare Rezultat
        disp([denumire, ' esantion ', num2str(rand), ' Detectie: ', classification]);
    end
    disp(' ');
end
```

Figura 33. Algoritm de clasificare normal/apnee

4 Rezultate experimentale

În cadrul acestui capitol, vor fi prezentate rezultatele algoritmului propus în capitolul de implementare, vor fi afișate simulări, dar și rezultatele obținute sub formă tabelară. De asemenea, vor fi prezentate și diverse grafice, care au rolul de a ilustra, într-un mod concludent, eficiența și buna funcționare a metodei utilizate. Din perspectiva aplicațiilor folosite pentru a crea structura de prezentare a informațiilor din cadrul acestui capitol, s-a utilizat programul MATLAB R2023a, dar și Microsoft Excel, pentru ilustrarea datelor obținute sub formă tabelară, dar și la nivel grafic.

Din perspectiva rezultatelor, acestea au fost obținute pentru testarea a 50 de semnale, colectate de la 5 subiecți, identificate în cadrul lucrării sub numele a01, a07, a13, a14 și a19. S-a ales ca numărul semnalelor detectate cu apnee din PhysioNet [57], să fie egal cu cel al semnalelor identificate ca fiind normale, la care, prin folosirea algoritmului de detecție detaliat în amănunt la capitolul de implementare, s-a obținut o serie de 13 parametrii, care sunt dependenți în mare măsură de vârfurile detectate din complexul QRS. Undele au fost detectate în urma utilizării algoritmului Pan Tompkins. În acest mod, se poate susține că acest algoritm de detecție al pozițiilor undelor semnalului joacă un rol crucial în cadrul lucrării prezentate. În continuare, vor fi prezentate datele și rezultatele obținute în urma testării algoritmului pe setul de date.

4.1 Detectarea vârfurilor P, Q, R, S și T pe tot intervalul

Până în acest moment, a fost expusă analiza intervalelor pentru durate ale semnalelor de 10 secunde, care stau la baza rezultatelor care o să fie ilustrate în cele ce urmează, dar și a clasificării explicate la capitolul de implementare. Însă, în cadrul secțiunii curente, 4.1, o să fie expuse două simulări, pentru subiecții a01 și a14, care detectează undele PQRST pe tot intervalul de o oră analizat. Astfel, se poate observa evoluția semnalului, în timp și amplitudine, de la starea normală la cea cu apnee, pentru a vedea la o scară mai mare diferența dintre cele două cazuri ilustrate în Figurile 34 și 35.




Figura 34. Semnal ECG cu durată de o oră a subiectului a01
[ECG normal (0s – 780s), ECG în prezența apneei (780s - 3600s)]




Figura 35. Semnal ECG cu durată de o oră a subiectului a14
[ECG normal (0s – 900s), ECG în prezența apneei (900s – 3600s)]

4.2 Testarea semnalelor ECG – Simulări MATLAB




Figura 36. Aplicarea algoritmului Pan-Tompkins pentru subiectul a01 cu etapele de filtrare, normalizare și diferențiere




Figura 37. Aplicarea algoritmului Pan-Tompkins pentru subiectul a01 cu etapele de ridicare la pătrat, integrare și aplicarea pragului

În Figurile 38 și 39 este ilustrată detecția vârfurilor P, Q, R, S și T pentru două cazuri diferite ale subiectului a01. Semnalul 37-47 este identificat ca fiind normal, iar semnalul 3017-3027 este identificat cu prezența apneei. Reprezentarea de față are rolul de a ilustra diferențele vizibile dintre două semnale clasificate diferit de către algoritm. În cadrul celor două reprezentări se pot observa diferențe majore în ceea ce privește modul în care variază amplitudinea undelor identificate, intervalele dintre două unde consecutive, dar și inconsistența pe care o are semnalul identificat cu apnee față de cel normal. După expunerea semnalelor pentru cazul a01 va fi oferit câte un exemplu și pentru ceilalți subiecți.




Figura 38. Reprezentarea semnalului ECG cu detecția vârfurilor pentru subiectul a01, eşantionul 37-47, detectat ca fiind normal




Figura 39. Reprezentarea semnalului ECG cu detecția vârfurilor pentru subiectul a01, eşantionul 3017-3027, detectat cu apnee




Figura 40. Reprezentarea semnalului ECG cu detecția vârfurilor pentru subiectul a07, eșantion 1799-1809, detectat normal și eșantion 1586-1596, detectat cu apnee




Figura 41. Reprezentarea semnalului ECG cu detecția vârfurilor pentru subiectul a14, eșantion 484-494, detectat normal și eșantion 1625-1635, detectat cu apnee




Figura 42. Reprezentarea semnalului ECG cu detecția vârfurilor pentru subiectul a13, eșantion 234-244, detectat normal și eșantion 3433-3443, detectat cu apnee




Figura 43. Reprezentarea semnalului ECG cu detecția vârfurilor pentru subiectul a19, eșantion 2231-2241, detectat normal și eșantion 217-227, detectat cu apnee

În continuare o să fie prezentate rezultatele codurilor utilizate în cadrul celor trei etape realizate. Astfel, în Figura 44 este reprezentat rezultatul algoritmului de determinare, pentru un singur semnal, a celor 13 parametrii utilizați pentru clasificarea semnalelor în categoria potrivită. În Figura 45 este reprezentat rezultatul algoritmului care detectează pragul unic al unui parametru. Mai departe, se clasifică valorile acelui parametru în funcție de pragul stabilit, în acest caz pentru unda R, dar procesul este la fel pentru toți parametrii. În Figura 46 este prezentat rezultatul clasificării tuturor semnalelor testate, acest rezultat este dat de numărul de parametrii care depășesc pragurile stabilite pentru fiecare subiect.

```

Command Window
Distanța MEDIE A undelor QRS PE INTERVALUL ALES ESTE: 0.2100
Distanța MEDIE A undelor PR PE INTERVALUL ALES ESTE: 0.0733
>> Detector_Final
Valoare minimă în secunde: 1625
Valoare maximă în secunde: 1635
R Valori perioada aleasa:
0.7724 0.8506 0.5790 0.7206 0.8252 0.6420 0.6737 0.7107 0.6388
P Valori perioada aleasa:
0.0250 0.0383 0.0347 0.0345 0.0424 0.0560 0.0292 0.0451 0.0553
T Valori perioada aleasa:
0.0755 0.0829 0.0767 0.0688 0.0723 0.0582 0.0862 0.0798 0.0645
Intervale RR:
1.0300 1.3400 1.0200 1.1300 1.1900 0.9800 1.0800 1.1400
Puterea totală a spectrului de putere semnal ECG:
0.0190
|
Heart rate general: = 55 bătăi pe minut
Heart rate interval: = 54 bătăi pe minut
SDNN_Interval: 0.1151
Mean RR interval (μ): 1.1138
Standard Deviation of RR intervals (σ): 0.1077
Mean RD interval (μ_rd): 0.01375
Standard Deviation of interbeat differentials rd (σ): 0.18378
RMSSD: 0.0652
Number of Extreme Points (NEP): 0.6667

Command Window
Intervale QRS:
0.2000 0.2300 0.2000 0.2100 0.2300 0.2000 0.2200 0.2200
Intervale PR:
0.0500 0.0600 0.0600 0.0500 0.1000 0.0700 0.0500 0.0600 0.0700
AMPLITUDINEA MEDIA A UNDEI R PE INTERVALUL ALES ESTE: 0.7126
AMPLITUDINEA MEDIA A UNDEI T PE INTERVALUL ALES ESTE: 0.0739
AMPLITUDINEA MEDIA A UNDEI P PE INTERVALUL ALES ESTE: 0.0401
Distanța MEDIE A undelor RR PE INTERVALUL ALES ESTE: 1.1138
Distanța MEDIE A undelor QRS PE INTERVALUL ALES ESTE: 0.2137
Distanța MEDIE A undelor PR PE INTERVALUL ALES ESTE: 0.0633
fx >> |
<

```

Figura 44. Testarea subiectului a14 care este detectat cu apnee

Command Window	Command Window
<pre> Pragul General/unic este: 0.73181 Clasificare vector valori normale: Vector Normal (Persoana 1, Valoare 1): Normal Vector Normal (Persoana 1, Valoare 2): Normal Vector Normal (Persoana 1, Valoare 3): Normal Vector Normal (Persoana 1, Valoare 4): Normal Vector Normal (Persoana 1, Valoare 5): Normal Vector Normal (Persoana 2, Valoare 1): Apnea Vector Normal (Persoana 2, Valoare 2): Apnea Vector Normal (Persoana 2, Valoare 3): Normal Vector Normal (Persoana 2, Valoare 4): Normal Vector Normal (Persoana 2, Valoare 5): Normal Vector Normal (Persoana 3, Valoare 1): Apnea Vector Normal (Persoana 3, Valoare 2): Apnea Vector Normal (Persoana 3, Valoare 3): Apnea Vector Normal (Persoana 3, Valoare 4): Apnea Vector Normal (Persoana 3, Valoare 5): Apnea Vector Normal (Persoana 4, Valoare 1): Normal Vector Normal (Persoana 4, Valoare 2): Normal Vector Normal (Persoana 4, Valoare 3): Normal Vector Normal (Persoana 4, Valoare 4): Normal Vector Normal (Persoana 4, Valoare 5): Normal Vector Normal (Persoana 5, Valoare 1): Normal Vector Normal (Persoana 5, Valoare 2): Normal Vector Normal (Persoana 5, Valoare 3): Normal fx Vector Normal (Persoana 5, Valoare 4): Normal </pre>	<pre> Vector Apnea (Persoana 1, Valoare 1): Normal Vector Apnea (Persoana 1, Valoare 2): Normal Vector Apnea (Persoana 1, Valoare 3): Normal Vector Apnea (Persoana 1, Valoare 4): Normal Vector Apnea (Persoana 1, Valoare 5): Normal Vector Apnea (Persoana 2, Valoare 1): Apnea Vector Apnea (Persoana 2, Valoare 2): Apnea Vector Apnea (Persoana 2, Valoare 3): Apnea Vector Apnea (Persoana 2, Valoare 4): Apnea Vector Apnea (Persoana 2, Valoare 5): Apnea Vector Apnea (Persoana 3, Valoare 1): Apnea Vector Apnea (Persoana 3, Valoare 2): Apnea Vector Apnea (Persoana 3, Valoare 3): Apnea Vector Apnea (Persoana 3, Valoare 4): Apnea Vector Apnea (Persoana 3, Valoare 5): Apnea Vector Apnea (Persoana 4, Valoare 1): Normal Vector Apnea (Persoana 4, Valoare 2): Normal Vector Apnea (Persoana 4, Valoare 3): Normal Vector Apnea (Persoana 4, Valoare 4): Normal Vector Apnea (Persoana 4, Valoare 5): Apnea Vector Apnea (Persoana 5, Valoare 1): Apnea Vector Apnea (Persoana 5, Valoare 2): Apnea Vector Apnea (Persoana 5, Valoare 3): Apnea Vector Apnea (Persoana 5, Valoare 4): Apnea Vector Apnea (Persoana 5, Valoare 5): Apnea fx >> </pre>

Figura 45. Testarea clasificării în raport cu unda R pentru toate semnalele

Command Window	Command Window
<pre> >> concluziil Subiect_a01_Normal esantion 1 Detectie: Normal Subiect_a01_Normal esantion 2 Detectie: Normal Subiect_a01_Normal esantion 3 Detectie: Normal Subiect_a01_Normal esantion 4 Detectie: Normal Subiect_a01_Normal esantion 5 Detectie: Normal Subiect_a01_Apnea esantion 1 Detectie: Apnea Subiect_a01_Apnea esantion 2 Detectie: Apnea Subiect_a01_Apnea esantion 3 Detectie: Apnea Subiect_a01_Apnea esantion 4 Detectie: Apnea Subiect_a01_Apnea esantion 5 Detectie: Apnea Subiect_a07_Normal esantion 1 Detectie: Normal Subiect_a07_Normal esantion 2 Detectie: Apnea Subiect_a07_Normal esantion 3 Detectie: Normal Subiect_a07_Normal esantion 4 Detectie: Normal Subiect_a07_Normal esantion 5 Detectie: Normal Subiect_a07_Apnea esantion 1 Detectie: Apnea Subiect_a07_Apnea esantion 2 Detectie: Apnea Subiect_a07_Apnea esantion 3 Detectie: Apnea Subiect_a07_Apnea esantion 4 Detectie: Apnea Subiect_a07_Apnea esantion 5 Detectie: Apnea Subiect_a13_Normal esantion 1 Detectie: Normal Subiect_a13_Normal esantion 2 Detectie: Normal Subiect_a13_Normal esantion 3 Detectie: Normal fx Subiect_a13_Normal esantion 4 Detectie: Normal </pre>	<pre> Subiect_a13_Apnea esantion 1 Detectie: Apnea Subiect_a13_Apnea esantion 2 Detectie: Apnea Subiect_a13_Apnea esantion 3 Detectie: Apnea Subiect_a13_Apnea esantion 4 Detectie: Apnea Subiect_a13_Apnea esantion 5 Detectie: Apnea Subiect_a14_Normal esantion 1 Detectie: Apnea Subiect_a14_Normal esantion 2 Detectie: Normal Subiect_a14_Normal esantion 3 Detectie: Normal Subiect_a14_Normal esantion 4 Detectie: Apnea Subiect_a14_Normal esantion 5 Detectie: Apnea Subiect_a14_Apnea esantion 1 Detectie: Apnea Subiect_a14_Apnea esantion 2 Detectie: Apnea Subiect_a14_Apnea esantion 3 Detectie: Apnea Subiect_a14_Apnea esantion 4 Detectie: Apnea Subiect_a14_Apnea esantion 5 Detectie: Apnea Subiect_a19_Normal esantion 1 Detectie: Normal Subiect_a19_Normal esantion 2 Detectie: Normal Subiect_a19_Normal esantion 3 Detectie: Normal Subiect_a19_Normal esantion 4 Detectie: Normal Subiect_a19_Normal esantion 5 Detectie: Normal Subiect_a19_Apnea esantion 1 Detectie: Normal Subiect_a19_Apnea esantion 2 Detectie: Normal Subiect_a19_Apnea esantion 3 Detectie: Normal fx Subiect_a19_Apnea esantion 4 Detectie: Normal </pre>

Figura 46. Clasificarea tuturor semnalelor utilizate

4.3 Centralizarea rezultatelor semnalelor ECG

Această etapă a fost realizată folosind tool-ul Microsoft Excel, în care datele au fost monitorizate sub formă tabelară pentru fiecare subiect, respectiv fiecare semnal în parte, cu scopul de a ilustra, într-o formă simplificată, rezultatele acestei lucrări. Cele 50 se semnale au fost grupate pe grupuri de câte 10, în funcție de originea de la care acestea provin. În tabelul 4 sunt expuse pragurile deduse pentru fiecare dintre cei 13 parametri analizați.

Tabelul 4. Stabilirea pragului pentru cei 13 parametri

Determinare PRAG Unic	Clasificare	AMPLITUDINI			INTERVALE					HRV	HRV			
	Algoritm	R (mv)	T (mv)	P (mv)	RR (s)	QRS (s)	PR (s)	HR (bpm)	Putere Totala (ms ²)	SDNN (ms)	RMSSD (ms)	RR St. DEV. (s)	RD St. DEV. (s)	NEP
VALOARE PRAG	5	0.73181	0.088069	0.037905	0.81724	0.2244	0.087	60-100	0.025	0.057	0.00609	0.054	0.048	0.38632

În tabelul 5 sunt contorizate rezultatele, la nivelul fiecărui semnal testat, în care au fost marcate valorile acelor parametri care depășesc pragul stabilit cu o culoare diferită. Diagnosticul este afișat tot în cadrul tabelului 5, atât cel pus de către adnotările PhysioNet, cât și cel rezultat în urma testării algoritmului propus. Cu culoarea verde au fost marcate rezultatele care le respectă pe cele din PhysioNet, în timp ce cu culoarea roșu au fost marcate cele care nu respectă această condiție.

Tabelul 5. Diagnostic și contorizare rezultate semnale ECG

Subiect a01	Clasificare	Clasificare	AMPLITUDINI			INTERVALE					HRV	HRV			
Interval	PhysioNet	Algoritm	R (mv)	T (mv)	P (mv)	RR (s)	QRS (s)	PR (s)	HR (bpm)	Putere Totala (ms ²)	SDNN (ms)	RMSSD (ms)	RR St. DEV. (s)	RD St. DEV. (s)	NEP
37-47	Normal	Normal	0.6037	0.0871	0.0247	0.903	0.195	0.0573	66	0.0182	0.0568	0.0152	0.053861	0.047776	0.5
105-115	Normal	Normal	0.611	0.092	0.024	0.881	0.198	0.0573	66	0.02	0.034	0.0114	0.0323	0.036	0.375
328-338	Normal	Normal	0.6057	0.0834	0.0212	0.8591	0.1964	0.0575	72	0.0204	0.0474	0.0117	0.045218	0.03886	0.333
575-585	Normal	Normal	0.5778	0.078	0.0275	0.8355	0.1973	0.0575	72	0.0189	0.0258	0.0074	0.024629	0.024421	0.44444
621-631	Normal	Normal	0.5801	0.0757	0.0304	0.934	0.194	0.0573	66	0.0172	0.0558	0.0143	0.052953	0.015166	0.375
1085-1095	Apnea	Apnea	0.6508	0.0789	0.0467	0.7945	0.2045	0.1108	72	0.024	0.0798	0.0128	0.076082	0.040479	0.222
1195-1205	Apnea	Apnea	0.6557	0.09	0.0326	0.8491	0.2055	0.08	72	0.0247	0.0428	0.0152	0.040778	0.050417	0.5556
1432-1442	Apnea	Apnea	0.6533	0.0811	0.0314	0.8273	0.2027	0.0738	72	0.0236	0.0571	0.0156	0.054454	0.051708	0.55556
3017-3027	Apnea	Apnea	0.6625	0.0847	0.0411	0.886	0.21	0.0745	66	0.021	0.0898	0.0332	0.085229	0.10489	0.375
3382-3392	Apnea	Apnea	0.63	0.0715	0.0434	1.0463	0.2087	0.0689	54	0.0152	0.0715	0.0213	0.066884	0.058522	0.5
Subiect a07	Clasificare	Clasificare	AMPLITUDINI			INTERVALE					HRV	HRV			
Interval	PhysioNet	Algoritm	R (mv)	T (mv)	P (mv)	RR (s)	QRS (s)	PR (s)	HR (bpm)	Putere Totala (ms ²)	SDNN (ms)	RMSSD (ms)	RR St. DEV. (s)	RD St. DEV. (s)	NEP
562-572	Normal	Normal	0.7411	0.1226	0.0329	0.7517	0.235	0.092	78	0.0309	0.0313	0.0049	0.029954	0.015336	0.3
784-794	Normal	Apnea	0.7458	0.1266	0.0229	0.855	0.238	0.085	66	0.0288	0.0284	0.0053	0.026926	0.013038	0.375
717-727	Normal	Normal	0.729	0.126	0.0287	0.8073	0.2355	0.085	72	0.0288	0.0144	0.0042	0.010523	0.014014	0.222
1799-1809	Normal	Normal	0.7111	0.1164	0.026	0.755	0.24	0.083	78	0.0295	0.0117	0.004	0.01118	0.013598	0.6
2855-2865	Normal	Normal	0.7253	0.1219	0.0287	0.7442	0.2383	0.083	78	0.0296	0.0151	0.0031	0.01441	0.010661	0.2
1586-1596	Apnea	Apnea	0.847	0.1445	0.0239	0.92	0.236	0.0927	66	0.0367	0.0615	0.0214	0.05831	0.066708	0.625
1618-1628	Apnea	Apnea	0.8364	0.1405	0.0287	0.8382	0.2391	0.1117	72	0.037	0.0506	0.0129	0.048208	0.042736	0.4333
3459-3469	Apnea	Apnea	0.7813	0.1271	0.0341	0.725	0.2317	0.05	78	0.0351	0.047	0.0088	0.045	0.029	0.5
3530-3540	Apnea	Apnea	0.77	0.1305	0.031	0.8282	0.24	0.1415	72	0.0316	0.0376	0.0072	0.035883	0.028	0.4333
3580-3590	Apnea	Apnea	0.8086	0.1356	0.0294	0.8278	0.2367	0.1151	78	0.0351	0.0591	0.0175	0.052	0.06	0.5
Subiect a13	Clasificare	Clasificare	AMPLITUDINI			INTERVALE					HRV	HRV			
Interval	PhysioNet	Algoritm	R (mv)	T (mv)	P (mv)	RR (s)	QRS (s)	PR (s)	HR (bpm)	Putere Totala (ms ²)	SDNN (ms)	RMSSD (ms)	RR St. DEV. (s)	RD St. DEV. (s)	NEP
10-20	Normal	Normal	0.7412	0.0873	0.0297	0.7215	0.2715	0.0881	84	0.0242	0.0099	0.0029	0.0094	0.0102	0.3636
234-244	Normal	Normal	0.7631	0.0926	0.0196	0.6636	0.2614	0.0867	90	0.028	0.0115	0.0028	0.011	0.0103	0.25
509-519	Normal	Normal	0.742	0.0844	0.0254	0.6579	0.265	0.0847	90	0.0256	0.0148	0.002	0.014	0.0069	0.5
698-708	Normal	Normal	0.7363	0.0831	0.0231	0.6614	0.2671	0.0793	90	0.0255	0.0151	0.0025	0.014	0.00925	0.3333
785-795	Normal	Normal	0.74565	0.0868	0.0202	0.6761	0.2662	0.0847	90	0.25	0.0128	0.0025	0.012	0.0085	0.25
2859-2869	Apnea	Apnea	0.8577	0.1031	0.0397	0.6686	0.2664	0.09	90	0.0347	0.0611	0.0061	0.589	0.0205	0
2520-2530	Apnea	Apnea	0.9004	0.1242	0.0343	0.7483	0.2617	0.0971	78	0.0358	0.0907	0.0085	0.0868	0.0214	0.3
3433-3443	Apnea	Apnea	0.8669	0.1066	0.0347	0.6457	0.2614	0.088	90	0.0354	0.049	0.0052	0.037553	0.018	0.41667
3563-3573	Apnea	Apnea	0.8942	0.1295	0.0327	0.84	0.2664	0.143	72	0.0332	0.0407	0.007	0.0388	0.022	0.333
3189-3199	Apnea	Apnea	0.8984	0.1262	0.03535	0.7725	0.2625	0.1569	78	0.036	0.074	0.007	0.0708	0.022	0.2

Subiect a14	Clasificare	Clasificare	AMPLITUDINI				INTERVALE				HRV	HRV			
Interval	PhysioNet	Algoritm	R (mv)	T (mv)	P (mv)	RR (s)	QRS (s)	PR (s)	HR (bpm)	Putere Totala (ms ²)	SDNN (ms)	RMSSD (ms)	RR St. DEV. (s)	RD St. DEV. (s)	NEP
260-270	Normal	Apnea	0.6341	0.0722	0.0401	0.9922	0.2	0.062	60	0.0176	0.0687	0.0258	0.0647	0.076	0.428
484-494	Normal	Normal	0.6256	0.0684	0.0468	1.0775	0.2062	0.0911	60	0.0162	0.0489	0.0159	0.0457	0.043	0.333
386-396	Normal	Normal	0.6376	0.0694	0.0511	1.0567	0.2011	0.075	60	0.0174	0.0548	0.0123	0.051	0.035	0.128
410-420	Normal	Apnea	0.6326	0.0704	0.0494	1.045	0.21	0.07	60	0.0167	0.068	0.0232	0.063	0.063	0.333
540-550	Normal	Apnea	0.628	0.0726	0.0331	1.08	0.2062	0.098	60	0.0162	0.0438	0.0177	0.0409	0.0493	0.5
1625-1635	Apnea	Apnea	0.7126	0.0739	0.047	1.1138	0.2137	0.0633	54	0.0191	0.1151	0.0652	0.1077	0.1837	0.666
2930-2940	Apnea	Apnea	0.7114	0.0698	0.0578	1.1687	0.2188	0.1256	54	0.0195	0.0937	0.0333	0.078	0.109	0.0233
2796-2806	Apnea	Apnea	0.7025	0.0718	0.0565	1.1829	0.21	0.1375	48	0.0163	0.1064	0.0409	0.098	0.1028	0.4
1409-1419	Apnea	Apnea	0.7103	0.0712	0.0537	1.1781	0.2143	0.125	54	0.0173	0.095	0.0419	0.069	0.107	0.8
1272-1282	Apnea	Apnea	0.7446	0.0746	0.0603	0.1071	0.2067	0.055	60	0.0227	0.0901	0.0252	0.0554	0.0954	0.571

Subiect a19	Clasificare	Clasificare	AMPLITUDINI				INTERVALE				HRV	HRV			
Interval	PhysioNet	Algoritm	R (mv)	T (mv)	P (mv)	RR (s)	QRS (s)	PR (s)	HR (bpm)	Putere Totala (ms ²)	SDNN (ms)	RMSSD (ms)	RR St. DEV. (s)	RD St. DEV. (s)	NEP
2231-2241	Normal	Normal	0.7223	0.0515	0.048	0.81	0.2155	0.1008	72	0.0168	0.0148	0.0037	0.0141	0.0121	0.2222
2650-2660	Normal	Normal	0.7216	0.0489	0.0469	0.7725	0.215	0.1031	78	0.0177	0.0097	0.0031	0.0092	0.0103	0.4
3351-3361	Normal	Normal	0.7071	0.0451	0.0499	0.78	0.2133	0.11	78	0.0176	0.0128	0.0033	0.0122	0.0114	0.5
3541-3551	Normal	Normal	0.7126	0.0457	0.0489	0.7842	0.2133	0.1077	78	0.0174	0.0211	0.0035	0.0201	0.0117	0.6
3570-3580	Normal	Normal	0.7159	0.0478	0.0484	0.7866	0.2142	0.1011	72	0.0173	0.0115	0.0034	0.01	0.0109	0.33
175-185	Apnea	Normal	0.8524	0.0598	0.0522	0.7442	0.2058	0.1	78	0.0271	0.0183	0.0039	0.0175	0.0125	0.3
217-227	Apnea	Normal	0.7931	0.0675	0.0519	0.7642	0.2033	0.1	78	0.0254	0.0178	0.0024	0.0171	0.0079	0
282-292	Apnea	Normal	0.8322	0.0695	0.0511	0.74	0.2083	0.0992	78	0.0252	0.0165	0.0033	0.0158	0.0081	0.5
325-335	Apnea	Normal	0.8821	0.0529	0.0474	0.7292	0.2062	0.0993	84	0.0291	0.0155	0.0024	0.0149	0.0078	0.3636
75-85	Apnea	Apnea	0.8399	0.0624	0.0506	0.7444	0.2059	0.0998	84	0.0267	0.0169	0.0028	0.0165	0.0085	0.55

4.4 Analiza de performanță a algoritmului propus

Determinarea valorilor de performanță reprezintă un pas important în analizarea performanței și utilității algoritmului implementat în acest proiect. Procesul de determinare a performanței poate să ofere multe informații utile despre funcționalitatea și eficiența algoritmului. Unul dintre cei mai utilizați parametrii pentru detectarea eficienței unui algoritm este reprezentat de acuratețe. Acuratețea oferă o idee generală a performanței algoritmului, dar poate induce în eroare în cazul în care cele două clase cu care se lucrează sunt dezechilibrate. Acuratețea poate să fie definită ca raportul dintre numărul de predicții corecte, atât în cazurile de apnee, cât și în cele normale, și numărul total de predicții, având următoarea formulă:

$$Acurate\text{ț}ea = \frac{TP+TN}{TP+TN+FP+FN} \quad (11)$$

În acest caz, *TP* vine de de „True Positive”, iar acest parametru indică numărul de cazuri în care a rezultat un caz corect în clasa pozitivă. *TN* înseamnă „True Negative”, iar acest parametru indică numărul de cazuri în care a rezultat un caz corect în clasa negativă. *FP* și *FN* provin de la „False Positive” și „False Negative”, iar acești doi parametrii prezic numărul de cazuri incorecte pentru clasa de la care le provine numele. În lucrarea de față, s-a ales ca clasa pozitivă să fie reprezentată de cazurile cu apnee și cea negativă de cazurile normale, așa că *TP* reprezintă cazurile cu apnee identificate cu apnee, iar *FP* reprezintă numărul de cazuri normale identificate ca fiind cazuri cu apnee. După aceeași logică va funcționa și *TN* cu *FN*, dar pentru cazurile normale. Dacă se face suma celor 4 parametrii menționați anterior, se va obține numărul total de semnale analizate. Parametrul de precizie poate să fie calculat utilizând termenii menționați anterior. Precizia este termenul care identifică cazurile pozitive detectate corect raportat la numărul total de cazuri pozitive, iar formula acestui parametru este exprimată în continuare:

$$Precizia = \frac{TP}{TP+FP} \quad (12)$$

Rezultatele pentru determinarea performanței și, de asemenea, valorile lui TP , TN , FP și FN o să fie determinate în continuare. În total sunt 50 de semnale testate, 25 sunt normale și 25 cu apnee, din care, în urma detecției, s-a observat că un număr egal de semnale normale și cu apnee au fost detectate greșit, adică 4 semnale normale și 4 cu apnee sunt identificate incorect. În urma analizei factorilor prezenți, s-au stabilit următoarele valori pentru cei 4 parametri: $TP = 21$, $TN = 21$, $FP = 4$ și $FN = 4$, cu aceste inițializări vor fi calculate acuratețea și precizia algoritmului după cum urmează:

1. **Acuratețea** = $(TP+TN)/(TP+TN+FP+FN) = (21+21)/(21+21+4+4) = 42/50 = 0,84 = 84\%$
2. **Precizia** = $TP/(TP+FP) = 21/(21+4) = 21/25 = 0,84 = 84\%$

Concluzia care reiese din aceste rezultate este că acuratețea și precizia au exact același rezultat. Astfel, se poate susține că algoritmul de față a înregistrat un grad de performanță de 84% pentru toate semnalele testate în cadrul acestuia. În continuare, pe baza rezultatelor înregistrate în acest capitol, vor fi expuse două grafice, în care vor fi reprezentate eficiența algoritmului la nivelul tuturor semnalelor, dar și eficiența de identificare corectă pentru cazurile separate de identificare de semnal normal sau cu apnee. Figura 47 expune situația la nivel general, în timp ce Figura 48 la nivel particular.




Figura 47. Eficiența generală a algoritmului de detecție




Figura 48. Eficiența particulară a algoritmului de detecție

5 Concluzii

Sănătatea sistemului circulator și a celui respirator sunt componente definitorii ale bunăstării generale a oamenilor din întreaga lume, iar apariția unor probleme de sănătate sau perturbarea bunei funcționări a acestor sisteme, cum ar fi neregularitățile în funcționarea inimii, poate duce la complicații grave. Una dintre aceste probleme a fost analizată în cadrul lucrării de față, aceasta fiind reprezentată de sindromul de apnee în somn. În acest context, este esențială descoperirea de noi metode care să permită identificarea și detectarea timpurie a apariției sau a riscului de apariție a acestei afecțiuni. Acest lucru ar permite tratamentul eficient sau menținerea acestuia sub control, contribuind astfel la reducerea ratei mortalității cauzate de problemele cardiace, care în prezent reprezintă una dintre cele mai frecvente cauze de deces la nivel global. Detectarea precoce și monitorizarea eficientă a afecțiunii de apnee în somn este esențială pentru prevenirea unor complicații reprezentate de bolile cardiovasculare ca hipertensiunea, cu scopul de a le putea prevenii și pentru a îmbunătăți calitatea vieții pacienților.

Lucrarea de față se concentrează pe dezvoltarea unor metode de identificare și detectare a afecțiunii de apnee în somn prin analiza semnalului de electrocardiogramă. Acest semnal este procesat și analizat utilizând mediul de dezvoltare MATLAB. Printre obiectivele principale ale proiectului de față s-a evidențiat explorarea modului în care anumiți parametri specifici pot să fie folosiți pentru a detecta dacă este prezentă apneea în somn, în cadrul semnalului analizat. Astfel, s-a urmărit analiza unor parametri ca: amplitudinea undelor R, P, T, intervalele RR, PR, QRS, sau a unor parametri ca SDNN (Standard Deviation of Normal-to-Normal Intervals), RMSSD (Root Mean Square of Successive Differences), NEP (Number of Extreme Points) și al altor parametri rezultați din analiza semnalului ECG. Prin acești parametri, lucrarea de față și-a propus să identifice anumite metode care pot indica evenimente de apnee.

Detectarea vârfurilor semnalului ECG utilizând algoritmul Pan-Tompkins a stat la baza acestei analize, deoarece a oferit posibilitatea de a crea și dezvolta modelul de clasificare conceput pentru a detecta apariția apneei în somn. Din perspectiva rezultatelor acestui proiect, s-a demonstrat faptul că majoritatea parametrilor analizați sunt folositori în detectarea ritmurilor cardiace normale și a celor anormale care sunt asociate evenimentelor de apnee în somn. Astfel, rezultatele obținute evidențiază faptul că monitorizarea și prelucrarea bazate pe semnalele ECG poate să fie un instrument eficient și non-invaziv pentru detectarea eficientă a acestei afecțiuni medicale, având avantajul de a putea fi integrată în diverse dispozitive portabile sau în cadrul sistemelor clinice de monitorizare. De asemenea, au fost obținute rezultate promițătoare și satisfăcătoare, cu o acuratețe a algoritmului de 84%, însă este important să se sublinieze și limitările metodei, care au fost identificate pe parcursul implementării metodei propuse. Aceste limitări includ complexitatea semnalelor ECG, implementarea secvențială a algoritmului și necesitatea validării acestuia pe o bază mai mare de date.

În cadrul cercetărilor viitoare, ar fi util să se acorde o atenție deosebită rafinării algoritmilor, prin îmbunătățirea acurateței și fiabilității metodei utilizate. Aceasta ar putea include și integrarea unor semnale fiziologice suplimentare, cum ar fi saturația de oxigen din sânge, precum și automatizarea detectării pragurilor parametrilor analizați și a clasificării semnalelor ca fiind normale sau asociate cu apneea în somn. În concluzie, proiectul de față reprezintă un punct foarte bun de plecare pentru a ajunge la o asistență medicală mai eficientă, în vederea prevenirii unor probleme de sănătate. Valorificarea prelucrării și analizei semnalului ECG, poate să devină o posibilitate reală a detecției precoce a apneei în somn, deoarece în acest mod se reduc șansele de dezvoltare a complicațiilor de natură cardiovasculară asociate cu acest sindrom. Din perspectiva avansărilor tehnologice, dezvoltarea unor asemenea tehnologii este extrem de promițătoare pentru viitorul pe care îl va avea domeniul medicinei în ceea ce privește monitorizarea sănătății pacienților și de prevenire a bolilor.

6 Bibliografie

- [1] S. Dattani, V. Samborska, H. Ritchie and M. Roser,” Cardiovascular Diseases”
- [2] R. Luengo-Fernandez, M. Walli-Attaei, A. Gray, A. Torbica, A. P Maggioni, R. Huculeci, F. Bairami, V. Aboyans, A. D Timmis, P. Vardas, J. Leal, “Economic Burden of Cardiovascular Diseases in the European Union: A Population-Based Cost Study.” *OUP Academic*, Oxford University Press, 26 Aug. 2023.
- [3] Y. Sattar and L. Chhabra. “Electrocardiogram.” *StatPearls.*, U.S. National Library of Medicine, 5 June 2023.
- [4] R. Vincent, “From a Laboratory to the Wearables: A Review on History and Evolution of Electrocardiogram”, Department of General Medicine, Amala Institute of Medical Sciences, Thrissur, Kerala, India, *IBEROAMERICAN JOURNAL OF MEDICINE* 04 (2022) 248-255, 6 Sept. 2022.
- [5] K. C. Siontis, P. A. Noseworthy, Z. I. Attia, P A. Friedman, “Artificial Intelligence-Enhanced Electrocardiography in Cardiovascular Disease Management.” *Nature News Nature Publishing Group*, Nature Publishing Group, 1 Feb. 2021.
- [6] M. M. R. Khan Mamun, A.T. Alouani, “Automatic Detection of Heart Diseases Using Biomedical Signals: A Literature Review of Current Status and Limitations”, In book: *Advances in Information and Communication* (pp.420-440), March 2022.
- [7] <https://www.statista.com/statistics/1282350/sleep-apnea-device-revenue-eastern-europe/>
- [8] A. Rath, D. Mishra, G. Panda “LSTM-based cardiovascular disease detection using ECG signal”. Book: *Cognitive informatics and soft computing*. Springer; 2021:133-142.
- [9] T. Nguyen, T. Nguyen, “Deep learning framework with ECG feature-based kernels for heart disease classification”, *Elektronika ir Elektrotechnika*. 2021;27(1):48-59.
- [10] F. Ali, S. El-Sappangh, S. M. Riazul Islam, D. Kwak, “A Smart Healthcare Monitoring System for Heart Disease Prediction Based On Ensemble Deep Learning and Feature Fusion”, *Information Fusion* 63, June 2020.
- [11] H. Mori, K. Inai, H. Sugiyama, Y. Muragaki, “Diagnosing atrial septal defect from electrocardiogram with deep learning”, *Pediatr Cardiol*, 2021
- [12] P. Xiong, Y. Xue, J. Zhang,”Localization of myocardial infarction with multi-lead ECG based on DenseNet”, *Comput Methods Programs Biomed*, 2021.
- [13] D. Shin, R.C. Park, K. Chung, “Decision boundary-based anomaly detection model using improved AnoGAN from ECG data”, *IEEE Access*, 2020.
- [14] J. Zhu, A. Zhou, Q. Gong, Y. Zhou, J. Huang, Z. Chen, “Detection of Sleep Apnea from Electrocardiogram and Pulse Oximetry Signals Using Random Forest.” *MDPI*, Multidisciplinary Digital Publishing Institute, 22 Apr. 2022.
- [15] T. Paul, O. Hassan, K. Alabound, H. Islam, K. Z. Rana, S. K. Islam, A. S. M. Mosa, “ECG and SpO2 Signal-Based Real-Time Sleep Apnea Detection Using Feed-Forward Artificial Neural Network.” *AMIA Joint Summits on Translational Science Proceedings*. AMIA Joint Summits on Translational Science, U.S. National Library of Medicine, 23 May 2022.
- [16] C. Karmakar, A. Khandoker, T. Penzel, C. Schobel, M. Palaniswami, “Detection of Respiratory Arousals Using Photoplethysmography (PPG) Signal in Sleep Apnea Patients”, *IEEE JOURNAL OF BIOMEDICAL AND HEALTH INFORMATICS*, VOL. 18, NO. 3.
- [17] T. Novotny, R. R. Bond, I. Andrsova, L. Koc, M. Sisakova, D. D. Finlay, D. Guldenring, J. Spinar, M. Malik, “Data analysis of diagnostic accuracies in 12-lead electrocardiogram interpretation by junior medical fellows“. *Journal of Electrocardiology*, 12 Aug. 2015.
- [18] J. Sacha, “Interaction between Heart Rate and Heart Rate Variability“, *Annals of Noninvasive Electrocardiology*, March 2014.
- [19] https://en.wikipedia.org/wiki/Heart_rate#cite_note-1
- [20] G.Q. Zhang , W. Zhang, "Heart rate, lifespan, and mortality risk". *Ageing Research Reviews*, 2009.

- [21] American Heart Association , "All About Heart Rate (Pulse)" , 25 Jan 2018.
- [22] American Heart Association, "Tachycardia| Fast Heart Rate", 21 May 2014.
- [23] The Only EKG BOOK You'll Ever Need NINTH EDITION MALCOLM S. THALER, M.D. Physician, Internal Medicine, One Medical Clinical Instructor in Medicine, Weill Cornell Medical College Medical Staff, New York Presbyterian Hospital New York, New York
- [24] <https://www.bbc.co.uk/bitesize/guides/zw3bfcw/revision/3>
- [25] T. Novotny, R. R. Bond, I. Andrsova, L. Koc, M. Sisakova, D. D. Finlay, D. Guldenring, J. Spinar, M. Malik, "Data analysis of diagnostic accuracies in 12-lead electrocardiogram interpretation by junior medical fellows". Journal of Electrocardiology, 12 Aug. 2015.
- [26] S. Sattar, R. Mumtaz, M. Qadir, S. Mumtaz, M. A. Khan, T. De Waele, E. De Poorter, I. Moerman, A. Shahid, "Cardiac arrhythmia classification using advanced deep learning techniques on digitized ECG datasets", Sensors, MDPI, 12 April 2024.
- [27] I. Rehman A. Rehman, "Anatomy, thorax, heart", StatPearls - NCBI Bookshelf, 28 August 2023.
- [28] S. K. Padala, J. Cabrera, K. A. Ellenbogen, "Anatomy of the cardiac conduction system", Pacing and Clinical Electrophysiology, 12 November 2021.
- [29] H. V. Weerd, V. Christoffels, "The formation and function of the cardiac conduction system ", ResearchGate, January 2016.
- [30] https://en.wikipedia.org/wiki/Heart#cite_note-51
- [31] <https://elitehrv.com/heart-rate-variability-vs-heart-rate>
- [32] ECG & the Electrical Activity of the Heart Stock Illustration - Illustration of inferior, heart: 216704758 (dreamstime.com)
- [33] <https://ecgwaves.com/topic/ecg-normal-p-wave-qrs-complex-st-segment-t-wave-j-point/>
- [34] <https://ecgwaves.com/>
- [35] U. Zalabarria, E. Irigoyen, R. Martinez, A. Lowe, "Online robust R-peaks detection in noisy electrocardiograms using a novel iterative smart processing algorithm", Applied Mathematics and Computation, 369, 124839, 15 March 2020.
- [36] https://www.wikidoc.org/index.php/T_wave
- [37] https://www.researchgate.net/figure/Illustration-of-QRS-complexes-and-RR-interval-of-ECG-signals_fig4_326588784
- [38] https://en.wikipedia.org/wiki/T_wave
- [39] <https://litfl.com/pr-interval-ecg-library/>
- [40] <https://ro.wikipedia.org/wiki/Apnee>
- [41] V. Tsara, A. Amfilochiou, M. J. Papagrigrakis, D. Georgopoulos, E. Liolios, "Definition and classification of sleep related breathing disorders in adults", Different types and indications for sleep studies (Part 1), PubMed Central (PMC), 1 September 2009.
- [42] X. Zhao, X. Wang, T. Yang, S. Ji, H. Wang, J. Wang, Y. Wang, Q. Wu, "Classification of sleep apnea based on EEG sub-band signal characteristics", Scientific Reports, 11(1), 5824, 12 March 2021
- [43] <https://www.sleepfoundation.org/sleep-apnea/ahi>
- [44] https://www.wikidoc.org/index.php/Sleep_apnea_classification
- [45] A. R. Hassan, M. A. Haque, "An expert system for automated identification of obstructive sleep apnea from single-lead ECG using random under sampling boosting", Neurocomputing, 235, 122–130, 26 April 2017
- [46] Arefin, M. Riadh. "Computationally efficient QRS detection analysis in electrocardiogram based on dual-slope method ", The University of North Dakota, 2015
- [47] A. Sheta, H. Turabieh, T. Thaher, J. Too, M. Mafarja, M. S. Hossain, S. R. Surani, "Diagnosis of Obstructive Sleep Apnea from ECG Signals Using Machine Learning and Deep Learning Classifiers", Applied Sciences, 11(14), 6622, 6 July 2021.

- [48] J. R. Gini, K. Dhanslakshmi, "Apnoea detection using ECG signal based on machine learning classifiers and its performances", Journal of Medical Engineering & Technology, 47(7), 344–354, 16 April 2024.
- [49] https://www.researchgate.net/figure/a-ECG-signal-apnea-before-and-after-filtering-b-Normal-ECG-signal-before-and-after_fig1_361466123
- [50] R. Khincha, S. Krishnan, R. Parveen, N. Goveas, "ECG signal analysis on an embedded device for sleep apnea detection", In Lecture notes in computer science (pp. 377–384), 5 June 2020.
- [51] https://github.com/antimattercorrade/Pan_Tompkins_QRS_Detection/blob/main/README.md
- [52] Pan, Jiapu, and Willis J. Tompkins. "A real-time QRS detection algorithm." IEEE transactions on biomedical engineering 3 (1985): 230-236.
- [53] Mohanty, Monalisa, Pradyut Kumar Biswal, and Sukanta Kumar Sabut. "Feature extraction of ECG signal for detection of ventricular fibrillation." 2015 International Conference on Man and Machine Interfacing (MAMI). IEEE, 2015.
- [54] https://www.mathworks.com/products/new_products/release2023a.html
- [55] <https://www.mathworks.com/videos/whats-new-in-matlab-and-simulink-r2023a-1683545073311.html>
- [56] <https://archive.physionet.org/cgi-bin/atm/ATM>
- [57] N. Pombo, B. M. C. Silva, A. M. Pinho, A. N. Garcia, "Classifier Precision Analysis for Sleep Apnea Detection Using ECG Signals", IEEE, Instituto de Telecomunicacoes, Universidade da Beira Interior, 6200-001 Covilha, Portugal, 5 November 2020.

ANEXE

```
%DETECTOR

%Pan_Tompkins Algoritm

clear variables;

% Fisierul CSV

[time,sigal] = importfile('a01s.csv');

fs= 100;

time=time+abs(time(1));

N= length(signal);

%VALOARE LINIA ISOELECTRICA

linia_isoelectrica = 0;

t = 1 / fs;

% Slectare intervale afisare

min_time = input('Valuare minimă în secunde: ');

max_time = input('Valuare maximă în secunde: ');

% interval in secunde,min si max

start_index = find(time >= min_time, 1);

end_index = find(time <= max_time, 1, 'last');

time_axis = (start_index:end_index) / fs;

% Afisare semnal ECG Original

figure,

subplot(4,1,1);

plot(time(start_index:end_index), signal(start_index:end_index));

xlabel('Timp (s)');

ylabel('Amplitudine (mV)');

title('Semnal ECG Original');

grid on;

%Pas 0 Eliminarea componentei continue

signal= signal-mean(signal);

signal= signal.*100;
```

```

%Pas 1 filtrare FTB apicat prin FTS si FTJ

%FTS-eliminare baseline wander and offseturi de tip curent continu

%FTJ-pentru a atenua zgomotu de nivel inalt

%definire frecvente de taiere filtre

fjos=2;

fsus=40;

ord=4;

%filtrare trece sus

f1 = fdesign.highpass('n,F3dB', ord, fjos, fs);

ftss = design(f1,'butter');

s_filtrat_1 = filter(ftss,signal);

%filterea trece jos

f2 = fdesign.lowpass('n,F3dB', ord, fsus, fs);

ftjj = design(f2, 'butter');

s_filtrat_2 = filter(ftjj,s_filtrat_1);

subplot(4,1,2);

plot(time(start_index:end_index), s_filtrat_2(start_index:end_index));

xlabel('Timp (s)');

ylabel('Amplitudine (mV)');

title('Semnal filtrat');

grid on;

%Pas2 NORMALIZARE,includ semnalul intre un interval mai mic si bine

%stabilit(-1->1)

numitor=max(abs(s_filtrat_2));

s_normalizat=(1/numitor)*s_filtrat_2;

subplot(4,1,3);

plot(time(start_index:end_index), s_normalizat(start_index:end_index));

xlabel('Timp (s)');

ylabel('Amplitudine (mV)');

title('Semnal Normalizat');

grid on;

```

```

%PAS3 DIFERENTIERE

sem_dif = diff(s_normalizat);

sem_dif_fin = sem_dif;

subplot(4,1,4);

plot(time(start_index:end_index), sem_dif_fin(start_index:end_index));

xlabel('Timp (s)');

ylabel('Amplitudine (mV)');

title('Semnal diff');

grid on;

%PAS 4 Ridicare la pătrat

% Squaring

% o sa am caracteristici pozitive si se vor evedentia mai bine semnalele

semnal_squ = sem_dif_fin .^ 2;

figure,

subplot(4,1,1);

plot(time(start_index:end_index), semnal_squ(start_index:end_index));

xlabel('Timp (s)');

ylabel('Amplitudine (mV)');

title('Semnal cu Squaring');

grid on;

%PAS 5

%Integrare

%Moving Window Integration

%obține informații atât despre panta cât și despre lățimea complexului QRS

%PAS 5 Integrare

integreare_f = round(0.150 * fs);

filterrr=ones(1,integreare_f)/integreare_f;

s_integrat= conv(semnal_squ,filterrr, 'same');

%s_integrat = movmean(semnal_squ, integreare_f);

subplot(4,1,2);

plot(time(start_index:end_index), s_integrat(start_index:end_index));

```

```

xlabel('Timp (s)');
ylabel('Amplitudine (mV)');
title('Semnal Integrare');
grid on;

%PAS 6 Initializarea de praguri -> Thresholding
thr=0.01 * max(s_integrat);
s_date = s_integrat > thr;
subplot(4,1,3);
plot(time(start_index:end_index), s_date(start_index:end_index));
xlabel('Timp (s)');
ylabel('Amplitudine (mV)');
title('Semnal cu Thrshold - Prag');
grid on;

%DETECTARE UNDE

%Detectare R

%per_r perioada de refractară - folosit pentru determinarea lungimii
%ferestrei, evită punctele fals pozitive și asigură că unda R este
%detectată într-o fereastră

%fer_r fereastră refractară - asigură detecarea unei singure unde R la un
%moment dat

per_r = round(0.25 * fs);
fer_r = zeros(1, per_r);
r_vs = zeros(size(s_date)); % va stoca amplitudinile undelor R
r_locs = []; %va stoca locațiile undelor R

%se produce o iterare peste fiecare probă a senalului s_date
for i = 1:length(s_date) - per_r

%verifică dacă valoare curentă e zero și că nici o undă R anterioară nu
%este în fereastra curentă

    if s_date(i) && all(fer_r == 0)

%detectare amplitudine și locație unda R

        [r_v, r_loc] = max(s_normalizat(i:i + per_r));

```

```

    r_vs(i + r_loc - 1) = r_v;
    r_locs = [r_locs i + r_loc - 1];
    fer_r = ones(1, per_r);
else
    fer_r = [0 fer_r(1:end - 1)];
% dacă condiția nu este adevărată atunci fereastra se mută cu o poziție
% spre dreapta
end
end

%UNDA Q
referinta_q = round(0.2 * fs);
q_locs = zeros(size(r_locs));
% Se caută Q fix înainte de poziția lui R
for i = 1:length(r_locs)
    r_loc = r_locs(i);
    start_cq = max(r_loc - referinta_q, 1);
    end_cq = r_loc - 1;
    [q_v, q_idx] = min(s_normalizat(start_cq:r_loc));
    q_locs(i) = start_cq + q_idx - 1;
end

%Unda S
% referința aproape unda R (imediat după ea)
referinta_s = round(0.05 * fs);
s_locs = zeros(size(r_locs));
% cautare unda s după unda r
for i = 1:length(r_locs)
    r_loc = r_locs(i);
    start_cs = r_loc + 1;
    end_cs = min(r_loc + referinta_s, length(s_normalizat));
    [s_v, s_idx] = min(s_normalizat(start_cs:end_cs));

```

```

    s_locs(i) = start_cs + s_idx - 1;
end
%UNDA T
referinta_t = round(0.15 * fs);
t_locs = zeros(size(r_locs));
for i = 1:length(r_locs)
    r_loc = r_locs(i);
    start_ct = r_loc + referinta_t;
    end_ct = min(r_loc + referinta_t, length(s_normalizat));
    [t_v, t_idx] = max(s_normalizat(start_ct:end_ct));
    t_locs(i) = start_ct + t_idx - 1;
end
% UNDA P
referinta_p = round(0.13 * fs);
p_locs = zeros(size(r_locs));
p_vs = zeros(size(r_locs));
for i = 1:length(r_locs)
    r_loc = r_locs(i);
    start_cp = max(r_loc - referinta_p, 1);
    end_cp = r_loc - referinta_p;
    [p_v, p_idx] = max(s_normalizat(start_cp:end_cp));
    p_vs(i) = p_v;
    p_locs(i) = start_cp + p_idx - 1;
end

% TOATE undeale PQRST din intervalul ales
r_loc_specific = r_locs(r_locs >= start_index & r_locs <= end_index);
q_loc_specific = q_locs(q_locs >= start_index & q_locs <= end_index);
s_loc_specific = s_locs(s_locs >= start_index & s_locs <= end_index);
t_loc_specific = t_locs(t_locs >= start_index & t_locs <= end_index);
p_loc_specific = p_locs(p_locs >= start_index & p_locs <= end_index);

```

```

% AMPLITUDINI SPECIFICE TOATE UNDELE

r_amp_specific = s_normalizat(r_loc_specific);

p_amp_specific = s_normalizat(p_loc_specific);

t_amp_specific = s_normalizat(t_loc_specific);

% Afisare amplitudini in consola

disp('R Valori perioada aleasa:');

disp(num2str(r_amp_specific, '%.4f '));

disp('P Valori perioada aleasa:');

disp(num2str(p_amp_specific, '%.4f '));

disp('T Valori perioada aleasa:');

disp(num2str(t_amp_specific, '%.4f '));

% AFISARE QRSPT Unde detectate

figure,

plot(time(start_index:end_index), s_normalizat(start_index:end_index), 'b');

hold on;

xlabel('Time (s)');

ylabel('Amplitude (mV)');

title('ECG Detectie puncte QRSPT');

grid on;

scatter(time(r_loc_specific), s_normalizat(r_loc_specific), 'r', 'filled', 'MarkerEdgeColor', 'none',
'SizeData', 50, 'MarkerFaceAlpha', 0.5);

scatter(time(q_loc_specific), s_normalizat(q_loc_specific), 'g', 'filled', 'MarkerEdgeColor', 'none',
'SizeData', 50, 'MarkerFaceAlpha', 0.5);

scatter(time(s_loc_specific), s_normalizat(s_loc_specific), 'm', 'filled', 'MarkerEdgeColor', 'none',
'SizeData', 50, 'MarkerFaceAlpha', 0.5);

scatter(time(t_loc_specific), s_normalizat(t_loc_specific), 'c', 'filled', 'MarkerEdgeColor', 'none',
'SizeData', 50, 'MarkerFaceAlpha', 0.5);

scatter(time(p_loc_specific), s_normalizat(p_loc_specific), 'yellow', 'filled', 'MarkerEdgeColor',
'none', 'SizeData', 50, 'MarkerFaceAlpha', 0.5);

% legend({'Semnal ECG', 'Vârf R', 'Vârf Q', 'Vârf S', 'Vârf T', 'Vârf P'})

% Calcul intervale axa timp rr

intervale_rr = diff(time(r_locs));

avg_rr_interval = mean(intervale_rr);

```

```

%Determinare Intervale RR perioadă aleasă
rr_intervale = diff(time(r_loc_specific));
intervale_rr_spec = diff(time(r_loc_specific));
disp('Intervale RR:');
disp(num2str(rr_intervale, '%.4f '));
avg_rr_interval2 = mean(rr_intervale);
rr_times = time(r_loc_specific(1:end-1)) + rr_intervale / 2;
figure,
subplot(3,1,1);
plot(rr_times, rr_intervale, '-o', 'MarkerFaceColor', 'r', 'LineWidth', 1.5);
xlabel('Time (s)');
ylabel('RR Interval (s)');
title('Valori intervale RR');
grid on;

for i = 1:length(rr_intervale)
    text(rr_times(i), rr_intervale(i), sprintf('%.2f', rr_intervale(i)), 'VerticalAlignment', 'bottom',
    'HorizontalAlignment', 'right');
end

% DETERMINARE AMPLITUDINE MEDIE UNDA R
% calcul amplitudini unda r
r_amp_amplitudine = s_normalizat(r_loc_specific) - linia_isoelectrica;
r_amplitudine_medie = mean(r_amp_amplitudine);
%disp(['AMPLITUDINEA MEDIA A UNDEI R PE INTERVALUL ALES ESTE: ',
num2str(r_amplitudine_medie, '%.4f')]);

% distanta unde rr media
r_dis_medie=mean(rr_intervale);
%disp(['Distanța MEDIE A undelor RR PE INTERVALUL ALES ESTE: ', num2str(r_dis_medie,
'%.4f')]);

K=0;

% amplitudini unda T
% calcul amplitudini unda T

```

```

t_amp_amplitudine = s_normalizat(t_loc_specific) - linia_isoelectrica;

% amplitudinea medie unda T
t_amp_amplitudine_medie = mean(t_amp_amplitudine);

% Spectrul de PUTERE si calculul PUTERII totale

% se aplica prima data FFT
N_s = length(s_normalizat(start_index:end_index));
f_s = (0:N_s-1) * (fs / N_s);
n_s = floor(N_s / 2);
FFT_ECG = fft(s_normalizat(start_index:end_index));

% amplitudinii spectrului
ecg_amplitudine_putere = abs(FFT_ECG / N_s);

% calcul pt. spectru de putere
putere_ECG = ecg_amplitudine_putere.^2;

%separareinterval pozitiv de cel negativ

figure();
plot(f_s(1:n_s), putere_ECG(1:n_s));
title('Spectrul de putere al semnalului ECG');
xlabel('Frenta');
ylabel('Putere');
putere_Totala = sum(putere_ECG);
disp('Puterea totală a spectrului de putere semnal ECG:');
disp(putere_Totala);

% H R
% 60 RC 100
timpul = (N/fs)/60;
RC= round(mean(length(r_locs))/timpul);
disp(['Heart rate general: = ', num2str(RC), ' bătăi pe minut']);

% Detectie HR interval scurt
time_segment = time(start_index:end_index);
time_segment_min = length(time_segment) / (fs * 60);
RCs = round(length(r_loc_specific) / time_segment_min);

```

```

disp(['Heart rate interval: = ', num2str(RCs), ' bătăi pe minut']);

%HRV

SDNNS = std(intervale_rr_spec);

disp(['SDNN Interval: ', num2str(SDNNS, '%.4f')]);

% Calculate HRV

%hrv = std(intervale_rr);

% m - numar intervale RR

m = length(intervale_rr_spec);

% Calcul mean ( $\mu$ ) intervale RR

mean_rr = sum(intervale_rr_spec) / m;

% Calcul standard deviation ( $\sigma$ ) intervale RR

standard_dev_rr = sqrt(sum((intervale_rr_spec - mean_rr).^2) / m);

% Calcul interbeat differentials (rd_i)

rd_interval = diff(intervale_rr_spec);

m_rd = length(rd_interval);

% Calcul mean of interbeat differentials ( $\mu_{rd}$ )

mean_rd = sum(rd_interval) / m;

% Standard deviation of interbeat differentials rd

standard_dev_rd = sqrt(sum((rd_interval - mean_rd).^2) / m);

%RMSSD

rmssd2= sqrt(sum((rd_interval).^2) / m);

disp(['Mean RR interval ( $\mu$ ): ', num2str(mean_rr)]);

disp(['Standard Deviation of RR intervals ( $\sigma$ ): ', num2str(standard_dev_rr)]);

disp(['Mean RD interval ( $\mu_{rd}$ ): ', num2str(mean_rd)]);

disp(['Standard Deviation of interbeat differentials rd ( $\sigma$ ): ', num2str(standard_dev_rd)]);

disp(['RMSSD: ', num2str(rmssd2, '%.4f')]);

% NEP (Number of Extreme Points)

%unit 1 -> pozitiv, 0 -> negativ

% deci daca produsul este pozitiv unit pozitiv => unit = 1 => SUMA 1-1 = 0

% deci daca produsul este negativ unit negativ => unit = 0 => SUMA 1-0 = 1

m_NEP = length(rr_intervale);

```

```

NEP_sum = 0;
for i = 2:m_NEP-1
    if ((rr_intervale(i) - rr_intervale(i-1)) * (rr_intervale(i+1) - rr_intervale(i))) < 0
        NEP_sum = NEP_sum + 1;
    end
end
NEP = (1 / (m_NEP - 2)) * NEP_sum;
disp(['Number of Extreme Points (NEP): ', num2str(NEP)]);
%filename = input('Introduceți numele fișierului pentru salvare (includeți ".csv"): ', 's');
%csvwrite(filename, [time(start_index:end_index), data(start_index:end_index)]);
%INTERVALU QRS
val = length(intervale_rr_spec);
s_end = zeros(1, val);
%Detactare punct final interval QRS
for i = 1:val
    start_s_idx = s_loc_specific(i);
    s_end_idx = find(s_normalizat(start_s_idx:end) >= linia_isoelectrica, 1, 'first') + start_s_idx - 1;
    s_end(i) = s_end_idx;
end
% Detectie Interval QRS
qrs_durata = zeros(1,val);
qrs_start_points = zeros(1,val);
qrs_end_points = zeros(1,val);
for i = 1:val
    qrs_start = find(s_normalizat(p_loc_specific(i):q_loc_specific(i)) <= linia_isoelectrica, 1, 'first') - 1;
    qrs_start = p_loc_specific(i) + qrs_start - 1;
    qrs_end = s_end(i);
    qrs_duration_samples = qrs_end - qrs_start + 1;
    qrs_duration_seconds = qrs_duration_samples / fs;
    qrs_durata(i) = qrs_duration_seconds;
end

```

```

qrs_start_points(i)=qrs_start;
qrs_end_points(i)= qrs_end;
end

disp('Intervale QRS:');
disp(num2str(qrs_durata, '%.4f '));

% Plot QRS

figure;
plot(time_axis, s_normalizat(start_index:end_index));

hold on;

% Afisare interval

for i = 1:length(qrs_start_points)

    plot(qrs_start_points(i) / fs, linia_isoelectrica * ones(size(qrs_start_points(i))), 'bo',
'MarkerSize', 5);

    plot(qrs_end_points(i) / fs, linia_isoelectrica * ones(size(qrs_end_points(i))), 'ko', 'MarkerSize',
5);

    plot([qrs_start_points(i) / fs qrs_end_points(i) / fs], [linia_isoelectrica linia_isoelectrica], 'g',
'LineWidth', 2);

end

% afisare interval selectat

xlim([start_index / fs end_index / fs]);

% interval QRS legenda

hold off;

title('Intervale QRS Semnal ECG');

xlabel('Time (s)');

ylabel('Amplitude (mV)');

legend('Semnal ECG ', 'QRS start ', 'QRS end ', 'QRS interval');

% INTERVALUL PR

pr_intervals = zeros(size(p_loc_specific));

pr_start_points = zeros(size(p_loc_specific));

pr_end_points = zeros(size(p_loc_specific));

for i = 1:length(p_loc_specific)

    pr_start = find(s_normalizat(1:p_loc_specific(i)) <= linia_isoelectrica, 1, 'last');

```

```

if i <= length(q_loc_specific)

    qrs_start = find(s_normalizat(p_loc_specific(i):q_loc_specific(i)) <= linia_isoelectrica, 1,
'first') - 1;

    pr_end = p_loc_specific(i) + qrs_start - 1;

end

if ~isempty(pr_start) && ~isempty(pr_end)

    pr_intervals(i) = time(pr_end) - time(pr_start);

    pr_start_points(i) = pr_start;

    pr_end_points(i) = pr_end;

else

    pr_intervals(i) = NaN;

end

end

disp('Intervale PR:');

disp(um2str(pr_intervals, '%.4f '));

% Plot ECG signal

figure;

plot(time_axis, s_normalizat(start_index:end_index));

hold on;

% AFISRE PR

for i = 1:length(pr_start_points)

    if ~isnan(pr_intervals(i))

        plot(pr_start_points(i) / fs, linia_isoelectrica, 'ro', 'MarkerSize', 5);

        plot(pr_end_points(i) / fs, linia_isoelectrica, 'mo', 'MarkerSize', 5);

        plot([pr_start_points(i) / fs pr_end_points(i) / fs], [linia_isoelectrica linia_isoelectrica], 'b',
'LineWidth', 2);

    end

end

xlim([start_index / fs end_index / fs]);

hold off;

title('Intervale PR Semnal ECG');

```

```

xlabel('Time (s)');
ylabel('Amplitude (mV)');
legend('Semnal ECG', 'PR start ', 'PR end', 'PR interval');

```

```

% Afisare cautare

```

```

figure,
plot(time, s_normalizat, 'b');
hold on;
xlabel('Time (s)');
ylabel('Amplitude (mV)');
title('ECG Detectie puncte QRSPT');
grid on;

scatter(time(r_locs), s_normalizat(r_locs), 'r', 'filled', 'MarkerEdgeColor', 'none', 'SizeData', 50,
'MarkerFaceAlpha', 0.5);

scatter(time(q_locs), s_normalizat(q_locs), 'g', 'filled', 'MarkerEdgeColor', 'none', 'SizeData', 50,
'MarkerFaceAlpha', 0.5);

scatter(time(s_locs), s_normalizat(s_locs), 'm', 'filled', 'MarkerEdgeColor', 'none', 'SizeData', 50,
'MarkerFaceAlpha', 0.5);

scatter(time(t_locs), s_normalizat(t_locs), 'c', 'filled', 'MarkerEdgeColor', 'none', 'SizeData', 50,
'MarkerFaceAlpha', 0.5);

scatter(time(p_locs), s_normalizat(p_locs), 'yellow', 'filled', 'MarkerEdgeColor', 'none', 'SizeData',
50, 'MarkerFaceAlpha', 0.5);

legend({'Semnal ECG', 'Vârf R', 'Vârf Q', 'Vârf S', 'Vârf T', 'Vârf P'})

% DETERMINARE AMPLITUDINE MEDIE UNDA R

% calcul amplitudini unda r
r_amp_amplitudine = s_normalizat(r_loc_specific) - linia_isoelectrica;
r_amplitudine_medie = mean(r_amp_amplitudine);

disp(['AMPLITUDINEA MEDIA A UNDEI R PE INTERVALUL ALES ESTE: ',
num2str(r_amplitudine_medie, '%.4f')]);

% DETERMINARE AMPLITUDINE MEDIE UNDA T

% calcul amplitudini unda T

```

```

t_amp_amplitudine = s_normalizat(t_loc_specific) - linia_isoelectrica;

t_amplitudine_medie = mean(t_amp_amplitudine);

disp(['AMPLITUDINEA MEDIA A UNDEI T PE INTERVALUL ALES ESTE: ',
num2str(t_amplitudine_medie, '%.4f')]);

% DETERMINARE AMPLITUDINE MEDIE UNDA P

% calcul amplitudini unda P

p_amp_amplitudine = s_normalizat(p_loc_specific) - linia_isoelectrica;

p_amplitudine_medie = mean(p_amp_amplitudine);

disp(['AMPLITUDINEA MEDIA A UNDEI P PE INTERVALUL ALES ESTE: ',
num2str(p_amplitudine_medie, '%.4f')]);

% distanta unde rr media

r_dis_medie=mean(rr_intervale);

disp(['Distanța MEDIE A undelor RR PE INTERVALUL ALES ESTE: ', num2str(r_dis_medie,
'%.4f')]);

% distanta unde qrs media

qrs_dis_medie=mean(qrs_durata);

disp(['Distanța MEDIE A undelor QRS PE INTERVALUL ALES ESTE: ', num2str(qrs_dis_medie,
'%.4f')]);

% distanta unde pr media

pr_dis_medie=mean(pr_intervals);

disp(['Distanța MEDIE A undelor PR PE INTERVALUL ALES ESTE: ', num2str(pr_dis_medie,
'%.4f')]);

%DETECTOR

%  UNDA R

normal_values = [
    0.6037 0.611 0.6057 0.5778 0.5801;
    0.7411 0.7458 0.729 0.7111 0.7253;
    0.7412 0.7631 0.742 0.7363 0.74565;
    0.6341 0.6256 0.6376 0.6326 0.628;
    0.7223 0.7216 0.7071 0.7126 0.7159;
];

```

```

apnea_values = [
    0.6508 0.6557 0.6533 0.6625 0.63;
    0.847 0.8364 0.7813 0.77 0.8086;
    0.8577 0.9004 0.8669 0.8942 0.8984;
    0.7126 0.7114 0.7025 0.7103 0.7446;
    0.8524 0.7931 0.8322 0.8821 0.83995;
];

% Combină toate valorile într-un singur vector
combined_normal_values = normal_values(:);
combined_apnea_values = apnea_values(:);

% calcul media valori normale si cu apnee
mean_combined_normal = mean(combined_normal_values);
mean_combined_apnea = mean(combined_apnea_values);

% Determinare Prag General
prag_medie = (mean_combined_normal + mean_combined_apnea) / 2;
disp(['Pragul General/unic este: ', num2str(prag_medie)]);

% Clasificare in functie de prag
disp('Clasificare vector valori normale:');
for i = 1:size(normal_values, 1)
    for j = 1:size(normal_values, 2)
        value = normal_values(i, j);
        if value > prag_medie
            disp(['Vector Normal (Persoana ', num2str(i), ', Valoare ', num2str(j), '): Apnea']);
        else
            disp(['Vector Normal (Persoana ', num2str(i), ', Valoare ', num2str(j), '): Normal']);
        end
    end
end

end

% Clasificare intervale cu apnee
disp('Clasificare vector valori apnee:');
for i = 1:size(apnea_values, 1)

```

```

for j = 1:size(apnea_values, 2)
    value = apnea_values(i, j);
    if value > prag_medie
        disp(['Vector Apnea (Persoana ', num2str(i), ', Valoare ', num2str(j), '): Apnea']);
    else
        disp(['Vector Apnea (Persoana ', num2str(i), ', Valoare ', num2str(j), '): Normal']);
    end
end
end

% Valoarea de clasificare dintre cazurile normale si cele cu apne
prag = 5;

% Definire matrice pentru fiecare persoana
subiect_a01_normal = [
    0 0 0 1 0 0 0 0 0 1 0 0 1;
    0 1 0 0 0 0 0 0 0 1 0 0 0;
    0 0 0 1 0 0 0 0 0 1 0 0 0;
    0 0 0 1 0 0 0 0 0 1 0 0 1;
    0 0 0 1 0 0 0 0 0 1 0 0 0;
];

subiect_a01_apnea = [
    0 0 1 0 0 1 0 0 1 1 1 1 0 0;
    0 0 1 0 1 0 0 0 0 1 0 1 1;
    0 0 0 1 0 0 0 0 1 1 1 1 1 1;
    0 0 1 1 0 0 0 0 1 1 1 1 1 0;
    0 0 1 1 0 0 1 0 1 1 1 1 1 1;
];

subiect_a07_normal = [
    1 1 0 0 1 0 0 1 0 0 0 0 0;
    1 1 0 1 1 0 0 1 0 0 0 0 0;
    0 1 0 0 1 0 0 1 0 0 0 0 0;
    0 1 0 0 1 0 0 1 0 0 0 0 1;
];

```

```
    0100100100000;  
];  
subject_a07_apnea = [  
    1101110111111;  
    1101110101001;  
    1100100101001;  
    1101110101001;  
    1101110111011;  
];  
subject_a13_normal = [  
    1000100000000;  
    1100100100000;  
    1000100000001;  
    1000100000000;  
    1000100000000;  
];  
subject_a13_apnea = [  
    1110110111100;  
    1100110111100;  
    1100110100001;  
    1101110101000;  
    1100110111100;  
];  
subject_a14_normal = [  
    0011000011111;  
    0011010001000;  
    0011000001000;  
    0011000011110;  
    0001010001011;  
];  
subject_a14_apnea = [  

```

```

0011001011111;
00110110111110;
0011011011111;
0011011011111;
1011000011111;
];
subject_a19_normal = [
    0010010000000;
    0010010000001;
    0010010000001;
    0010010000001;
    0010010000000;
];
subject_a19_apnea = [
    1010010100000;
    1010010000000;
    1010010000001;
    1010010100000;
    1010010100001;
];
% stocare nume si matrici
data = {
    'Subject_a01_Normal', subject_a01_normal;
    'Subject_a01_Apnea', subject_a01_apnea;
    'Subject_a07_Normal', subject_a07_normal;
    'Subject_a07_Apnea', subject_a07_apnea;
    'Subject_a13_Normal', subject_a13_normal;
    'Subject_a13_Apnea', subject_a13_apnea;
    'Subject_a14_Normal', subject_a14_normal;
    'Subject_a14_Apnea', subject_a14_apnea;
    'Subject_a19_Normal', subject_a19_normal;

```

```

'Subiect_a19_Apnea', subject_a19_apnea;
};
for i = 1:size(data, 1)
    denumire = data{i, 1};
    sir = data{i, 2};
    % numaratoare in cadrul sirului
    for rand = 1:size(sir, 1)
        k = sum(sir(rand, :) == 1);
        %Determinare rezultat
        if k >= prag
            classification = 'Apnea';
        else
            classification = 'Normal';
        end
        % Afisare Rezultat
        disp([denumire, ' esantion ', num2str(rand), ' Detectie: ', classification]);
    end
    disp(' ');
end
end

```

Ioan Adrian Candrea

Data nașterii: 12/04/2001

Cetățenie: română

Gen: Masculin

CONTACT

Jud. Suceava, Com. Dorna
Candrenilor, Sat Dealu Floreni ,
Str. Poligon nr. 23, -
727192 Dealu Floreni, România
(Acasă)

ioanadrian.candrea@gmail.com

(+40) 759017198

[https://www.linkedin.com/in/
ioan-adrian-
candrea-9b89761bb/](https://www.linkedin.com/in/ioan-adrian-candrea-9b89761bb/)



europass

DESPRE MINE

Student la Universitatea Tehnică din Cluj-Napoca, Facultatea de Electronică Telecomunicații și Tehnologia Informației în anul 4, vreau să îmi construiesc o carieră în acest domeniu, prin care să îmi pot folosi abilitățile și cunoștințele dobândite până în acest moment. Îmi doresc să mă aflu într-o companie/mediu care susține și caută oameni dedicați, aflați într-o dezvoltare continuă din punct de vedere profesional și personal.

EDUCAȚIE ȘI FORMARE PROFESIONALĂ

- 2020 – **ÎN CURS** Cluj-Napoca, România
- **Studii Nivel Licență** Universitatea Tehnică din Cluj-Napoca
- 2016 – 2020 Bistrița, România
- **Diplomă de Bacalaureat, media 9,36** Colegiul Național "Andrei Mureșanu" Bistrița, Matematică-Informatică, Intensiv Informatică

PROIECTE

- **Proiect realizat în MATLAB: Implementarea unei interfețe care calculează și afișează caracteristicile unui Amplificator de Putere Clasă A**
- **Proiect realizat în Python : Implementarea unei aplicații (Harris corner detector) care să detecteze colțurile dintr-o imagine folosind metoda Harris pentru detecția colțurilor.**
- **Proiect realizat în C reprezentat de implementarea unui server și al unui client prin intermediul socket-urilor utilizând protocolul TCP**
- **Proiectarea unui senzor de temperatură folosind OrCAD**
- **Ceas Cu Cronometru și Alarmă utilizând VHDL**
- **2020 - ATESTAT DE COMPETENȚE PROFESIONALE: Realizarea design-ului și structurii produselor soft necesare implementării de pagini WEB(HTML,CSS,JS)**

COMPETENȚE DIGITALE

Microsoft Office | Utilizare buna a programelor de comunicare(mail messenger skype) | cunoștințe Matlab | OrCad (proiectare scheme electronice) | Cunoștințe medii Linux | SQL SERVER MANAGEMENT STUDIO | Cunoștințe de bază în HTML/CSS/JavaScript | Cunoștințe de bază în C/C++/Java

COMPETENȚE LINGVISTICE

LIMBĂ(I) MATERNĂ(E): română

Altă limbă (Alte limbi):

engleză

Comprehensiune orală B2

Citit B2

Scris B2

Exprimare scrisă B2

Conversație B1

Niveluri: A1 și A2 Utilizator de bază B1 și B2 Utilizator independent C1 și C2 Utilizator experimentat

VOLUNTARIAT

Cluj-Napoca

● **Alegerile studenților din Universitatea Tehnică**

● **Crosul Universității Tehnice- Crosul UT**

PERMIS DE CONDUCERE

● **Permis de conducere: AM**

● **Permis de conducere: B1**

● **Permis de conducere: B**

